Big Data

Diplomado de Datos 2026

Clase 1: Introducción

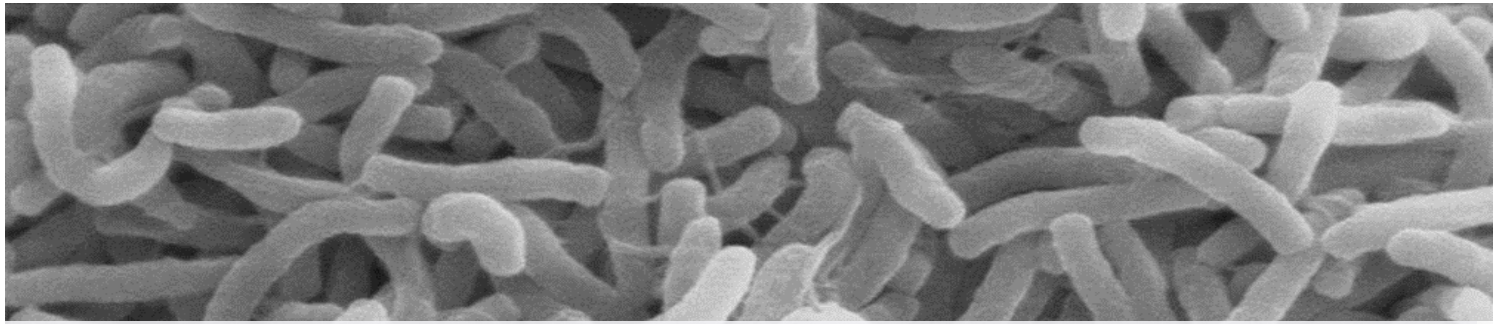
Aidan Hogan
aidhog@gmail.com

El valor de los datos

Soho, Londres, 1854

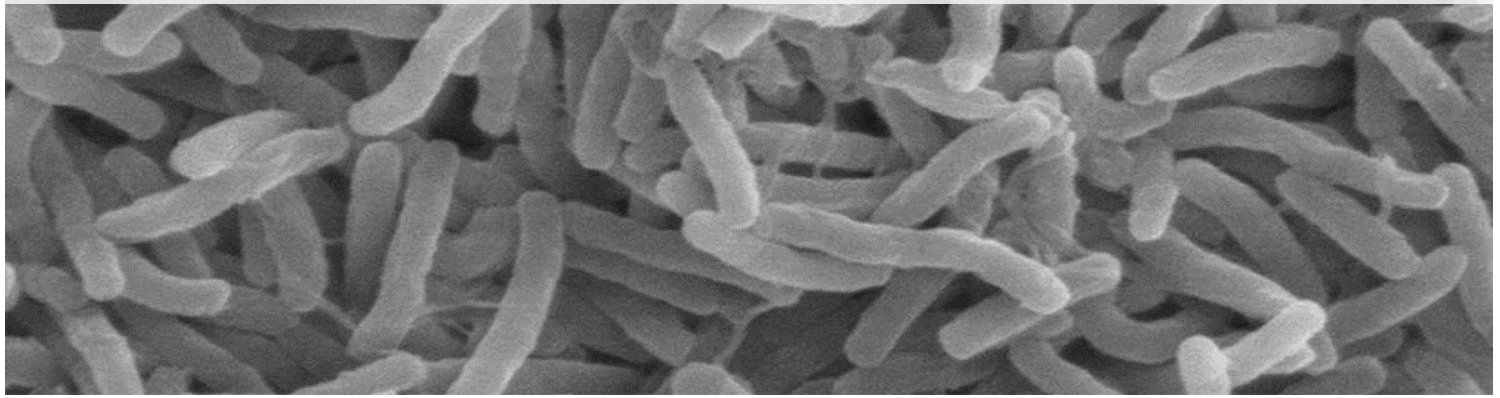


Cólera: Lo que sabemos hoy en día …

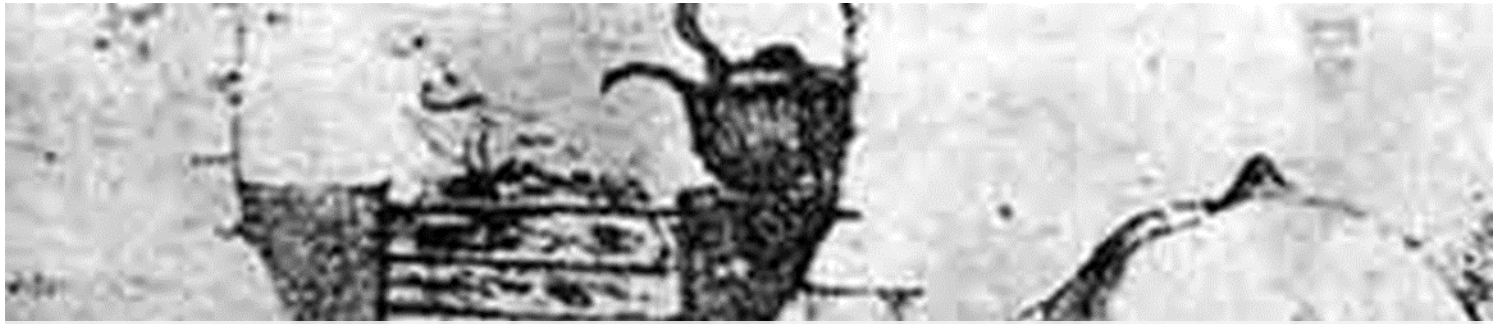


cólera [2]

1. m. **PAT.** Enfermedad infecciosa producida por una bacteria que se transmite a través de aguas contaminadas y que origina dolores abdominales, vómitos y diarreas que pueden causar la muerte.



Cólera: Lo que sabíamos en 1854



cólera [2]

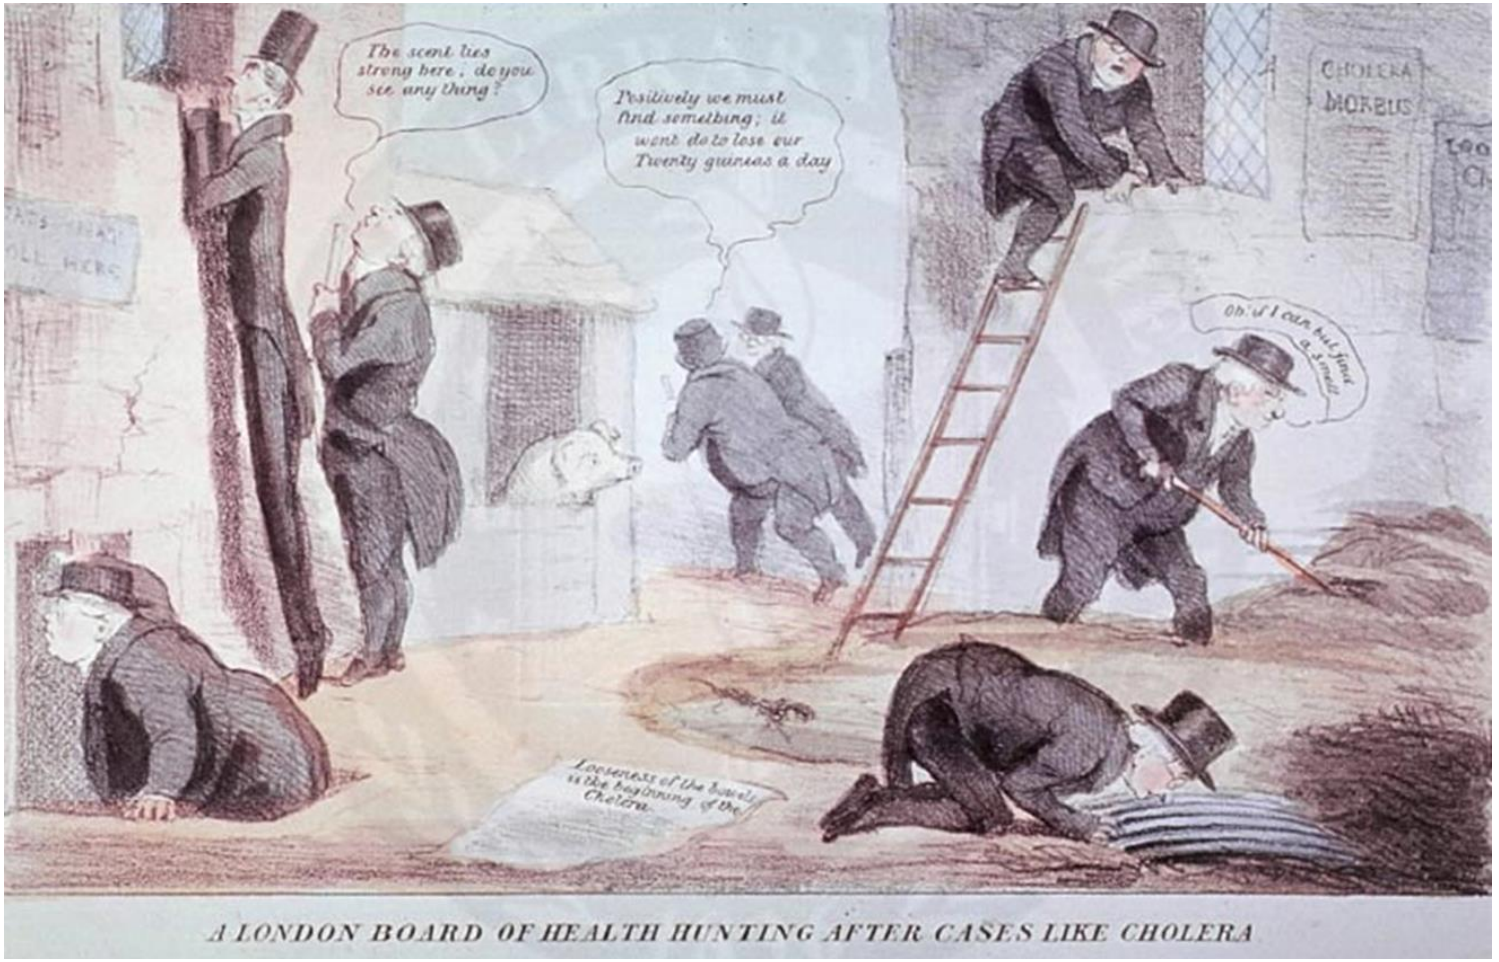
1. m. **PAT.** Enfermedad infecciosa producida por una bacteria que se transmite a través de aguas contaminadas y que origina dolores abdominales, vómitos y diarreas que pueden causar la muerte.



1854: La teoría del miasma de Galen



1854: La caza por el cólera invisible



A LONDON BOARD OF HEALTH HUNTING AFTER CASES LIKE CHOLERA

John Snow: 1813–1858



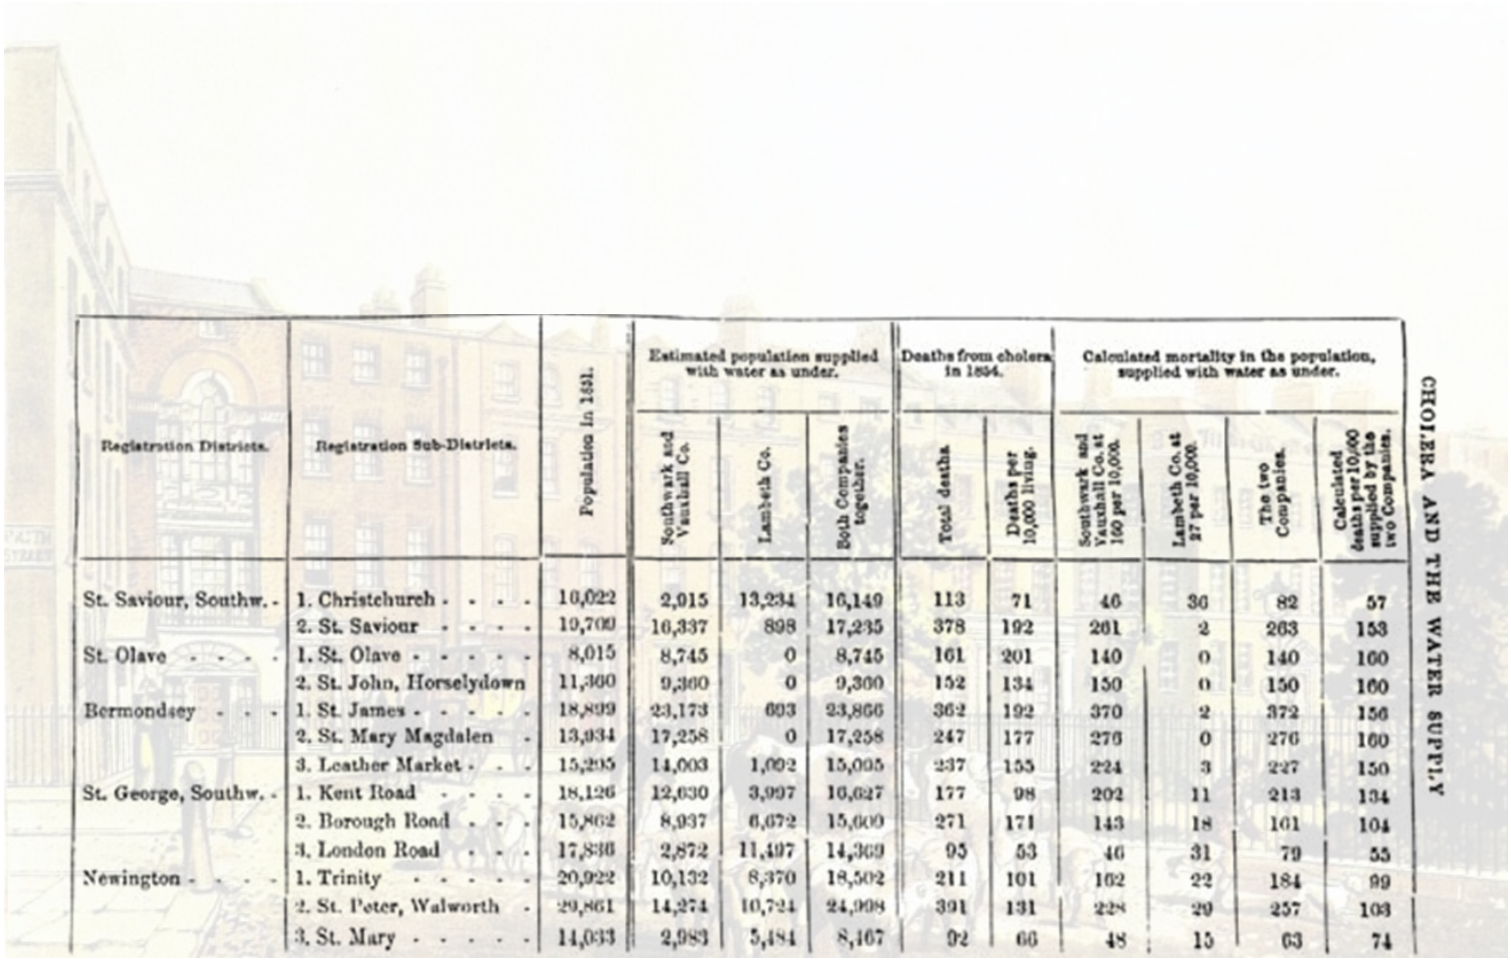
John Snow: 1813–1858



La encuesta de Soho



Recolección de datos ...



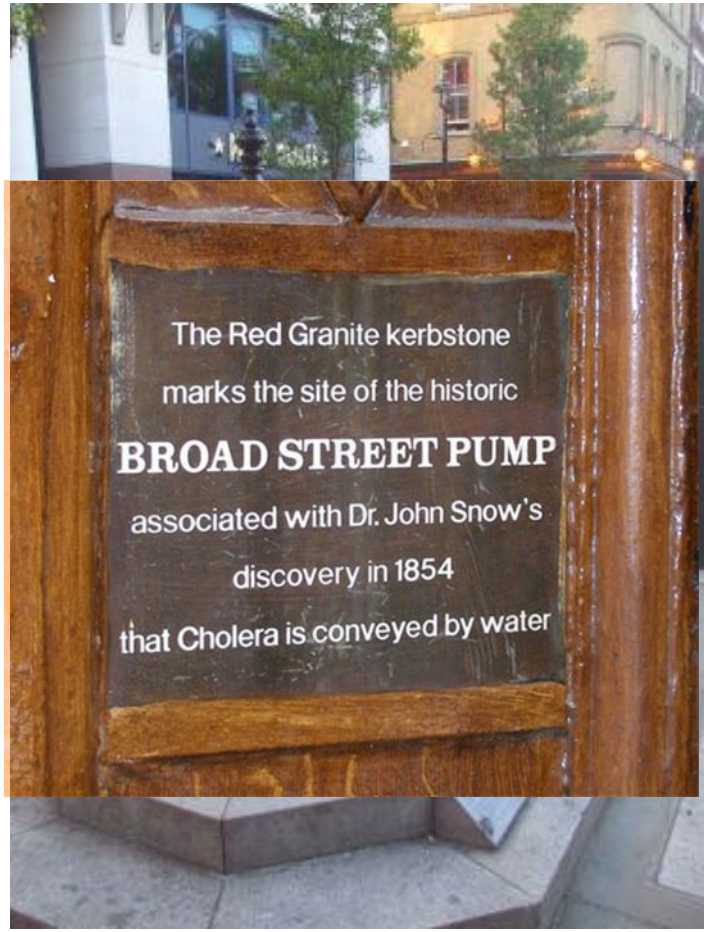
CHOLERA AND THE WATER SUPPLY.

Registration Districts.	Registration Sub-Districts.	Population in 1851.	Estimated population supplied with water as under.			Deaths from cholera in 1854.		Calculated mortality in the population, supplied with water as under.			
			Southwark and Vauxhall Co.	Lambeth Co.	Both Companies together.	Total deaths	Deaths per 10,000 living.	Southwark and Vauxhall Co. at 150 per 10,000.	Lambeth Co. at 37 per 10,000.	The two Companies.	Calculated deaths per 10,000 supplied by the two Companies.
St. Saviour, Southw.	1. Christchurch	16,022	2,915	13,234	16,149	113	71	46	36	82	57
	2. St. Saviour	19,709	16,337	898	17,235	378	192	261	2	263	153
St. Olave	1. St. Olave	8,015	8,745	0	8,745	161	201	140	0	140	160
	2. St. John, Horselydown	11,360	9,360	0	9,360	152	134	150	0	150	160
Bermondsey	1. St. James	18,899	23,173	693	23,866	362	192	370	2	372	156
	2. St. Mary Magdalen	13,034	17,258	0	17,258	247	177	276	0	276	160
	3. Leather Market	15,295	14,003	1,092	15,095	237	155	224	3	227	150
St. George, Southw.	1. Kent Road	18,126	12,630	3,997	16,627	177	98	202	11	213	134
	2. Borough Road	15,862	8,937	6,672	15,609	271	171	143	18	161	104
	3. London Road	17,836	2,872	11,497	14,369	95	53	46	31	79	55
Newington	1. Trinity	20,922	10,132	8,370	18,502	211	101	162	22	184	99
	2. St. Peter, Walworth	29,861	14,274	10,724	24,998	391	131	228	29	257	103
	3. St. Mary	14,033	2,983	5,484	8,467	92	66	48	15	63	74

Lo que los datos mostraron …

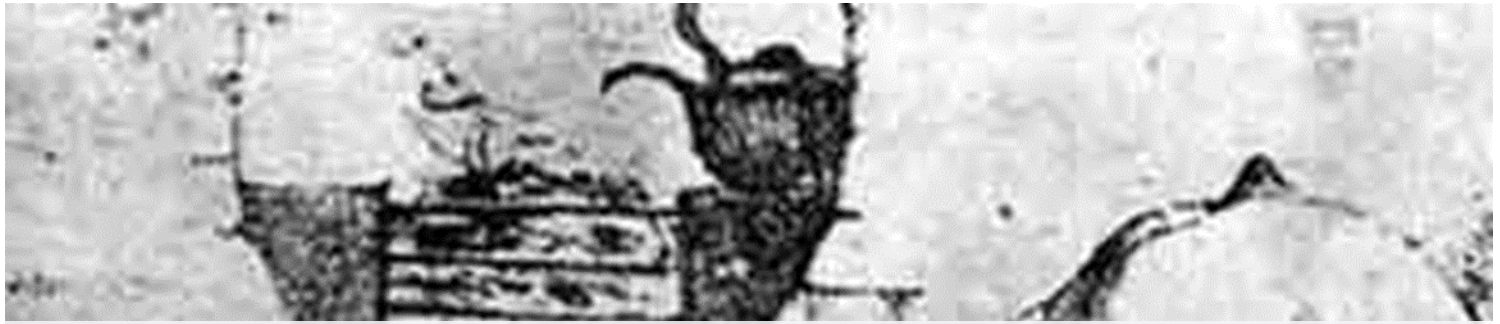


616 muertes, 8 días después …





Lo que aprendimos …



cólera [2]

1. m. **PAT.** Enfermedad infecciosa producida por una bacteria que se transmite a través de aguas contaminadas y que origina dolores abdominales, vómitos y diarreas que pueden causar la muerte.



Cartel cólera ca. 1866 (aviso de hervir el agua)

CHOLERA
AND
WATER.

BOARD OF WORKS
FOR THE LIMEHOUSE DISTRICT,
Comprising Limehouse, Ratcliff, Shadwell, and Wapping.

The INHABITANTS of the District within which CHOLERA IS PREVAILING, are earnestly advised

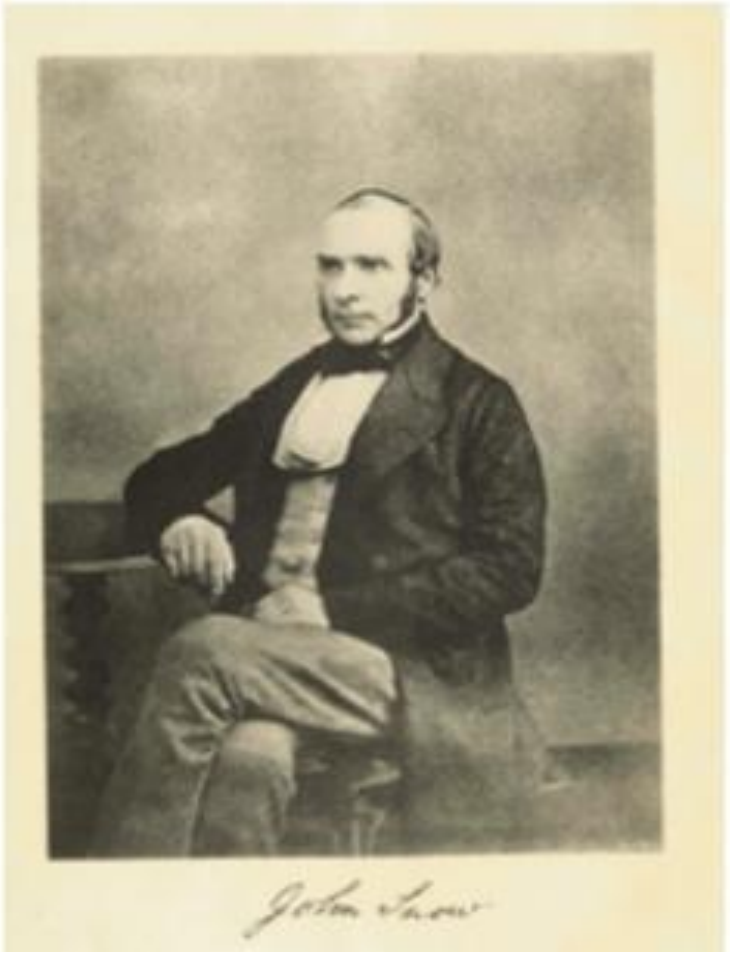
NOT TO DRINK ANY WATER
WHICH HAS NOT
PREVIOUSLY BEEN BOILED.

Fresh Water ought to be Boiled every Morning for the day's use, and what remains of it ought to be thrown away at night. The Water ought not to stand where any kind of dirt can get into it, and great care ought to be given to see that Water Butts and Cisterns are free from dirt.

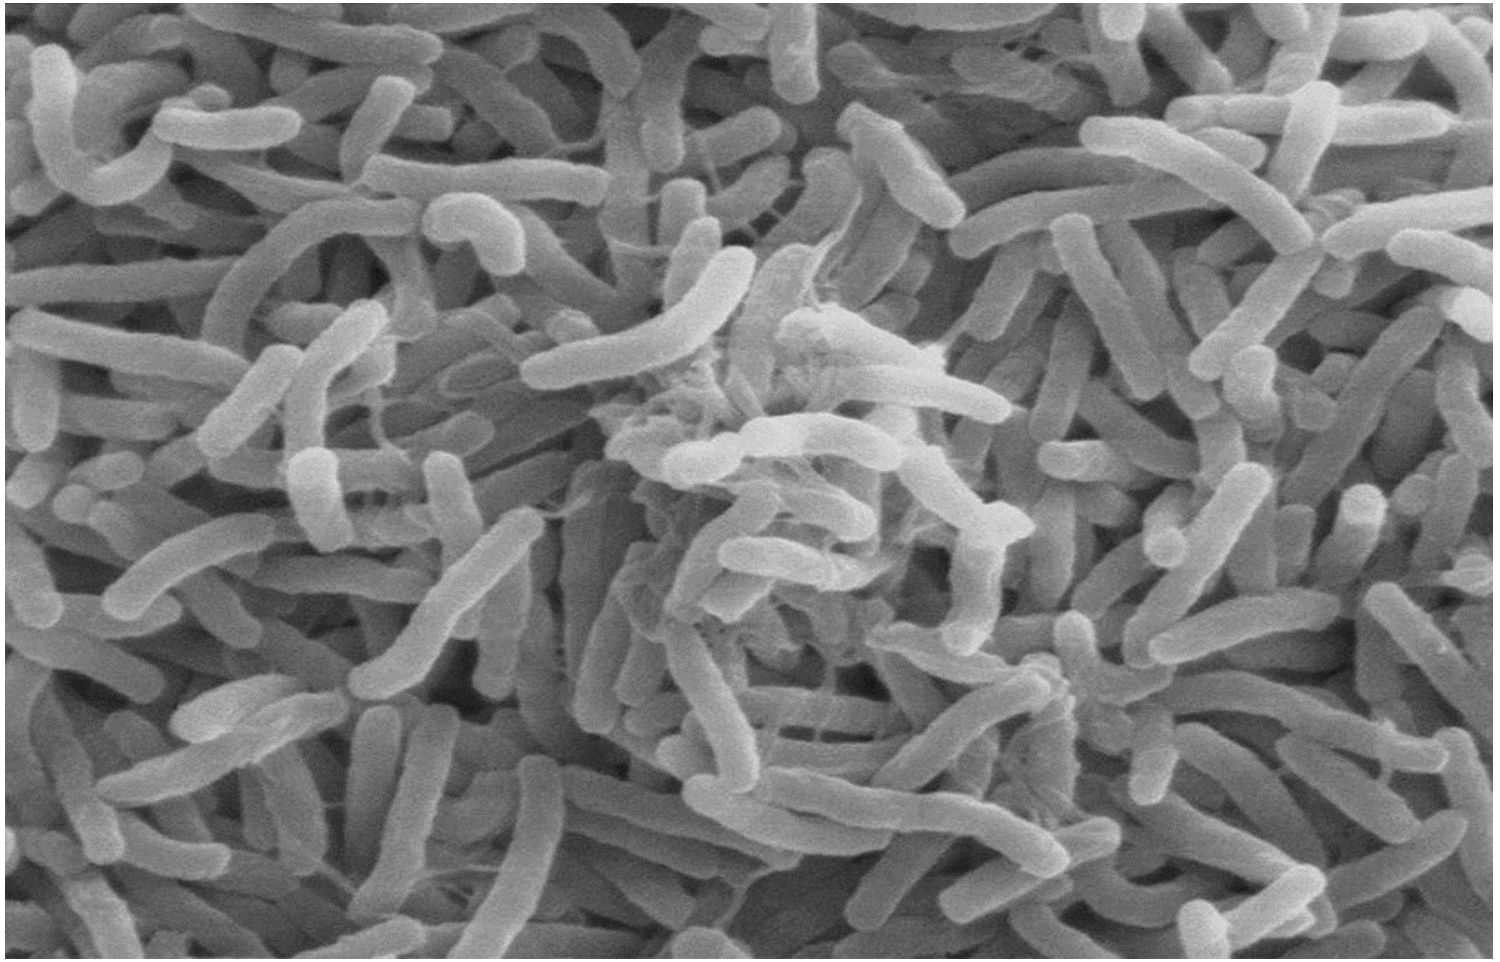
BY ORDER,

THOS. W. RATCLIFF,
CLERK OF THE BOARD.

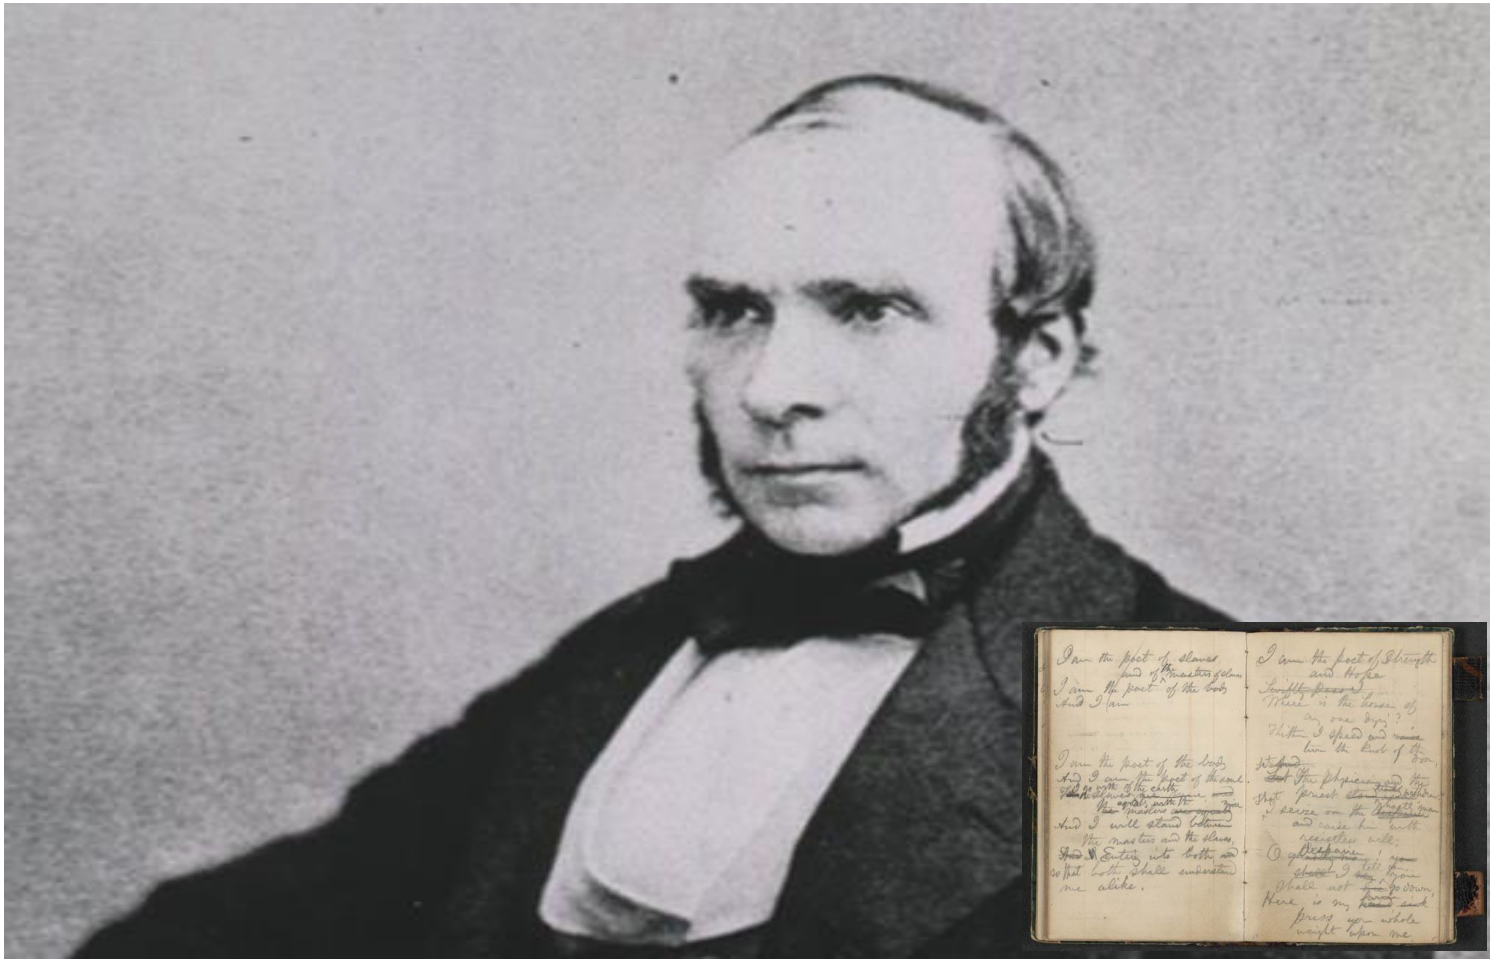
Board Office, Bow [illegible] Street,
[illegible]



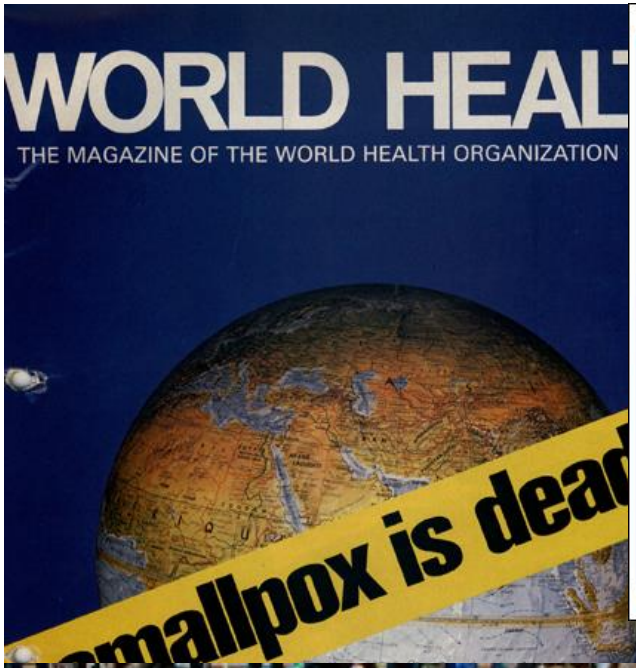
30 años antes (del descubrimiento) de *V. cholerae*



John Snow: El padre de la Epidemiología



Historias de éxitos de la Epidemiología

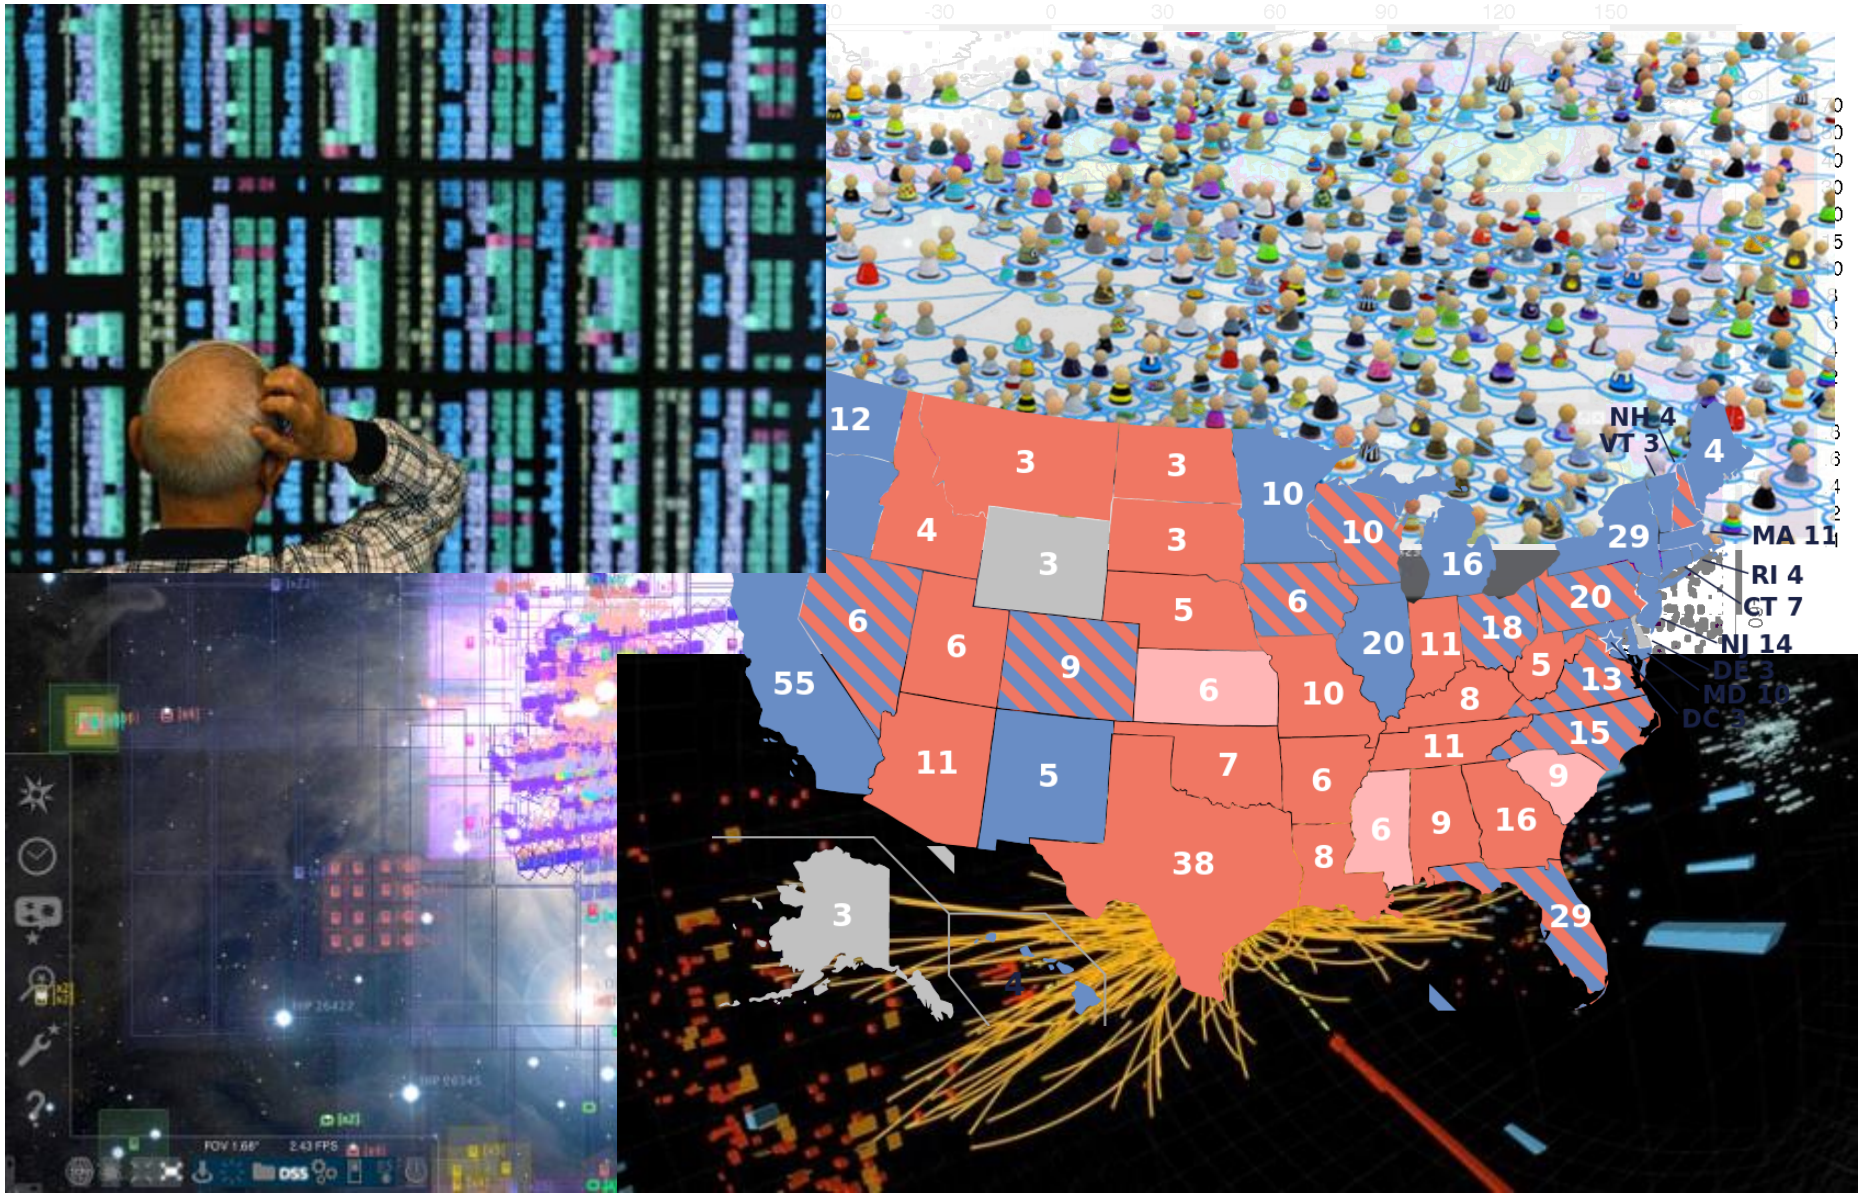








Valor de los datos: No sólo Epidemiología



Cuadernos no son suficientemente buenos



El crecimiento de los datos

“Big Data”



English Wikipedia

≈ 51 GB de datos

(2015 dump)

(Texto; Datos actuales)

(XML; no comprimido)

WIKIPEDIA
The Free Encyclopedia

1 Wiki = 1 Wikipedia

“Big Data”

Twitter

≈ 8 TB / día

≈ 157 Wiki / día

(2013, generados)



“Big Data”



Vera C. Rubín (LSST)

≈ 20 TB / día (noche)

≈ 392 Wiki / día

(2025, generados)



“Big Data”



Large Hadron Collider

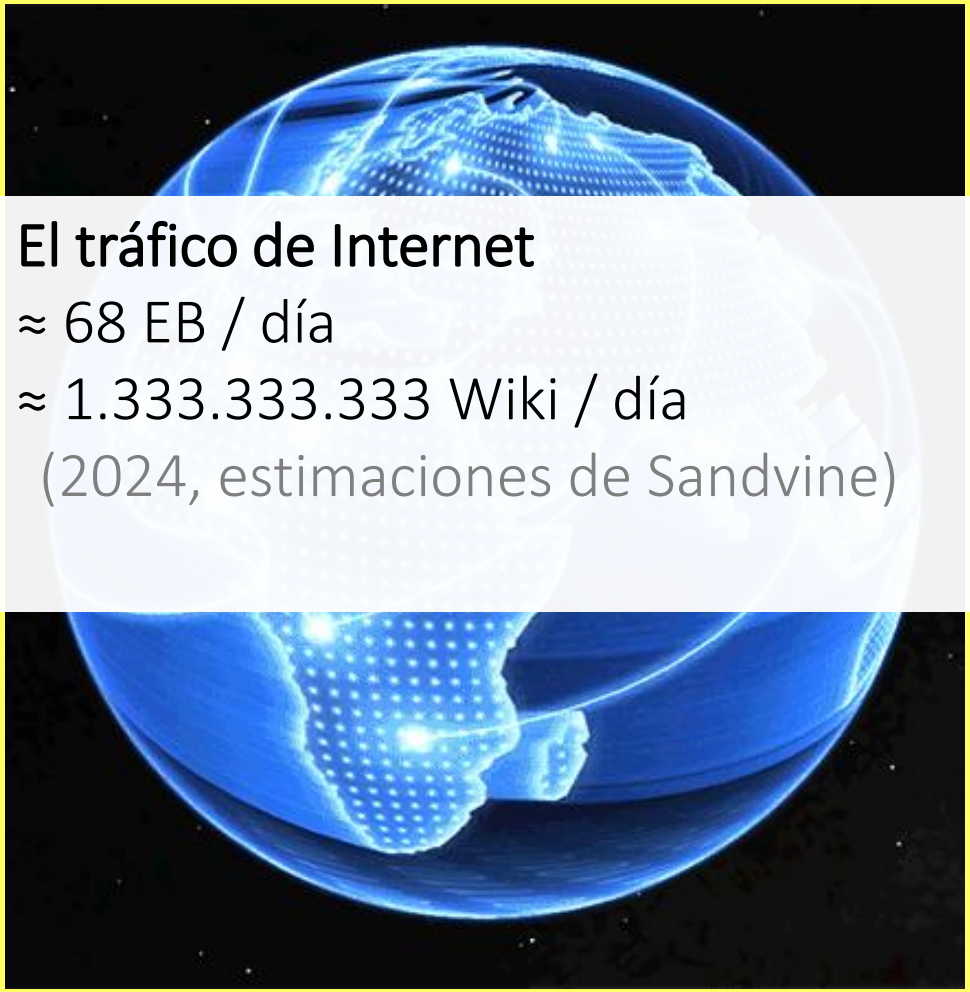
≈ 10 PB / día

≈ 196.070 Wiki / día

(2017, datos filtrados)



“Big Data”



El tráfico de Internet

≈ 68 EB / día

≈ 1.333.333.333 Wiki / día

(2024, estimaciones de Sandvine)

Los datos: Un cuello de botella moderno?



Las ‘V’s de “Big Data”



“Big Data” necesita “Gestión de datos (masivos)” …

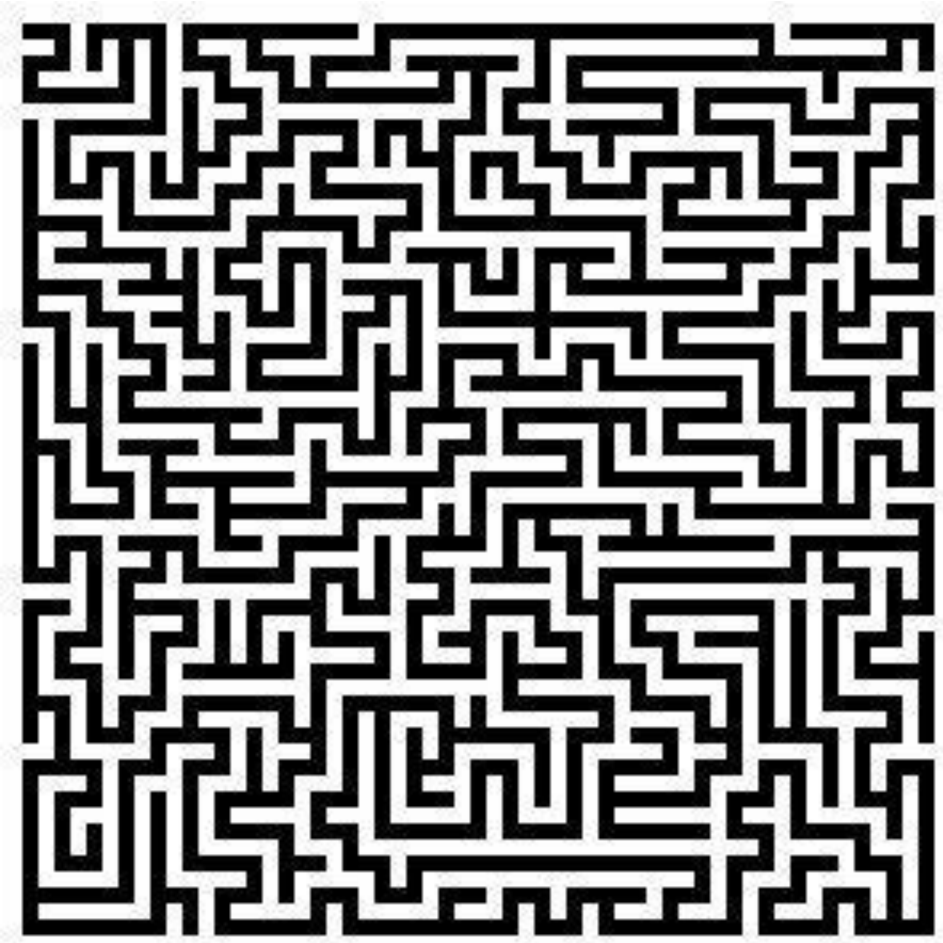
Cada aplicación es distinta …

- **Datos** pueden ser
  - (semi-)estructurados
    - (Relational DBs, JSON, XML, CSV)
  - sin estructura
    - (documentos de texto, tweets, comentarios)
  - y cualquier cosa entre medio!

Cada aplicación es distinta …

- **Procesamiento** puede involucrar
  - Gestión de Datos Estructurados
    - (indexación, consultas, joins, agregación)
  - Procesamiento de Lenguaje Natural
    - (búsqueda de texto, clasificación de texto, análisis de sentimiento, relevancia y similitud, etc.)
  - Minería de Datos y Aprendizaje
    - (regresión, reconocimiento de patrones, clasificación, detección de eventos, etc.)
  - Y cualquier cosa entre medio.

¿Por dónde deberíamos empezar?



Gestión de datos (masivos)

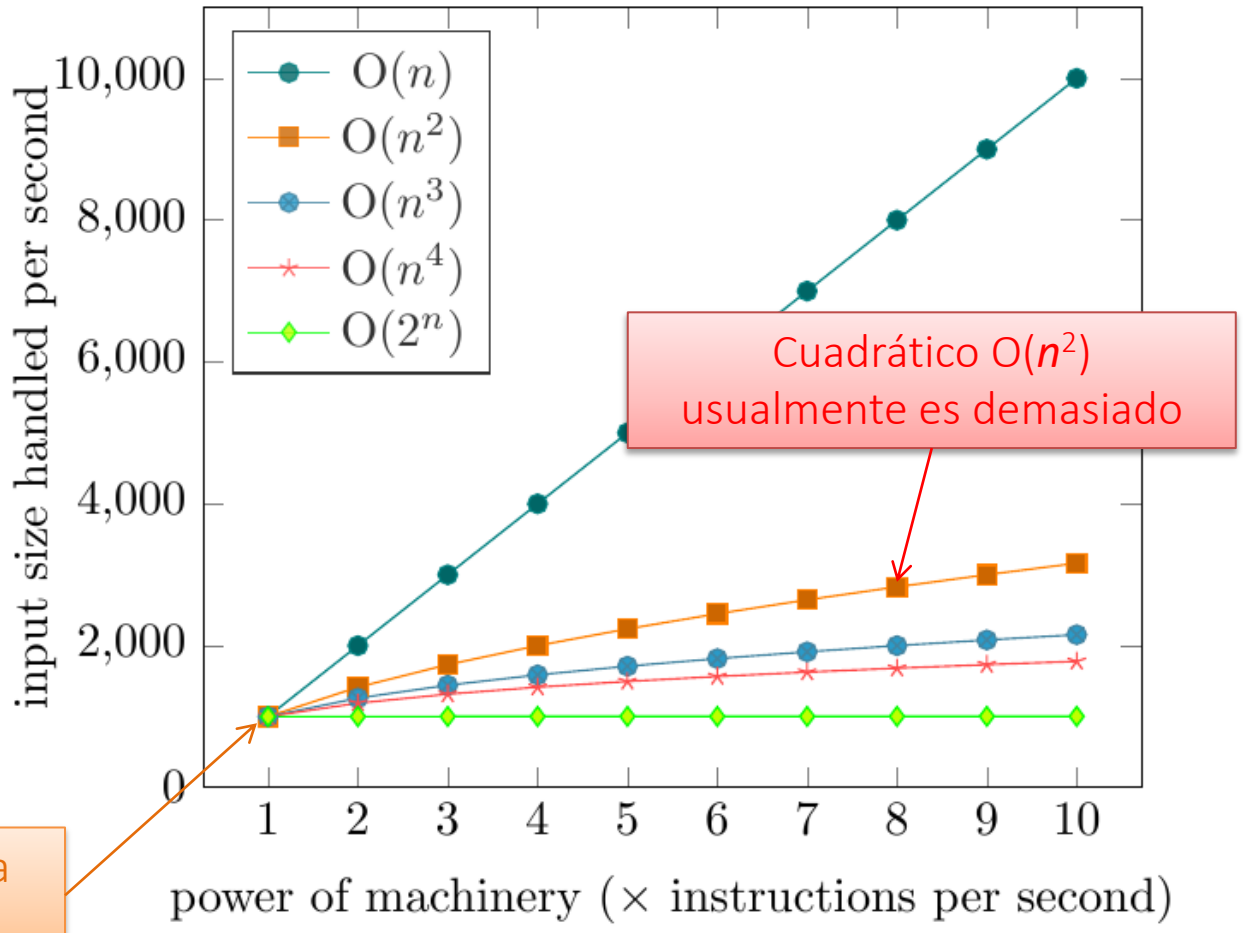
La escala es un factor importante …

Tengo un algoritmo.

Tengo una máquina que puede procesar 1.000 entradas por hora.

Si compro una máquina que es ***n*** veces más potente, ¿cuántas entradas puedo procesar?

¡Depende del algoritmo!



Cuadrático O(n^2) usualmente es demasiado

Nota: No la misma máquina!

La escala es un factor importante …

- ¿Una máquina que es *n* veces más potente?
- ¿*n* máquinas que son igualmente potentes entre ellas?

VS.





¿Cuál es mejor?

¡Depende de la aplicación!

La escala es un factor importante …

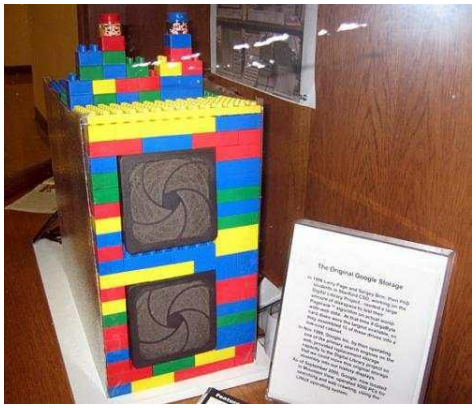
- Intensivo en los datos (nuestro foco!)
  - Algoritmos baratos / Grandes entradas
  - p.ej., Google, Facebook, Twitter
- Intensivo en computo (no es nuestro foco!)
  - Algoritmos más caros / Entradas más pequeñas
  - p.ej., simulaciones de clima, ajedrez, etc.
- No es blanco y negro

"Gestión de datos (masivos)" necesita "computación distribuida"

Computación distribuida

- Necesita más de una máquina

- Google ca. 1998:

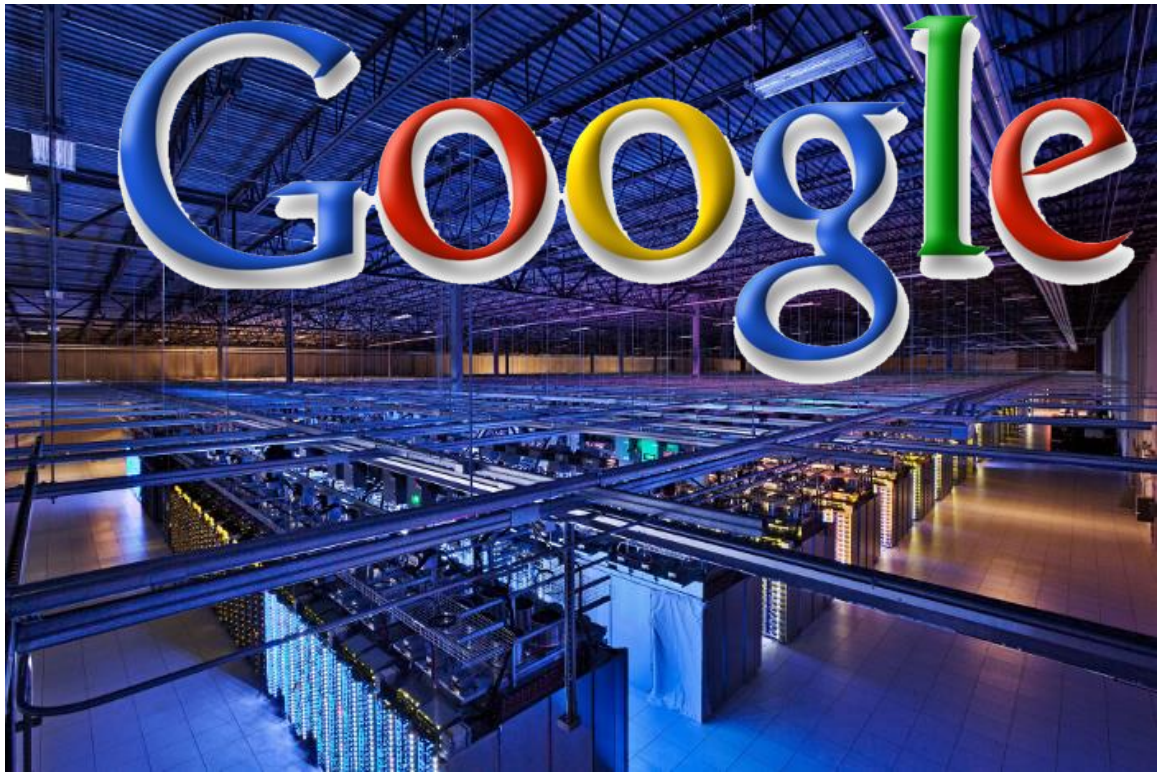




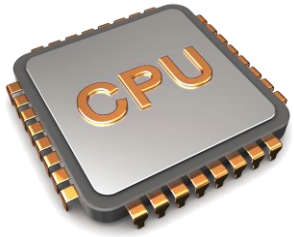
Computación distribuida

- Necesita más de una máquina

- Google ca. 2018:



Costos de transporte de los datos (estimaciones)



¡Se necesita minimizar los costos de red!
(La red da un costo adicional)
(Se reparte la red entre muchas máquinas)

(transmisión)

30 GB/s	4 GB/s	100 MB/s	6.25 GB/s	25 GB/s
Memoria Principal	Disco de Estado Sólido	Disco Duro	Red (mismo *rack*)	Red (a través de los *racks*)
5–50 ns	50–150 µs	5–15 ms	300–600 ns	1–15 µs

(latencia)

Colocación de los datos

- Hay que pensar cuidadosamente dónde poner qué datos

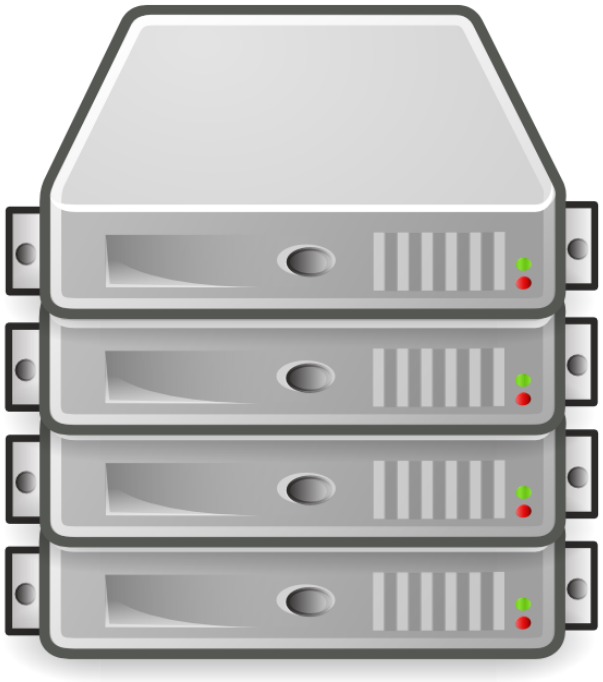
Tengo cuatro máquinas para correr mi página web. Tengo 10 millones de usuarios.

Cada usuario tiene un perfil personal, fotos, amigos y juegos.

¿Cómo debería dividir los datos en las máquinas?

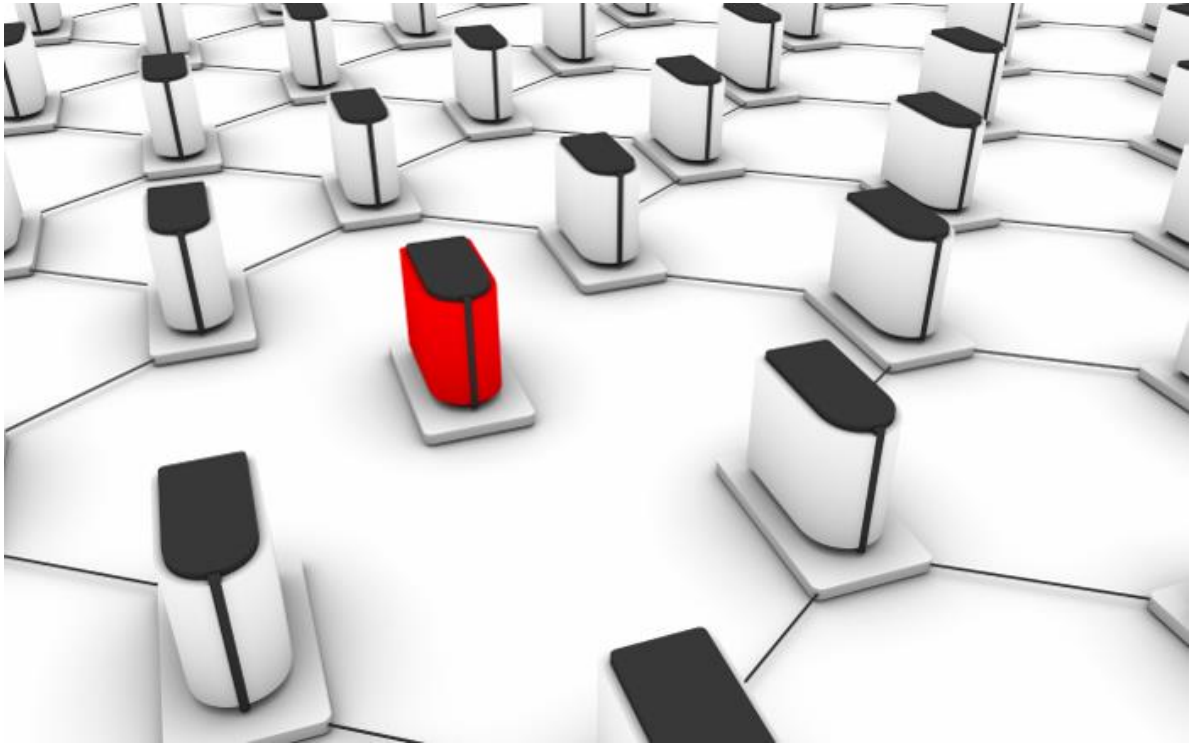
¡Depende de la aplicación!

(Pero buenos principios de diseño aplican universalmente.)



Fallas de red/nodo

- Si tenemos miles de máquinas, ¡hay que pensar en las fallas!



Colocación de los datos

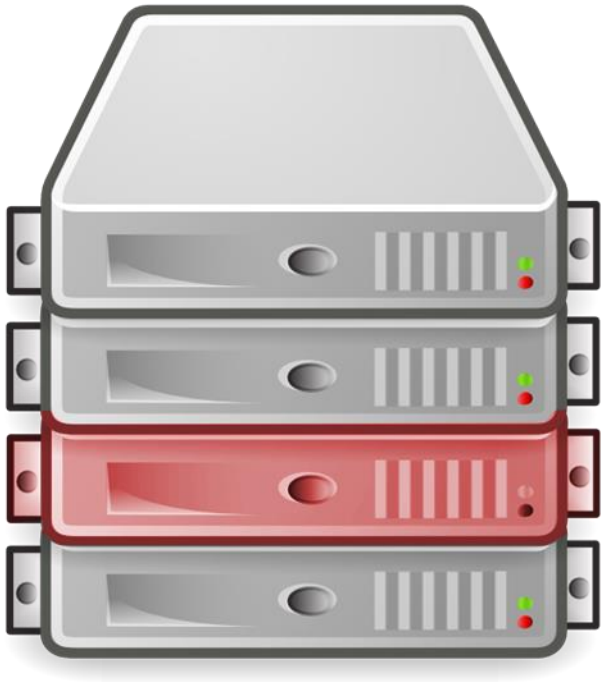
- Hay que pensar (¡aún más!) cuidadosamente dónde poner qué datos

Tengo cuatro máquinas para correr mi página web. Tengo 10 millones de usuarios.

Cada usuario tiene un perfil personal, fotos, amigos y juegos.

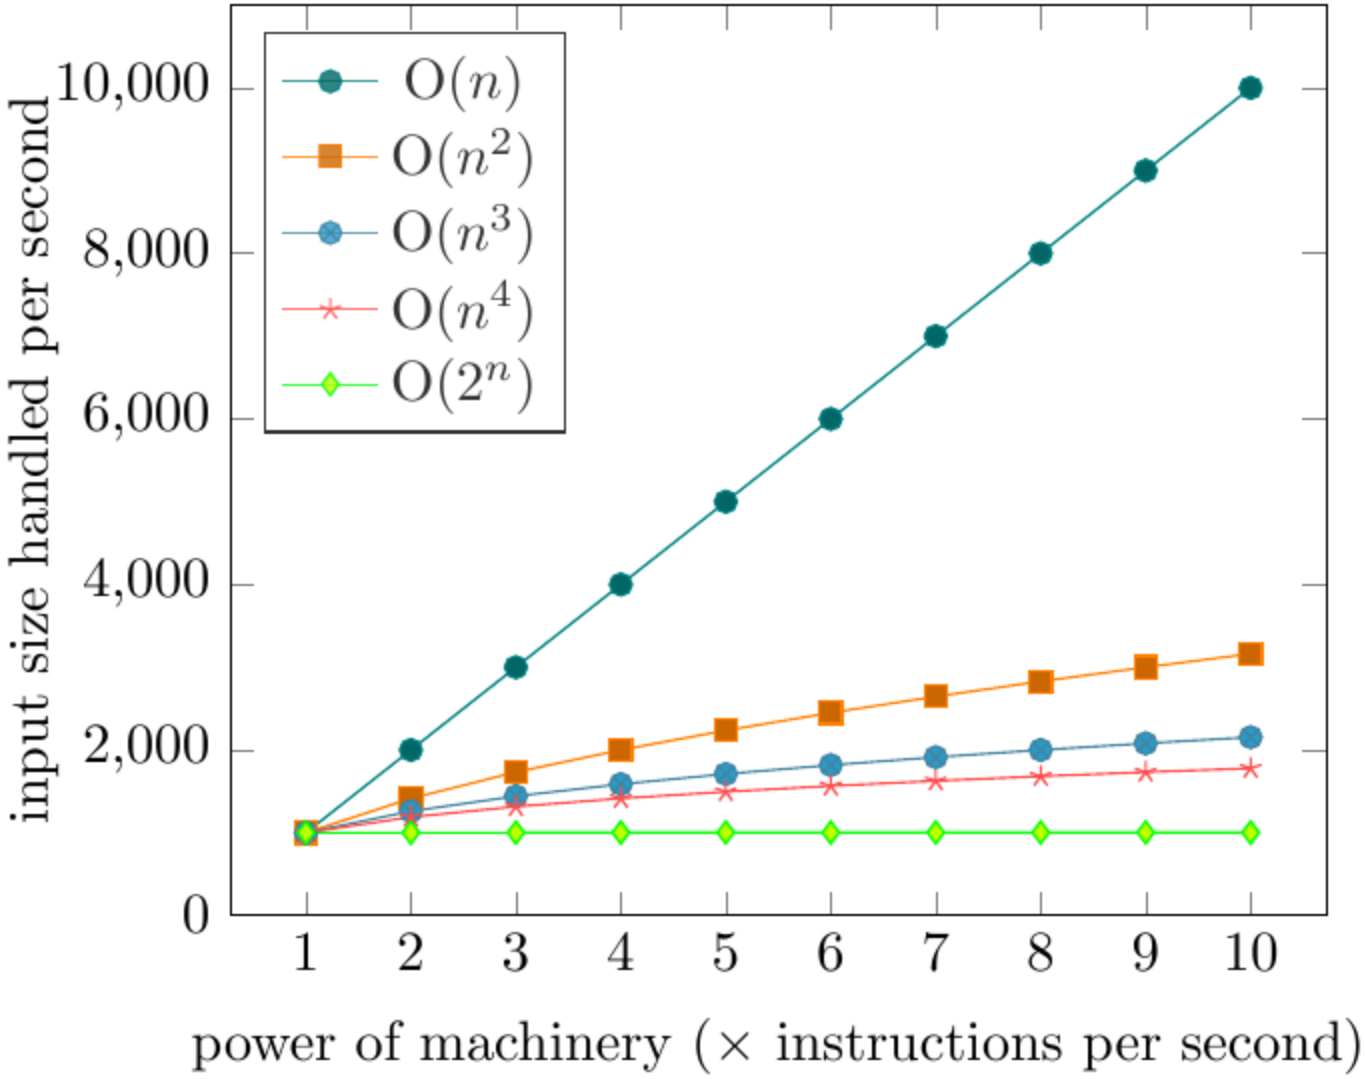
¿Cómo debería dividir los datos en las máquinas?

¡Depende de la aplicación!
(de nuevo)
(Pero buenos principios de diseño aplican universalmente.)



"Computación distribuida”
Limitaciones y desafíos ...

¡Distribución no es siempre aplicable!



Desarrollo distribuido es difícil

- Sistemas Distribuidos pueden ser complejos

- Con múltiples máquinas hay que ocuparse de:
  - Datos en diferentes localizaciones
  - Logs y mensajes en diferentes lugares
  - La eficiencia de la red
  - ¡Hay que manejar fallas!
  - ¡Hay que balancear carga!

- ¡Tareas toman mucho tiempo!
  - Bugs pueden no ser evidentes por horas
  - Muchos datos = muchos contra ejemplos

Frameworks/abstracciones pueden ayudar

Para procesamiento distribuido
(p.ej.)



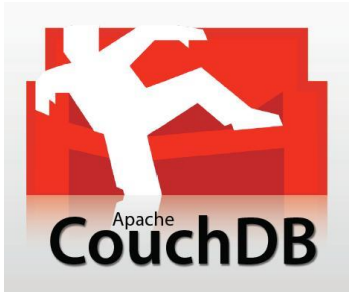




Frameworks/abstracciones pueden ayudar

Para almacenamiento distribuido
(p.ej.)









"Gestión de datos"
Acerca del curso

¿Qué es el curso/No es?

- Intensivo en datos | No intensivo en computo
- Tareas distribuidas | No crear redes
- Hardware no especializado | No supercomputadores
- Métodos generales | No algoritmos específicos
- Métodos prácticos | Con poco teoría

Estructura del curso

- Primera mitad de la sesión: Clase
- Segunda mitad de la sesión: Práctica

1.	Introducción	Java: Conteo local de palabras
2.	GFS & MapReduce	HDFS & Hadoop: Conteo de palabras
3.	Pig	Pig: Contando IMDb co-actores
4.	Spark	Spark: Analizando series de televisión
5.	Crawling & Índices Invertidos D.	Elasticsearch: Búsqueda sobre Wikipedia
6.	PageRank & Grafos	Giraph: PageRank sobre Wikipedia
7.	NoSQL I	Cassandra: Consultas e índexación
8.	NoSQL II	MongoDB: Consultas sobre series de televisión

Nota final: 100% prácticas (8 en total, 12,5% cada una)

Ciencia e Ingeniería de Datos

Ciencia de los Datos

Harvard Business Review



DATA

Data Scientist: The Sexiest Job of the 21st Century

by Thomas H. Davenport and D.J. Patil

FROM THE OCTOBER 2012 ISSUE

“Data Scientist” Ofertas de Trabajo (2016)

Here are the top 10 in-demand skills for data scientists:

Skills	Job skill appears in	% of jobs with skill
SQL	1987	56%
Hadoop	1713	49%
Python	1367	39%
Java	1287	36%
R	1120	32%
Hive	1099	31%
Mapreduce	768	22%
NoSQL	657	18%
Pig	561	16%
SAS	560	16%

http://visit.crowdflower.com/rs/416-ZBE-142/images/CrowdFlower_DataScienceReport_2016.pdf

“Data Scientist” Ofertas de Trabajo (2017)

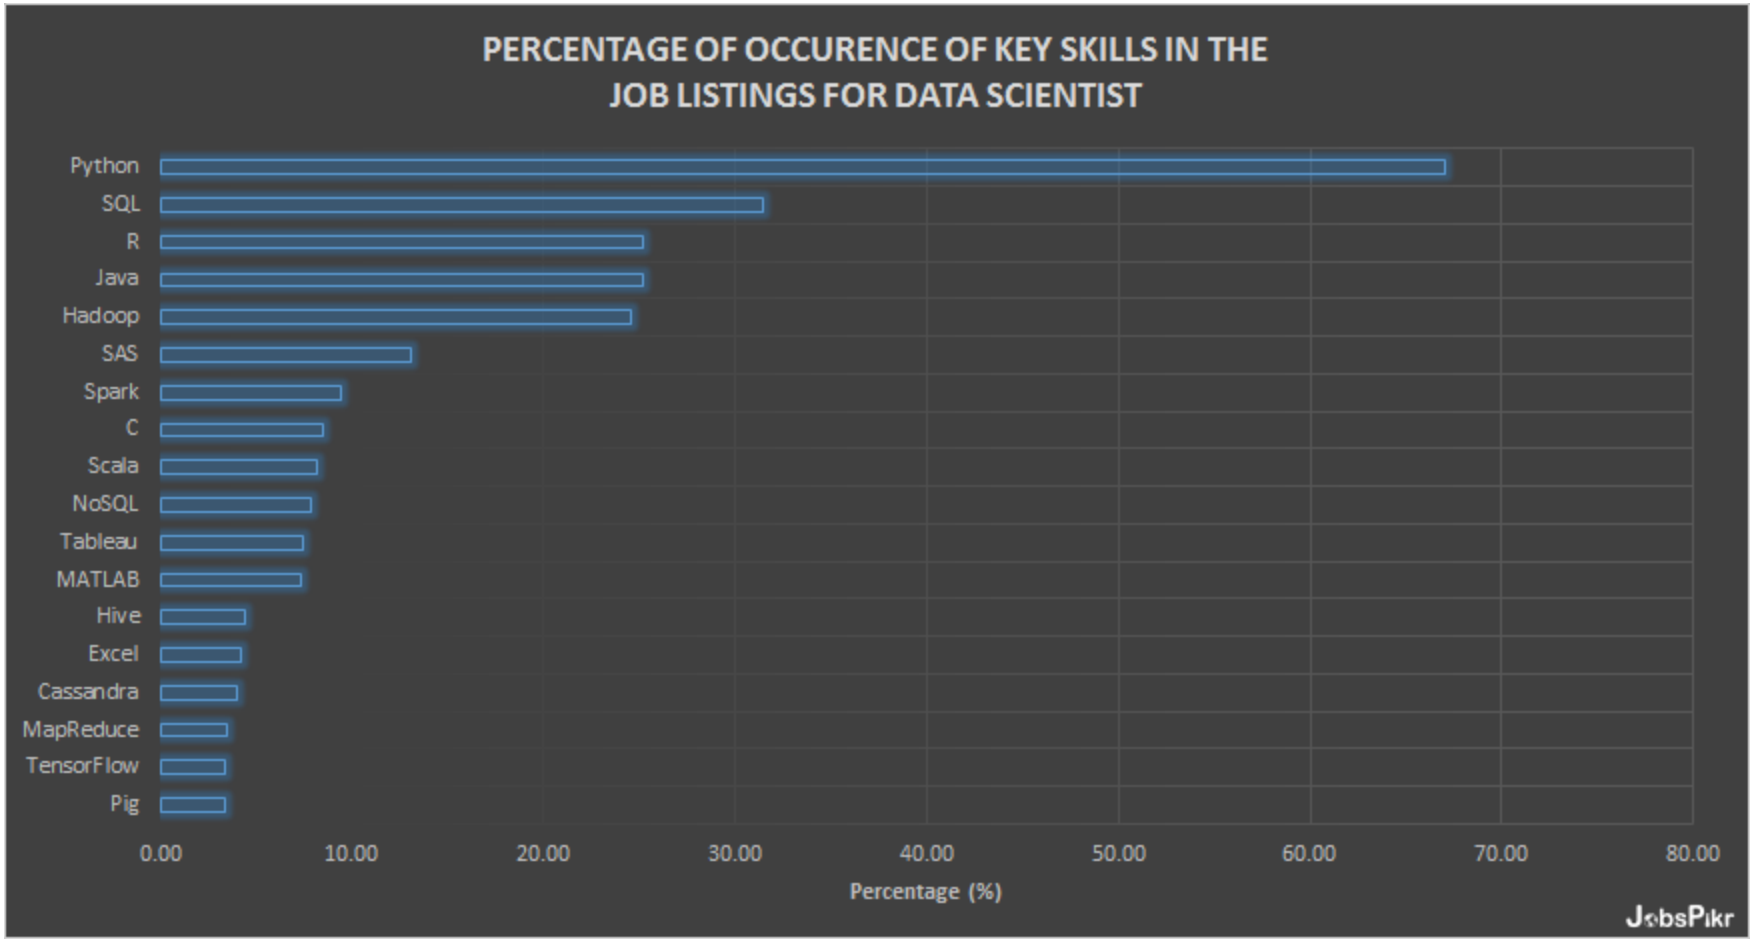
Becoming A Data Scientist: The Skills That Can Make You The Most Money

To pinpoint the most common skills, Glassdoor took 10,000 data scientist job listings that appeared on its job search platform between January and July of this year. The skills required were noted, as were the salaries offered. The data coding skills were extrapolated and analysts searched for those that came up the most within listings. The ten skills that appeared most often as prerequisites for the job, and the percentage of job listings in which they appeared, were:

1. **Python** (72%)
2. **R** (64%)
3. **SQL** (51%)
4. **Hadoop** (39%)
5. **Java** (33%)
6. **SAS** (30%)
7. **Spark** (27%)
8. **Matlab** (20%)
9. **Hive** (17%)
10. **Tableau** (14%)

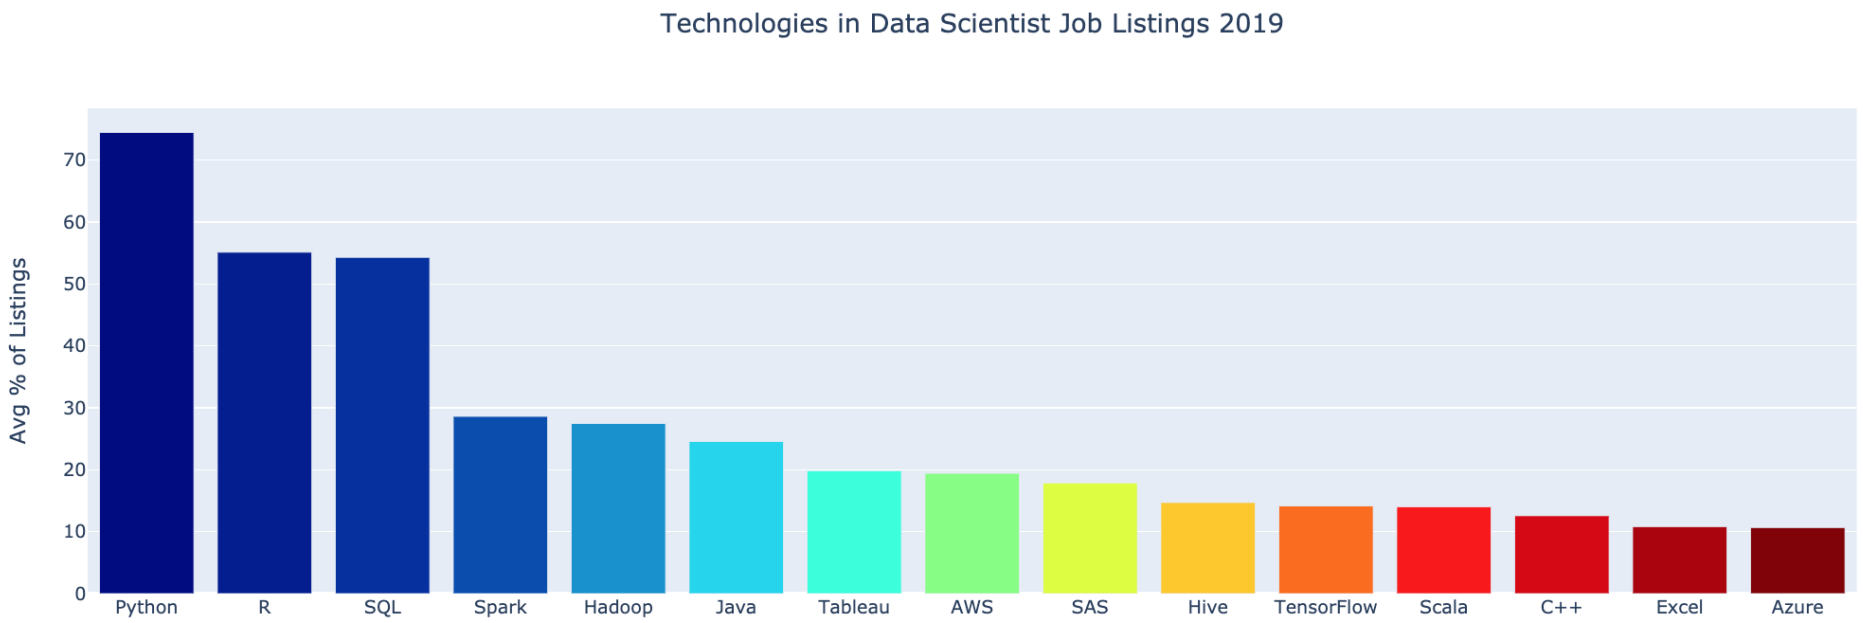
https://www.forbes.com/sites/karstenstrauss/2017/09/21/becoming-a-data-scientist-the-skills-that-can-make-you-the-most-money/

“Data Scientist” Ofertas de Trabajo (2018)



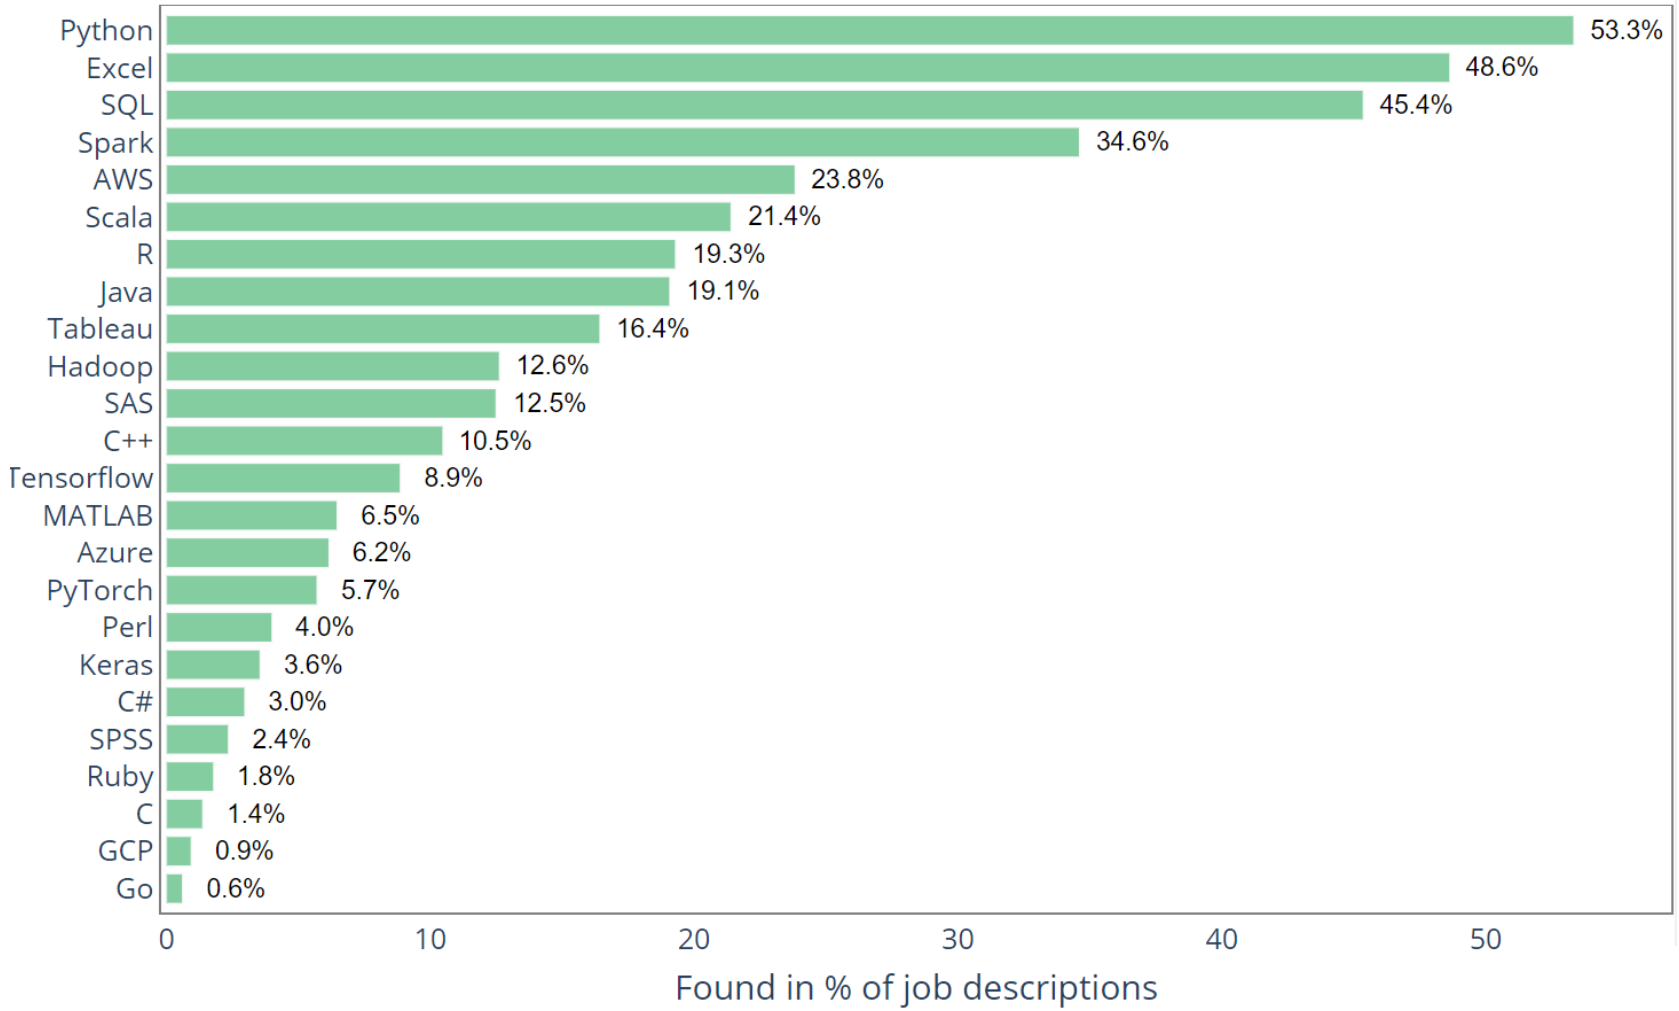
https://www.jobspikr.com/blog/job-data-analysis-reveals-top-skills-required-for-data-science-role/

“Data Scientist” Ofertas de Trabajo (2019)



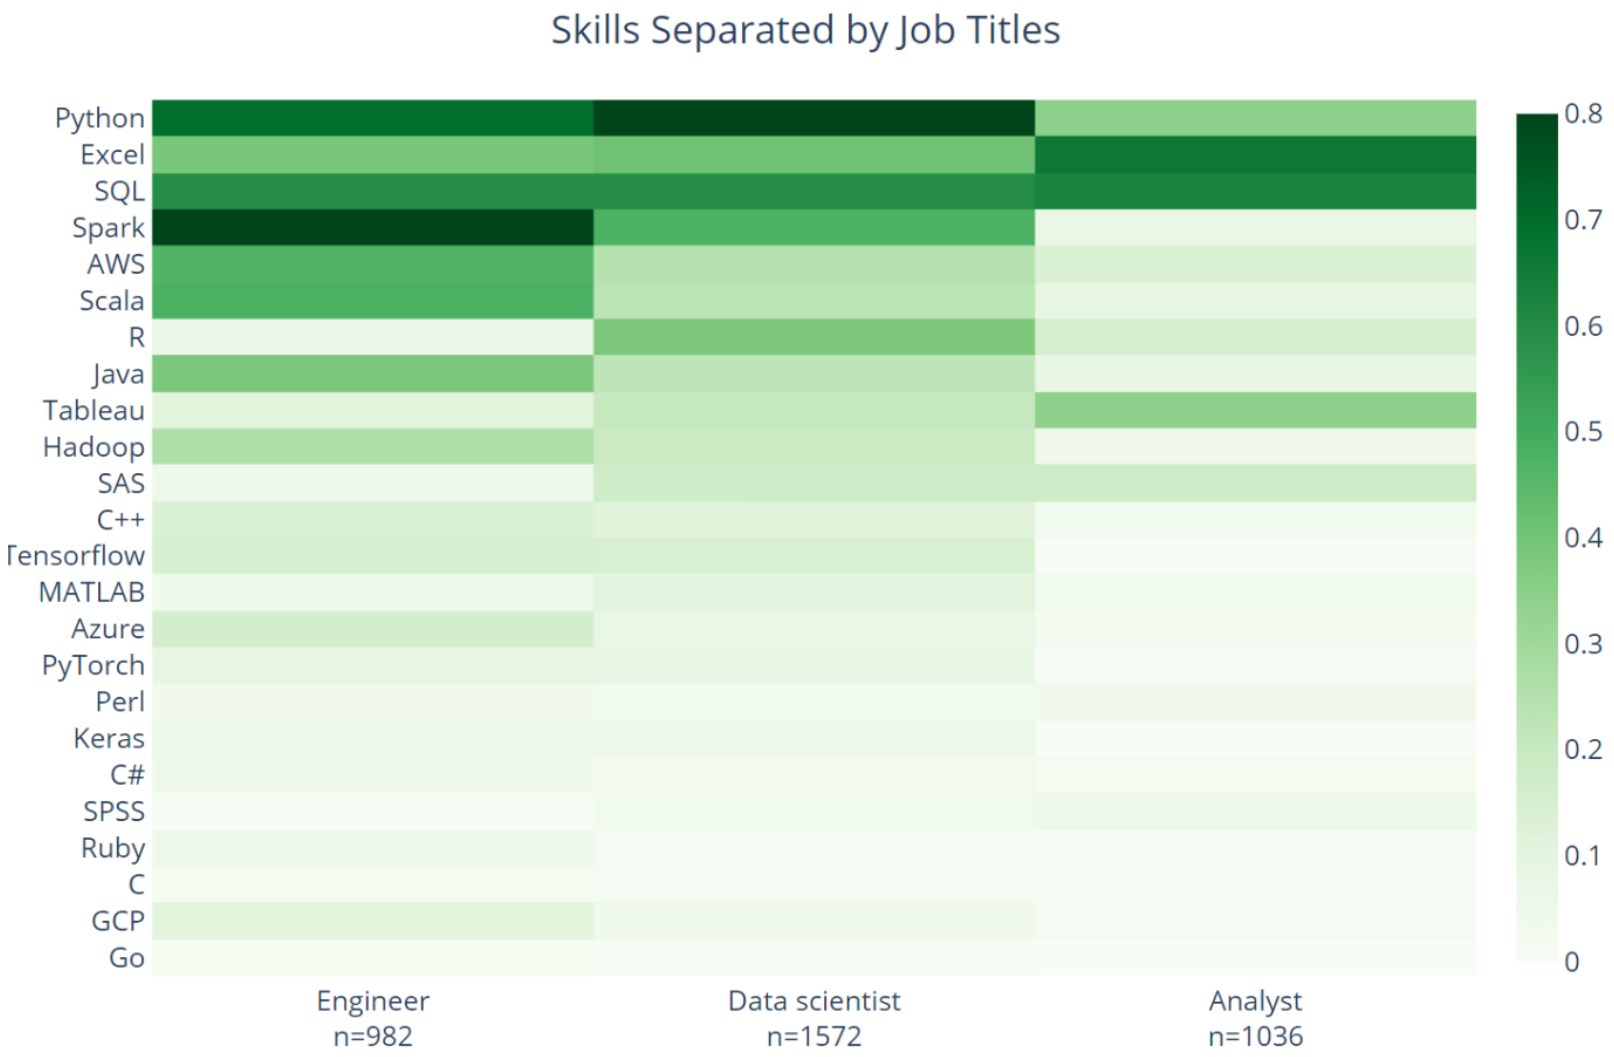
https://towardsdatascience.com/the-most-in-demand-tech-skills-for-data-scientists-d716d10c191d/

“Data Scientist” Ofertas de Trabajo (2020)



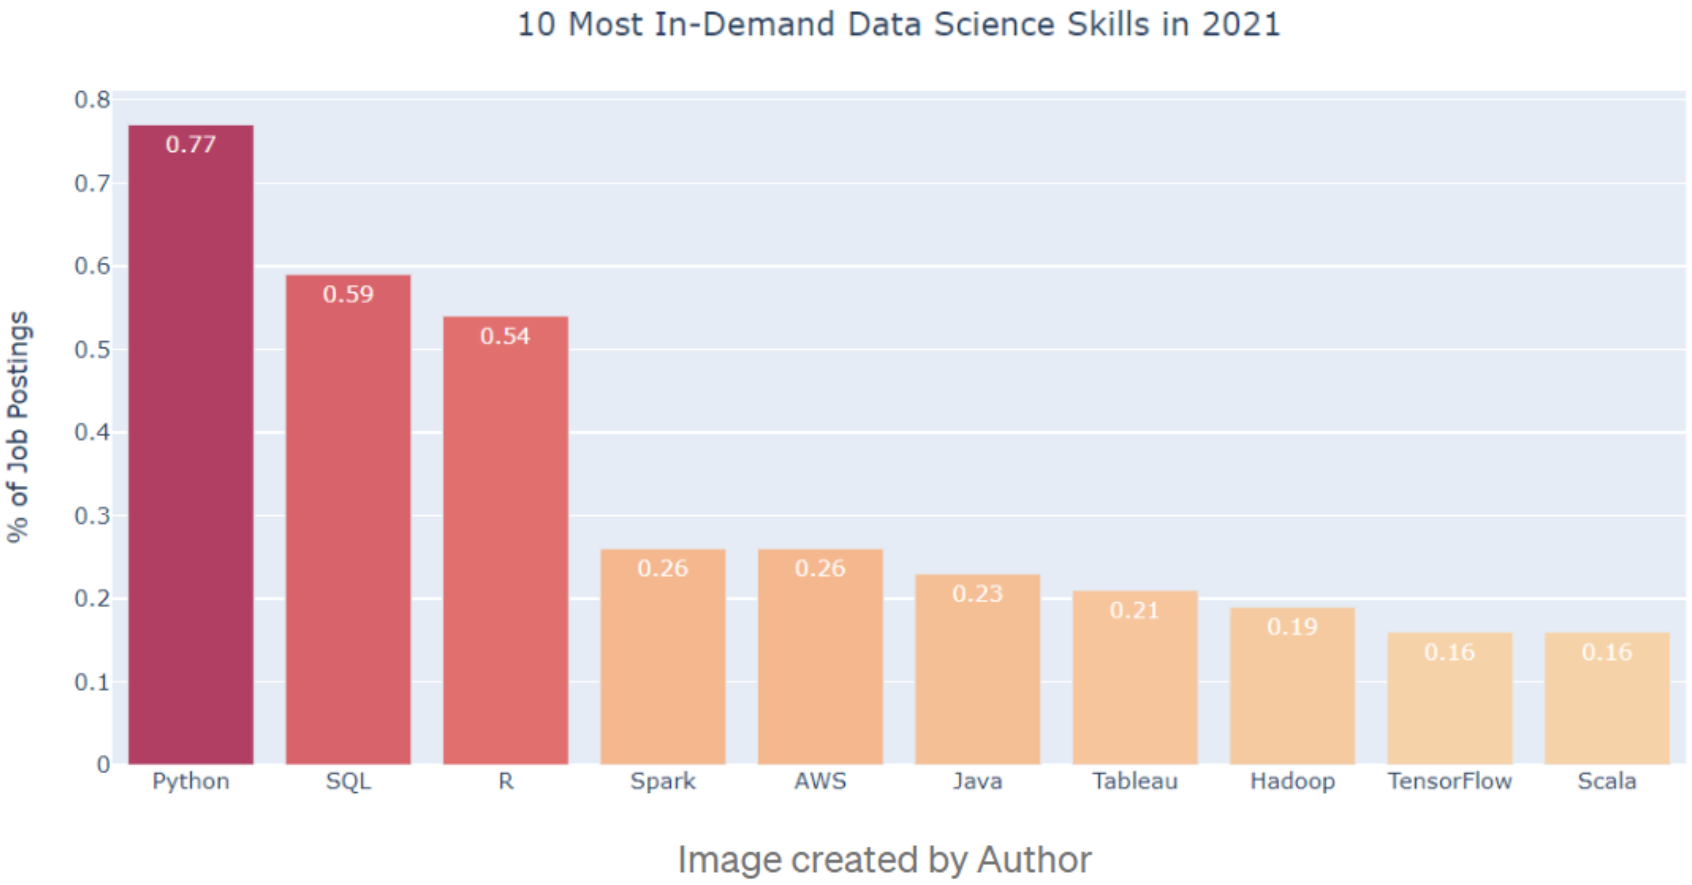
https://medium.com/@chihhsulin/5-500-data-scientist-jobs-report-2020-adefe1d364d3

“Data Scientist” Ofertas de Trabajo (2020)



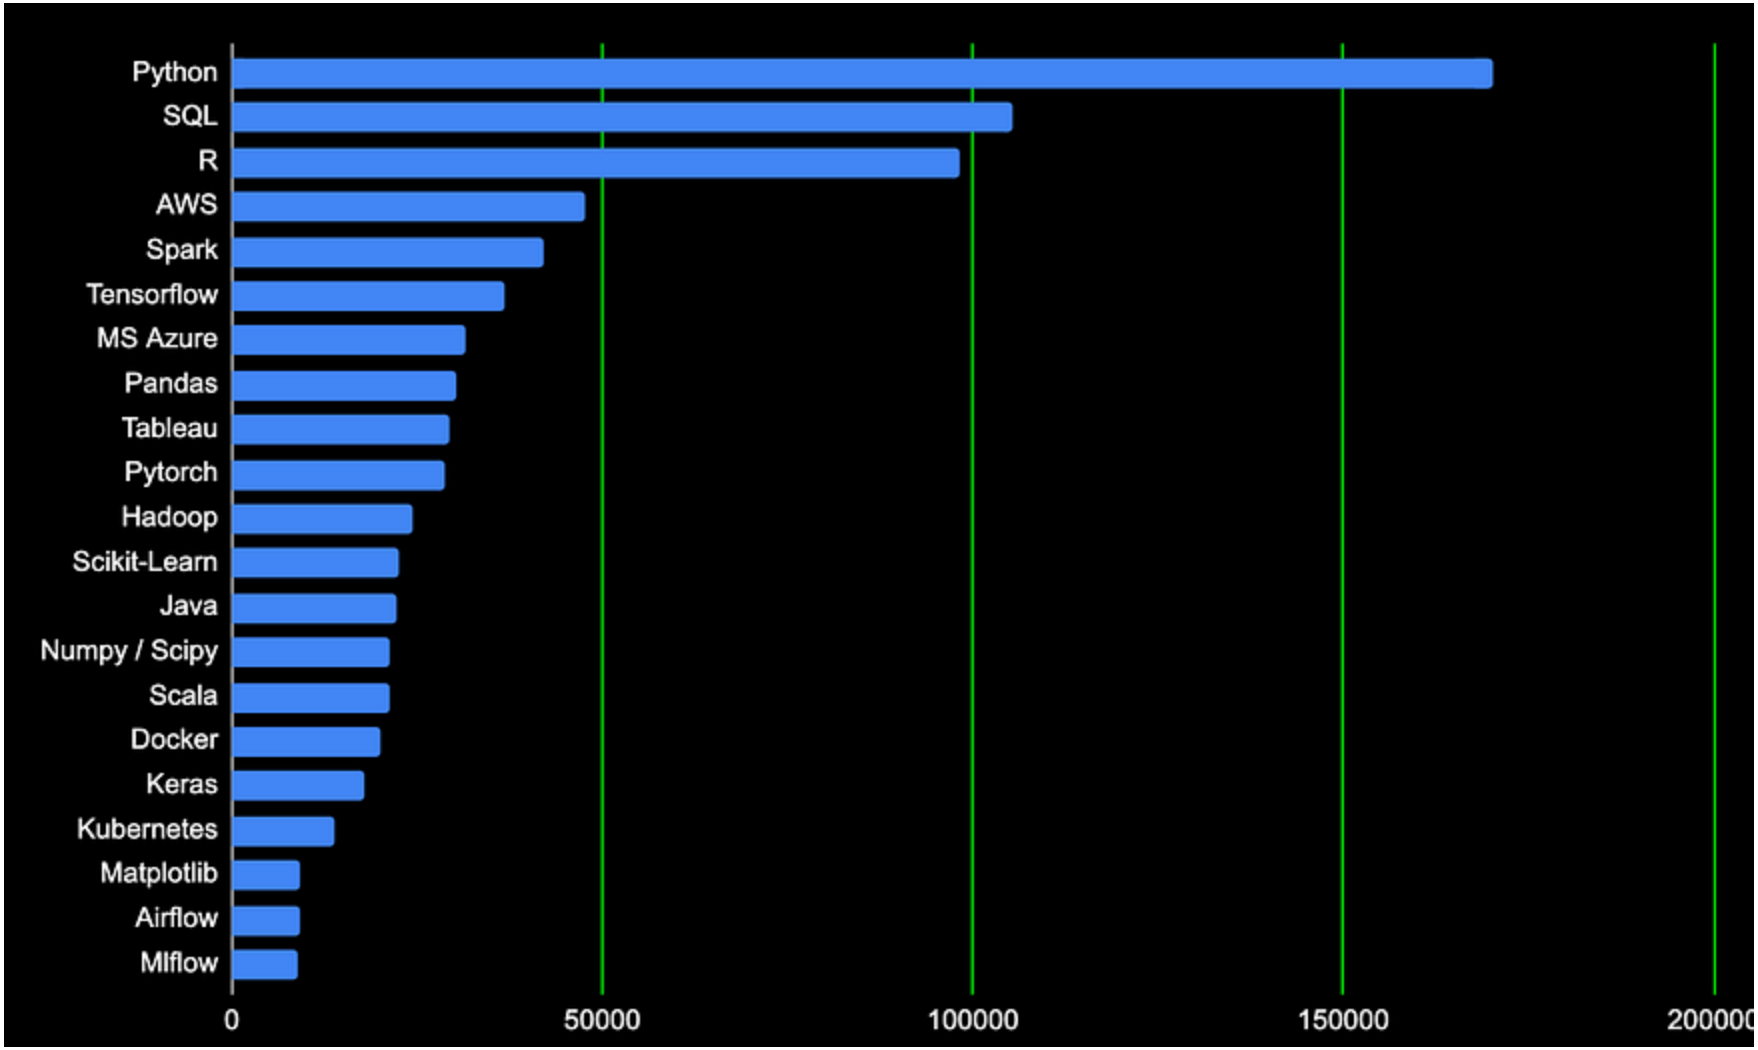
https://medium.com/@chihhsulin/5-500-data-scientist-jobs-report-2020-adefe1d364d3

“Data Scientist” Ofertas de Trabajo (2021)



https://towardsdatascience.com/the-most-in-demand-skills-for-data-scientists-in-2021-4b2a808f4005

“Data Scientist” Ofertas de Trabajo (2023)



https://odsc.medium.com/40-must-know-data-science-skills-and-frameworks-for-2023-582fef0bc3fa

“Data Scientist” Ofertas de Trabajo (2025)

27 Data Science Skills for a Successful Career in 2025

By Ronald Van Loon

Share This Article:

Last updated on Jun 9, 2025

467799

Skills Required For Data Scientists

- SQL, R, and Python for programming.
- Statistical procedures in statistical analysis.
- TensorFlow, PyTorch, Scikit-Learn, and algorithms are used in machine learning.
- Tableau, Power BI, and Matplotlib are tools for data visualization.
- Data Wrangling: Data transformation and cleaning.
- Big Data: Spark and Hadoop.
- MongoDB, PostgreSQL, and MySQL database management systems.
- Cloud computing: Google, Azure, and Amazon.
- Software for statistics: SPSS, SAS.
- Mathematics: Calculus, probability, and linear algebra.
- Info extraction is known as data mining.
- NLP: Analysis of textual data.
- Neural networks in deep learning.
- Time series analysis is the study of data that varies with time.
- Git is used for version control.
- Handling commercial issues with a sense of understanding.
- Solving problems requires analytical thought.
- Communication: Outlining research results.
- Managing projects is called project management.
- Ethics: ethics, data privacy.
- Cooperation: Group effort.
- Remaining current through ongoing learning.

https://www.simplilearn.com/what-skills-do-i-need-to-become-a-data-scientist-article

Descargar datos



http://aidanhogan.com/teaching/data/wiki/es/es-wiki-abstracts.txt.gz



Preguntas?

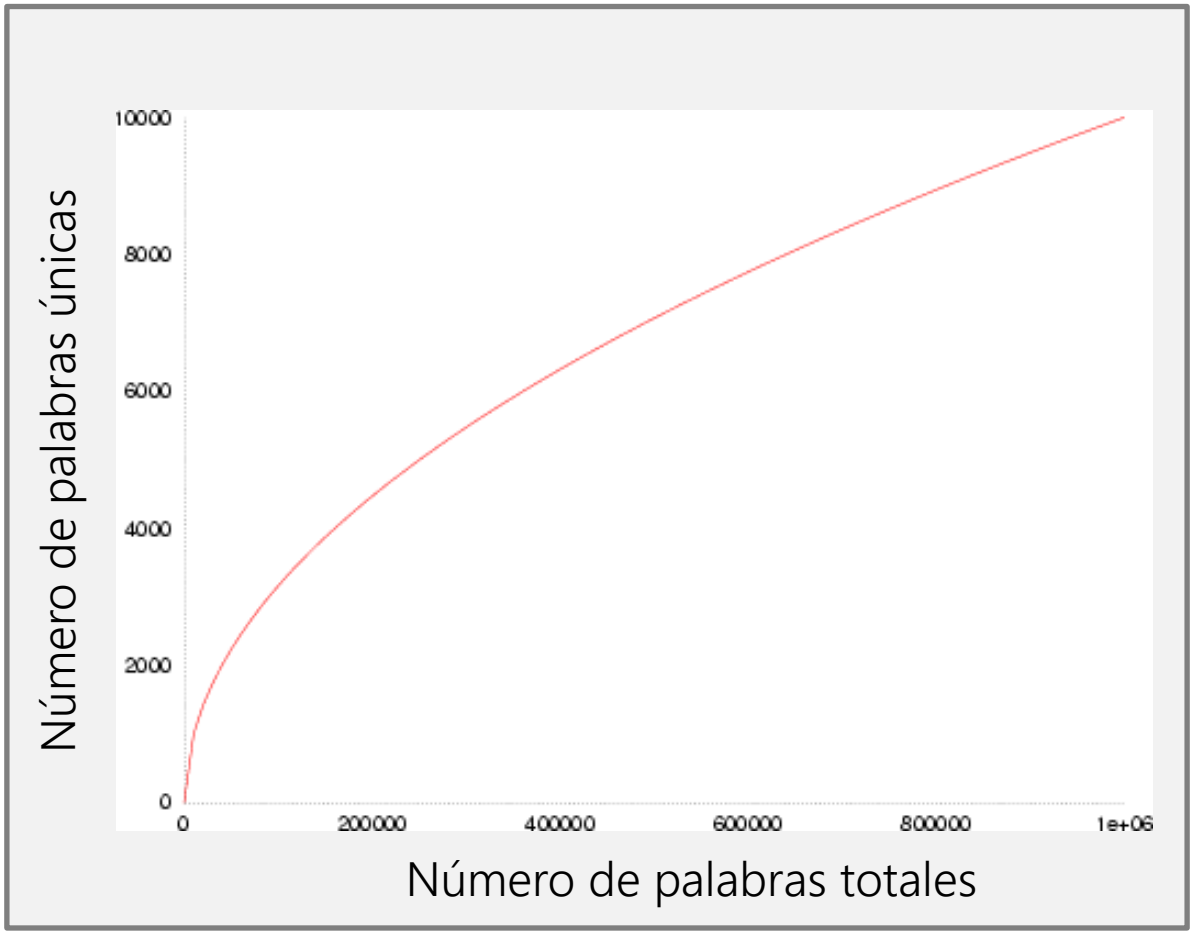
Lab

¿Por qué funcionó?

Procesamos muchos datos. ¿Por qué funcionó en memoria?

No hay tantas palabras únicas …

- Ley de Heap:

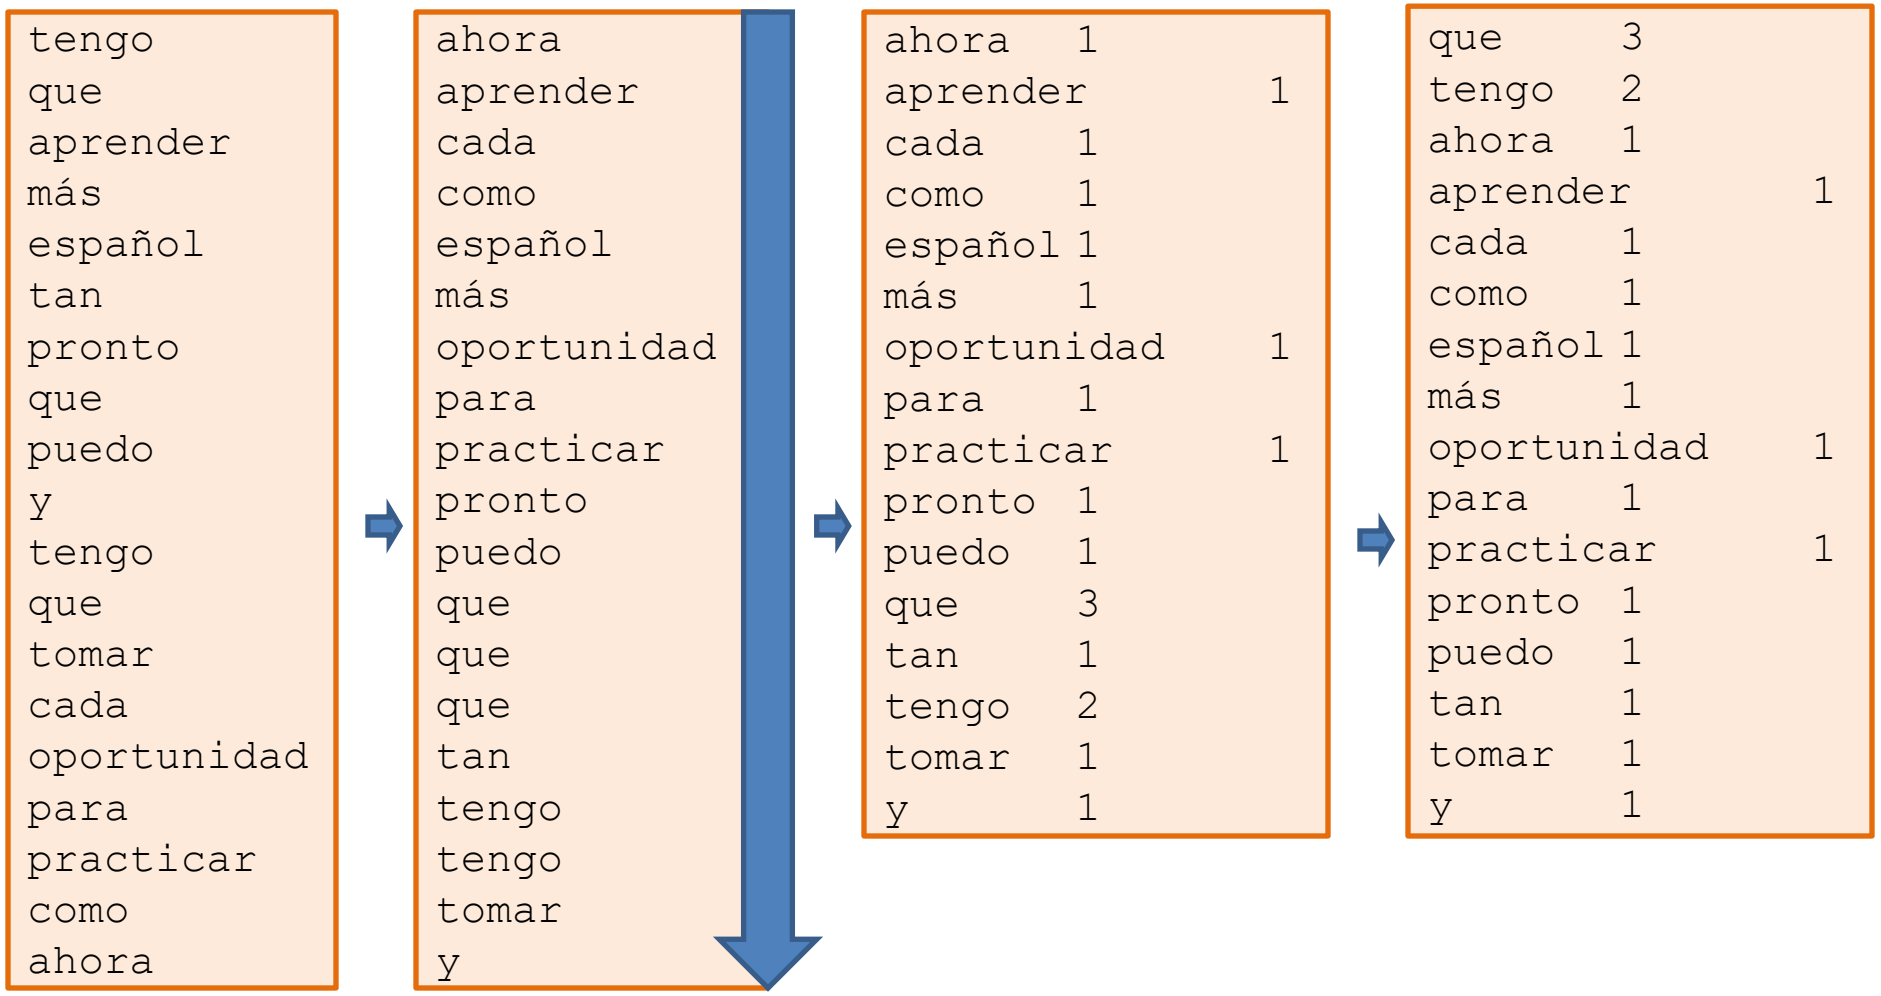


¿Y si no funciona?

Y ¿si no funciona en memoria?



Ordenar los datos



¿Cómo podemos usar el disco para ordenar los datos?

Ordenamiento Externo 1: Lotes

- Ordenar los datos en lotes

Entrada (disco)
(Tamaño: *n*)

es que
de la
por qué
de la

ha sido
no hay
de la
y de

ha sido
de la
así es
ha sido

Ordenar (en memoria)
(Lote: *b*)



Salida intermedia (disco)
(⌈*n*/*b*⌉ lotes)

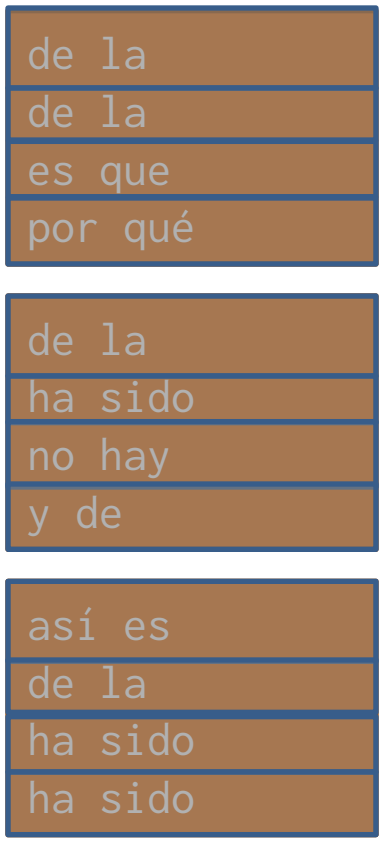
de la
de la
es que
por qué

de la
ha sido
no hay
y de

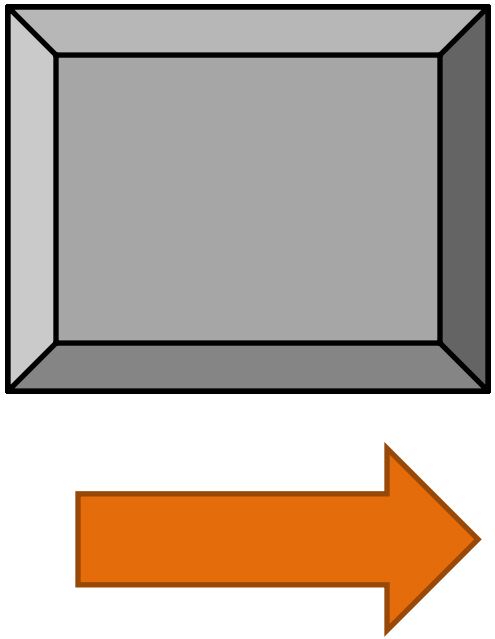
así es
de la
ha sido
ha sido

Ordenamiento Externo 2: Combinar (*Merge*)

Salida intermedia (disco)
(⌈*n*/*b*⌉ lotes



Ordenar (en memoria)
(Espacio: ⌈*n*/*b*⌉)

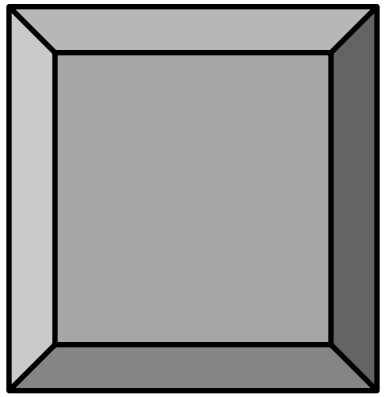


Salida final (disco)
(Tamaño: *n*)

así es
de la
de la
de la
de la
es que
ha sido
ha sido
ha sido
no hay
por qué
y de

Contar

```
así es
de la
de la
de la
de la
es que
ha sido
ha sido
ha sido
no hay
por qué
y de
```



Podríamos ordenar de nuevo, esta vez por frecuencia, usando el mismo método

```
así es,    1
de la,     4
es que,    1
ha sido,   3
no hay,    1
por qué,   1
y de,      1
```

¿Escalar más?

