

Lab 3 – Contando las estrellas con Pig

Big Data

23 de julio de 2026

¡Ya no se contarán más palabras! Hoy contaremos estrellas.

Más específicamente, contaremos co-estrellas de películas listadas en IMDb.¹ Tu misión ... si decides aceptarla ... es crear un Pig script que cuente las parejas de actores o actrices que han protagonizado más películas juntos. El objetivo de este laboratorio es ver cómo crear un “job” (tarea) MapReduce más complejo usando un lenguaje de más alto nivel, en este caso Pig Latin.

- Las instrucciones para iniciar sesión en el servidor, para acceder y subir archivos a HDFS, etc. se encuentran disponibles en las instrucciones del laboratorio 2.
- Los datos que necesitas están en HDFS en la carpeta `/uhadoop/shared/imdb/`. El archivo con los datos completos `imdb-stars.tsv` pesa alrededor de 2.3GB y contiene 35 millones de roles interpretados por diferentes actores en IMDb (prácticamente la base de datos completa). Échale una mirada al comienzo del archivo².
- El encabezado (no incluido en el archivo) se ve como sigue:

Star Name	Movie Name	Year	Movie Type	Starring As	Gender
...	...	...	...	...	...

Las columnas están delimitadas por tabs. Algunos valores pueden no aplicar y ser `null`.

Star Name es el nombre de la estrella (actor/actriz).

Movie Name es el nombre de la película, serie de televisión, etc., donde aparece la estrella.

Year es ... bueno, el año en que la película fue estrenada.

Movie Type es el tipo de película ... si es una película teatral (de cine), de televisión, una serie, etc.

Starring As una lista de personajes interpretados.

Gender es el género del actor/actriz.

Nos concentraremos, principalmente, en las primeras cinco columnas. El campo **Star Name** es único para cada persona. **Sin embargo, para las películas, Movie Name no es único ... Solo la combinación de Movie Name y Year es suficiente para identificar únicamente a una.** Para crear una llave única para una película necesitarás concatenar los valores de estas dos columnas. Ahora para buscar información de un determinado actor: escribe (por ejemplo)
`hdfs dfs -cat /uhadoop/shared/imdb/imdb-stars.tsv | grep -e "^Al Pacino" | more`
recorre algunos resultados con `[Espaciadora]`, y presiona `[Ctrl+C]` para terminar. Cada línea representa la participación en una película, una serie de televisión, etc.

¹La base de datos de películas en Internet ... <http://imdb.com/> ... estoy seguro de que muchos de ustedes la conocen.

²`hdfs dfs -cat [FILEPATH] | more` presionando `[Espaciadora]` para escanear, `[Ctrl+C]` para terminar.

- Para facilitar el desarrollo del script, hemos proporcionado un archivo pequeño. Deberías revisarlo en HDFS aquí: `hdfs dfs -cat /uhadoop/shared/imdb/imdb-stars-test.tsv`. También hemos proporcionado un ejemplo de un script de Pig para contar cuántas películas cada actor ha protagonizado. Descarga el script del proyecto de Material Docente `gdd-lab03.zip` y ábrelo. Allí encontrarás un archivo llamado `star-count.pig`; ábrelo en el editor de texto de tu elección.
- Usaremos el shell de Pig para correr el script `star-count.pig` interactivamente, línea por línea, sobre los datos pequeños. Abre el shell en el servidor con `pig -x local`. El argumento `-x local` dice que vamos a abrir una instancia local (en una máquina) de Pig; dado que estamos trabajando con datos muy pequeños, será más rápido porque no necesitamos ni usaremos la red, pero si intentamos trabajar con datos grandes en este modo, Pig fallará. Es **muy importante** no usar `pig -x local` sobre datos grandes. Podemos usar `pig` para abrir una sesión distribuida, o mejor llamar a un script de Pig (veremos eso luego).
- Copiar, pegar y ejecutar el primer comando del script `star-count.pig` (el cual define la relación `raw`) en el shell local de Pig (se pueden ignorar las líneas que empiecen con `--` pues son comentarios). En Pig se ejecutan los comandos de forma perezosa; es decir que ha guardado el comando, pero no va a ejecutarlo hasta que sea necesario, por ejemplo para ver o guardar la salida. Intentas ahora con el comando `DESCRIBE raw`; el cual entrega una descripción del esquema de la relación. No definimos los tipos de las columnas así que por defecto cada columna es del tipo `bytearray` (si quieres, puedes definir los tipos usando los ejemplos de la clase). Intentas ahora con el comando `DUMP raw`; el cual muestra los datos de la relación. Ahora Pig tiene que ejecutar el comando original para poder desplegar el contenido de la relación, y verás varios mensajes de esa ejecución antes de ver los datos. Deberías seguir con este proceso para el segundo comando, etc., hasta llegar al comando final. En el comando final, deberías usar una carpeta personal de la forma `/uhadoop2026/cc66i/[USUARIO]/imdb-stars-test/`; el comando escribirá los datos de la última relación a HDFS. Puedes salir del shell con `quit`. Revisa la salida en la carpeta de HDFS.
- Ahora ejecutaremos el script sobre los datos completos. Cambia la entrada en la primera línea para apuntar al archivo `imdb-stars.tsv` y cambia la última línea para guardar los resultados en la carpeta `/uhadoop2026/cc66i/[USUARIO]/imdb-stars/`. Usa SCP para copiar el script a tu carpeta local en el servidor `/data/2026/uhadoop/cc66i/[USUARIO]`. Desde la misma carpeta en SSH, llama al comando `pig star-count.pig`. Puede demorar un poco, así que puedes dejarlo correr, seguir con el lab, y regresar para revisar los resultados luego. Si varios grupos llaman al script al mismo tiempo, puede generar una cola en Hadoop. En el enunciado previo de MapReduce, explica cómo revisar la cola (algo que puedes hacer en otra sesión SSH/terminal; el comando es `mapred job -list`).
- Hemos visto como ejecutar un ejemplo interactivamente, y usando un script. Ahora deberías adaptar el script para contar cuántas películas los *pares* de actores han protagonizado juntos. Solo queremos considerar películas, es decir, solo debes considerar líneas del archivo donde `Movie Type` sea igual a `movie`; si es algo más, saltatela. No incluyas las parejas con cero películas en común, ni las parejas reflexivas ((a, a)), ni las parejas simétricas (si hay (a, b) , no incluyas (b, a)). Los pares finales deberían ser ordenados (descendente) por el conteo de películas en la salida.
- Nuestra sugerencia sería copiar el script `star-count.pig` a otro archivo `costar-count.pig`, **cambiar el primer comando para cargar el ejemplo `imdb-stars-test.tsv` de nuevo**, y adaptar el script línea por línea en el shell local (`pig -x local`); de esta forma van a poder desarrollar y probar cada comando individualmente, revisando el esquema y los datos de cada relación. Es una buena idea editar los comandos en un editor de texto local en tu notebook, y copiar los comandos al shell de Pig; de esa forma, tendrás el script listo, y no perderás trabajo en caso de haber un problema con el shell. De nuevo, por favor, **no cargues** datos grandes en el shell local de Pig.
- En el desarrollo del script, puedes usar las diapositivas de la clase de Pig y la documentación de Pig: <http://pig.apache.org/docs/r0.17.0/basic.html>. Esta hoja de referencia de Pig también puede ser útil: <https://www.qubole.com/wp-content/uploads/2014/01/Pig-Cheat-Sheet.pdf>.

- Cuando los comandos estén funcionando bien para el ejemplo, preparar el script para leer los datos completos de `imdb-stars.tsv` en HDFS, con la salida `/uhadoop2026/cc66i/USUARIO/imdb-costars/`. Después tienes que copiar el script a tu carpeta local en el servidor de nuevo. Como esto tomará un tiempo en correr deberías ejecutarlo en una **screen**. Una **screen** es una terminal de sesión virtual que permanecerá activa aún cuando hayas cerrado la sesión desde tu notebook:
 - Escribe **screen** en tu sesión SSH. Aparecerá una terminal en blanco. Ejecuta normalmente tu script en esa terminal.
 - Si quieres regresar a la terminal principal presiona `Ctrl+A`, y luego `D` (mantén apretado `Ctrl` mientras presionas `A`, suelta ambos, y luego presiona `D`). Tu terminal virtual se seguirá ejecutando en el fondo (correrá en background), y se mantendrá aún cuando cierres sesión. Asegúrate de tomar nota del número `NUM` que aparecerá en el mensaje: `[detached from NUM.pts-3.cluster-01]`. Anótalo! Este corresponde a tu screen. Existen muchas como ella, pero esta es tuya. Necesitarás el número para poder encontrarla después.
 - Si, desde la terminal principal, quieres volver a la virtual, escribe **screen -d -r NUM**.
 - Si ya no quieres ocupar la screen virtual, estando en ella, puedes matarla presionando `Ctrl+D`, pero ten en cuenta que esto también terminará todo lo que esta estaba ejecutando. Obviamente no mates las screens de otras personas; eso sería muy descortés.
- Es poco probable que obtengas resultados con el archivo grande para el final del laboratorio, pero puedes revisarlo, por ejemplo, la próxima clase. ¿Qué pares de estrellas aparecieron en mayor cantidad de películas? ¿Cuántas películas protagonizó Robert De Niro junto a Al Pacino? ¿Quién protagonizó más películas junto a Uma Thurman? Para responder a estas preguntas puedes intentar usar **grep** u otra herramienta sobre la salida. ¿Cuántas tareas de MapReduce se necesitan para ejecutar el script?
- ENTREGA tu script a U-Cursos con los top-10 resultados finales como un comentario (“--” antes de cada línea) al inicio del script, e incluir otro par de actores que te gusta (a tu elección).
- OPCIONAL: Implementa el mismo análisis en Hadoop/Java.