Big Data

Diplomado de Datos 2026

Clase 6: Recuperación de Información a gran escala (II)

Alberto Moya
albertomoya87@gmail.com

Manejando datos de texto



Con Elasticsearch

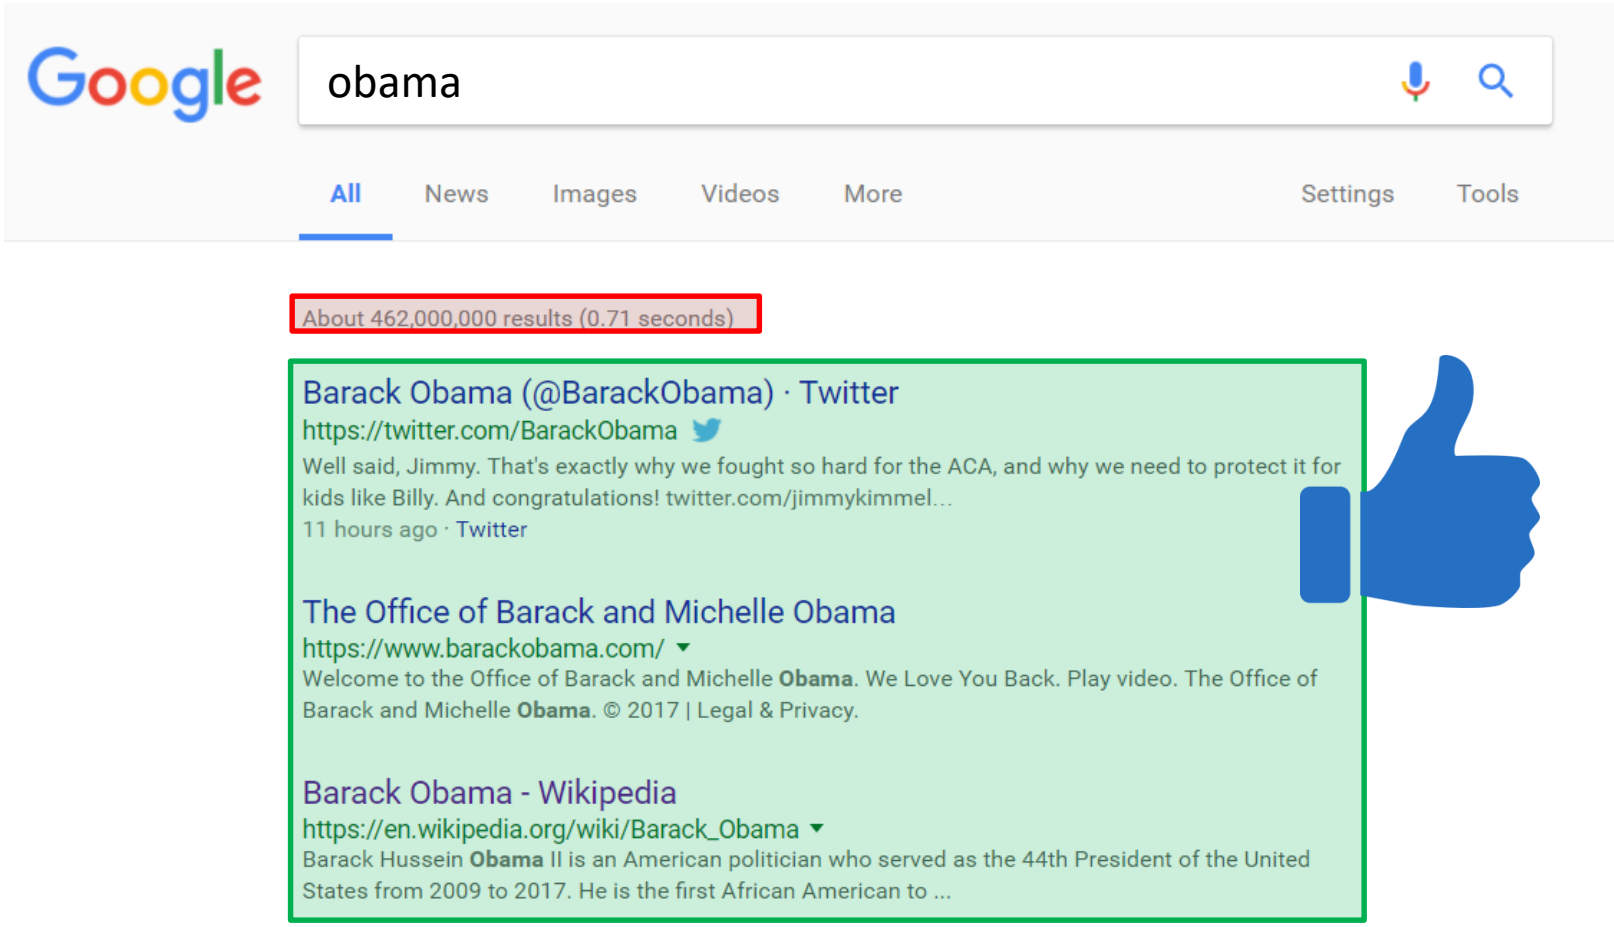
Búsqueda: “obama”

Resultados:

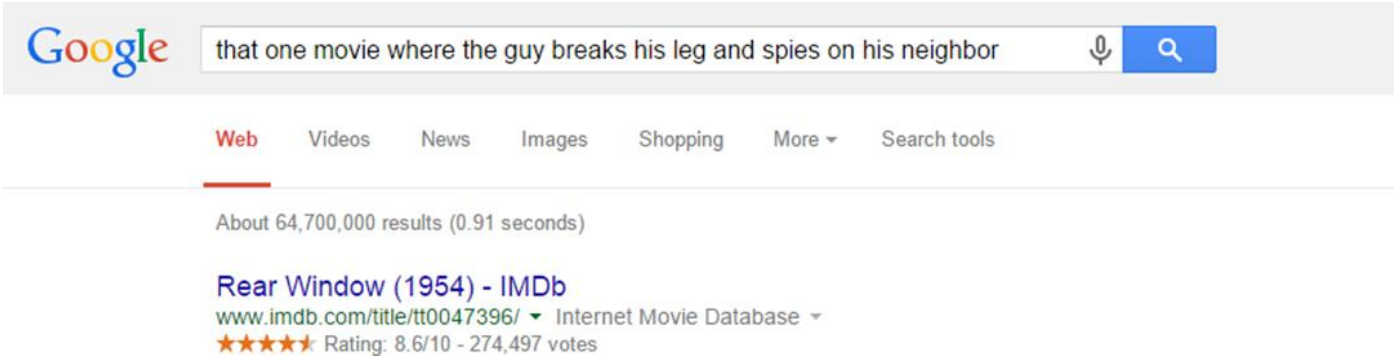
1. http://es.wikipedia.org/wiki/Obama_Republican
2. http://es.wikipedia.org/wiki/Obama_(Fukui)
3. http://es.wikipedia.org/wiki/Michelle_Obama
4. http://es.wikipedia.org/wiki/Barack_Obama
5. http://es.wikipedia.org/wiki/Republicanos_por_Obama
6. http://es.wikipedia.org/wiki/Cartel_%22Hope%22_de_Obama Cartel
7. http://es.wikipedia.org/wiki/Ricardo_Mangue_Obama_Nfubea
8. http://es.wikipedia.org/wiki/Transición_presidencial_de_Barack_Obama
9. http://es.wikipedia.org/wiki/Primera_investidura_presidencial_de_Barack_Obama
10. http://es.wikipedia.org/wiki/Campaña_presidencial_de_Barack_Obama_de_2008



¿Cómo Google obtiene tan buenos resultados?

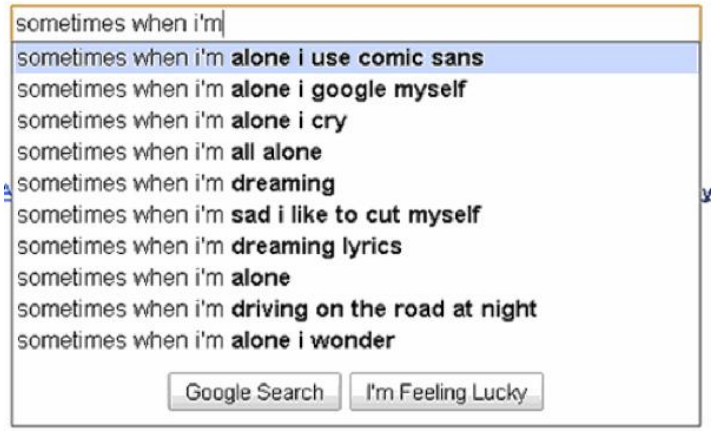


¿Cómo Google obtiene tan buenos resultados?









Las dos caras del ranking: Relevancia



Las dos caras del ranking: Importancia



Ranking:
Relevancia

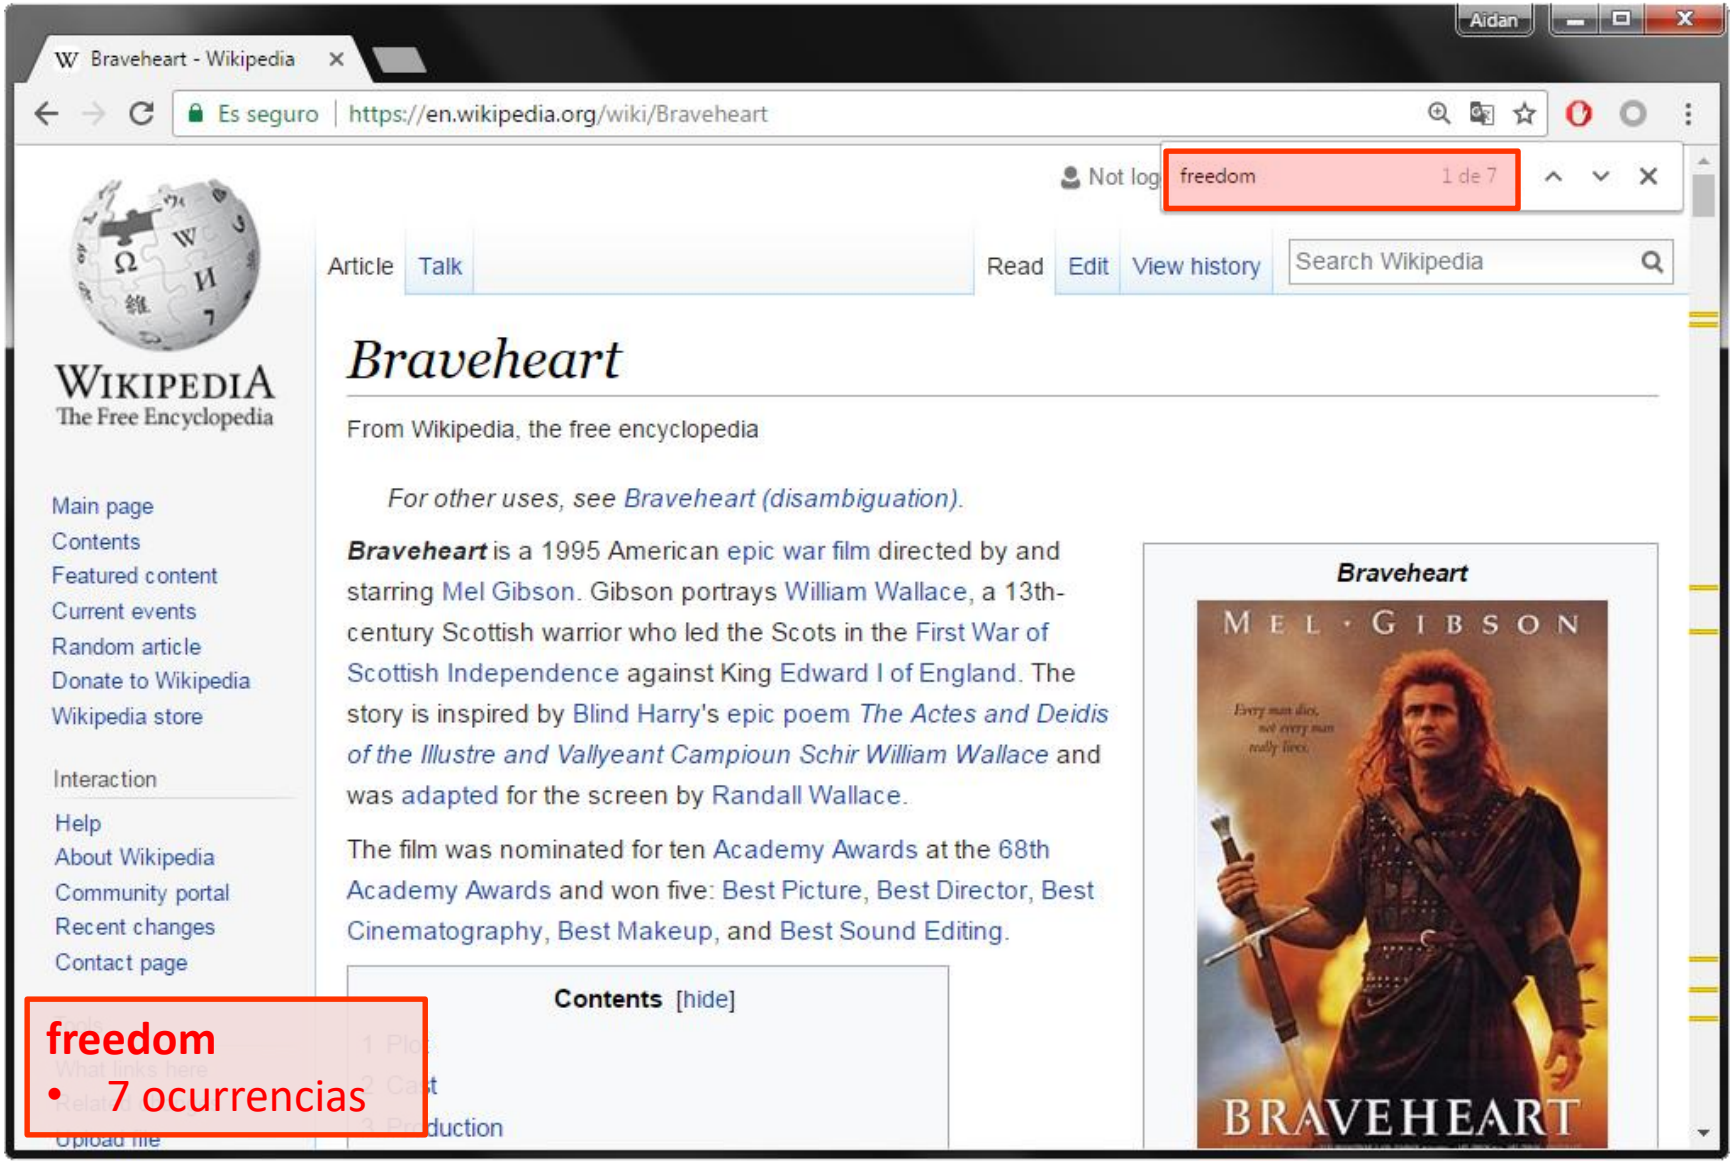
Ejemplo de una consulta

¿Cuáles de las tres palabras debería pesar más en el ranking?

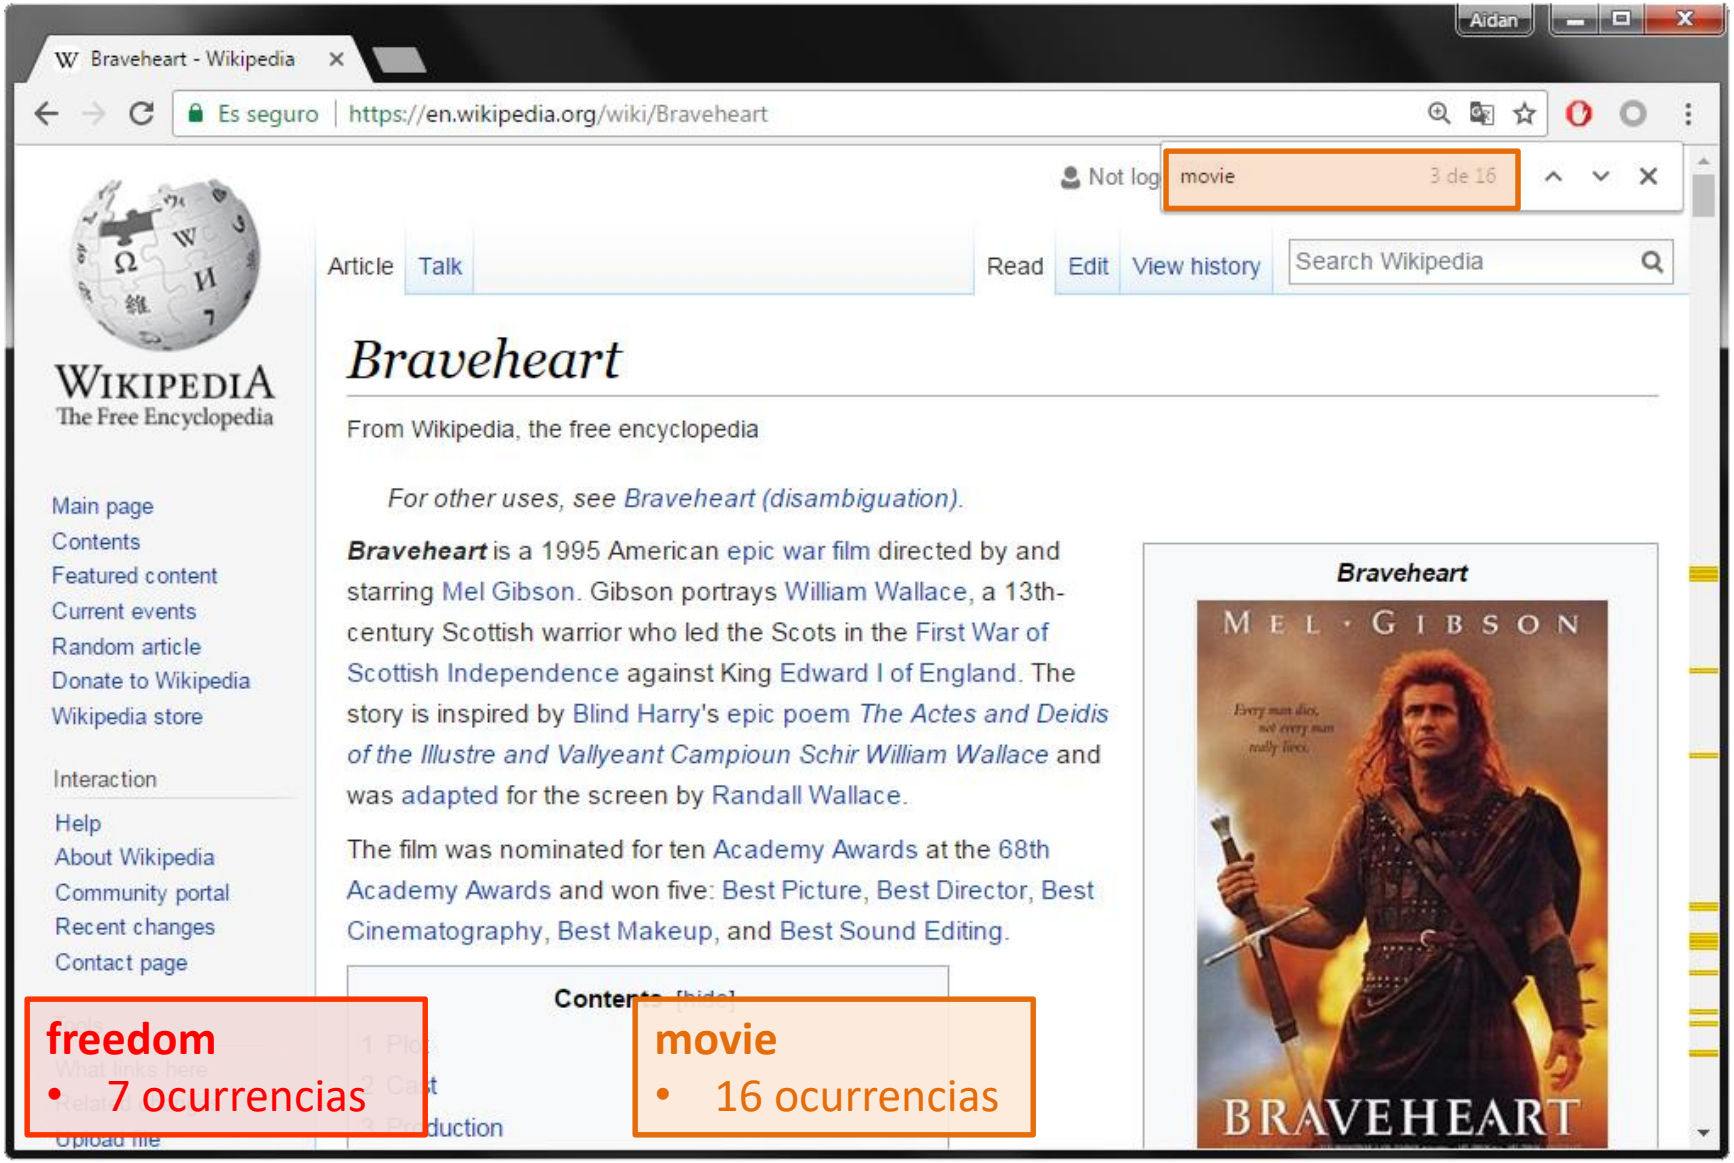
Veremos (en más detalle) con un ejemplo …



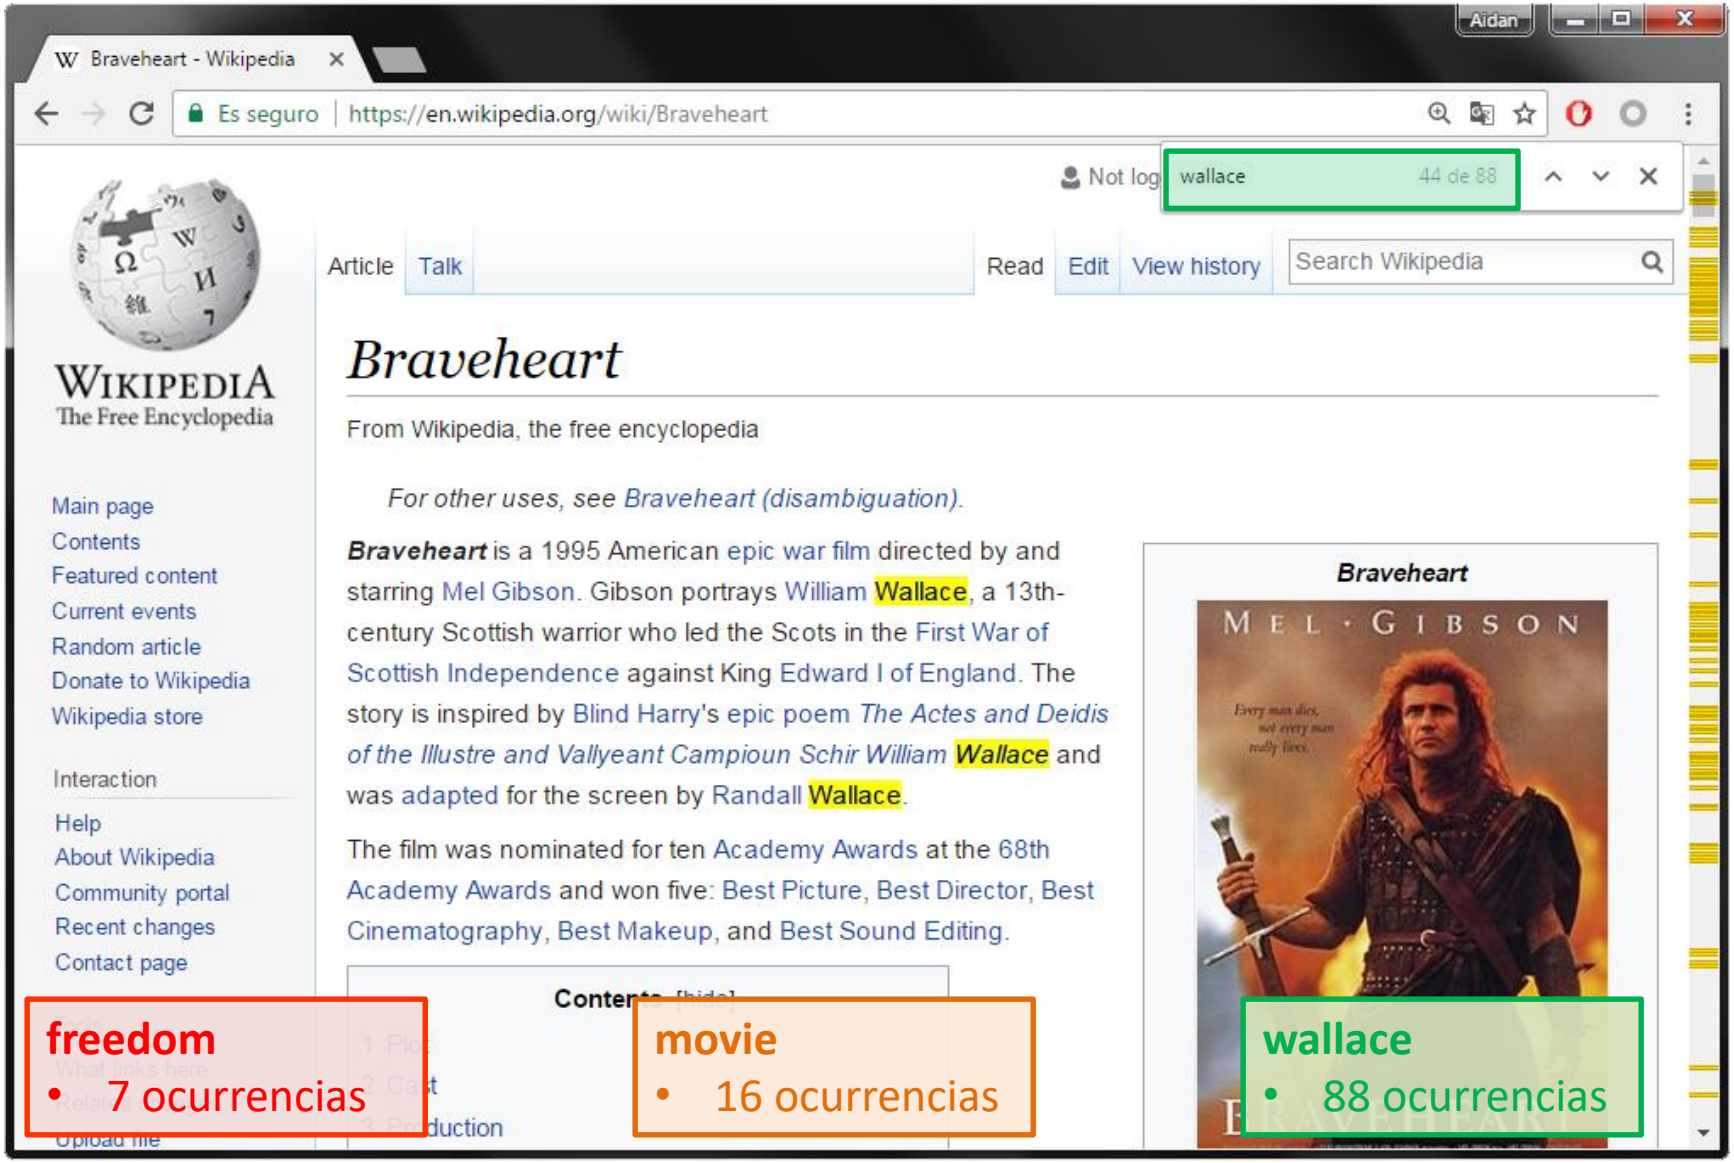
Coincidencias en un documento



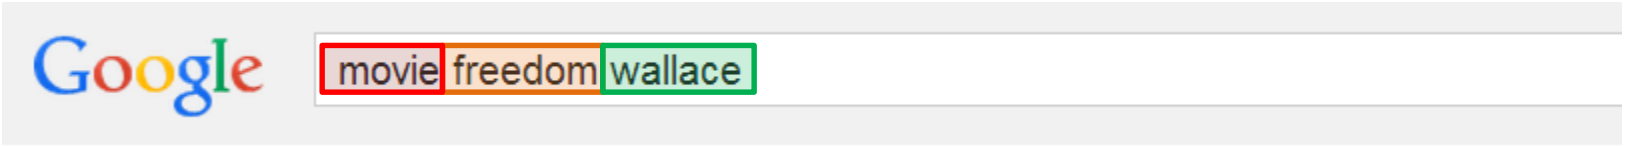
Coincidencias en un documento

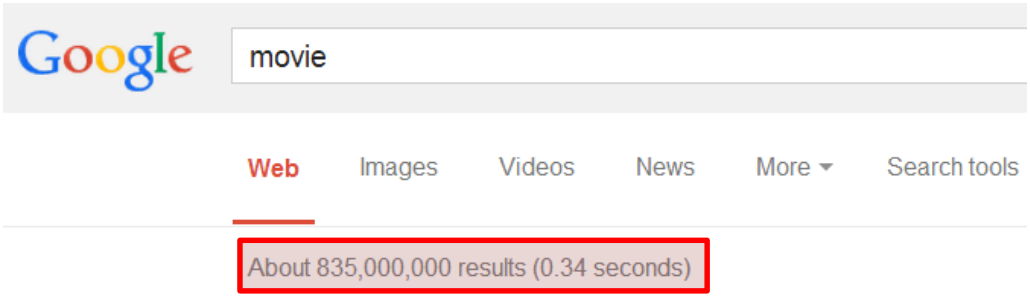


Coincidencias en un documento



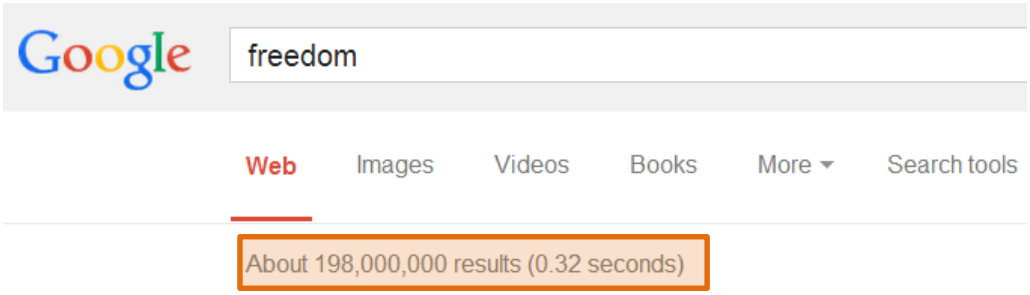
Pesos de las palabras





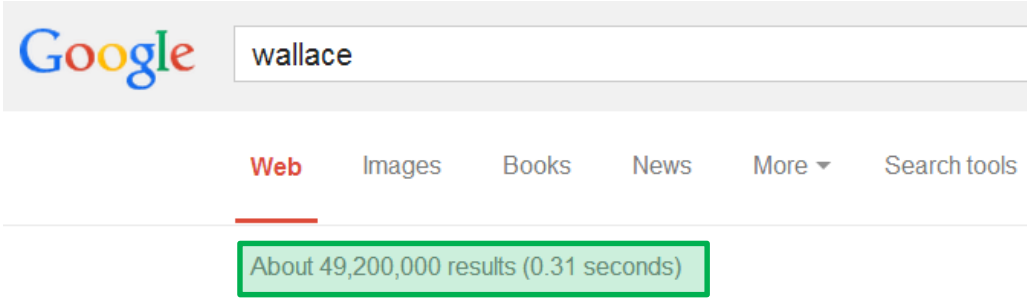
movie

- se usa muy frecuentemente



freedom

- se usa frecuentemente



wallace

- se usa ocasionalmente

Estimando la relevancia de un documento

- Palabras raras pesan más que palabras comunes
  - wallace (49M) pesa más que freedom (198M) que a su vez pesa más que movie (835M)

- Palabras con más ocurrencias en un documento pesan más
  - wallace (88) pesa más que movie (16) que a su vez pesa más que freedom (7)

Medida de relevancia: TF–IDF

- TF: Term Frequency (frecuencia de términos)
  - Mide la cantidad de ocurrencias de una palabra en un documento
  - $\mathrm{tf}(t, d)$ … hay varias opciones
    - Conteo simple de ocurrencias

$$\mathrm{tf}(t, d) = \mathrm{count}(t, d)$$

    - Escala logarítmica

$$\mathrm{tf}(t, d) = \log(\mathrm{count}(t, d) + 1)$$

    - Normalizado con respecto al largo del documento

$$\mathrm{tf}(t, d) = \frac{\mathrm{count}(t,d)}{\sum_{t' \in d} \mathrm{count}(t',d)}$$

$$\mathrm{tf}(t, d) = \frac{\mathrm{count}(t,d)}{\max_{t' \in d} \mathrm{count}(t',d)}$$

    - Una combinación / otras opciones ☺

Medida de relevancia: TF–IDF

- IDF: Inverse Document Frequency

  (frecuencia inversa de documentos)

  - ¿Qué tan raro es un término a través de todos los documentos?
  - $\mathrm{idf}(t, D)$ ...
    - La proporción de los documentos que contengan el término, invertida y escalada logarítmicamente

$$\mathrm{idf}(t, D) = \log\left(\frac{|D|+1}{|\{d \in D : t \in d\}|+1}\right)$$

Medida de relevancia: TF–IDF

- TF–IDF: Combina Term Frequency e Inverse Document Frequency:

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \text{idf}(t, D)$$

- Puntaje para una consulta
  - Sea una consulta $q = (t_1, \ldots, t_n)$
  - El puntaje de la consulta es: $\text{score}(q, d) = \sum_{t \in q} \text{tf-idf}(t, d)$

(Hay otras posibilidades)

Medida de relevancia: TF–IDF



Term Frequency

$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$
movie	16
freedom	7
wallace	43

Medida de relevancia: TF–IDF



Term Frequency

$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$
movie	16	835,000,000
freedom	7	198,000,000
wallace	43	49,200,000

Medida de relevancia: TF–IDF



Term Frequency

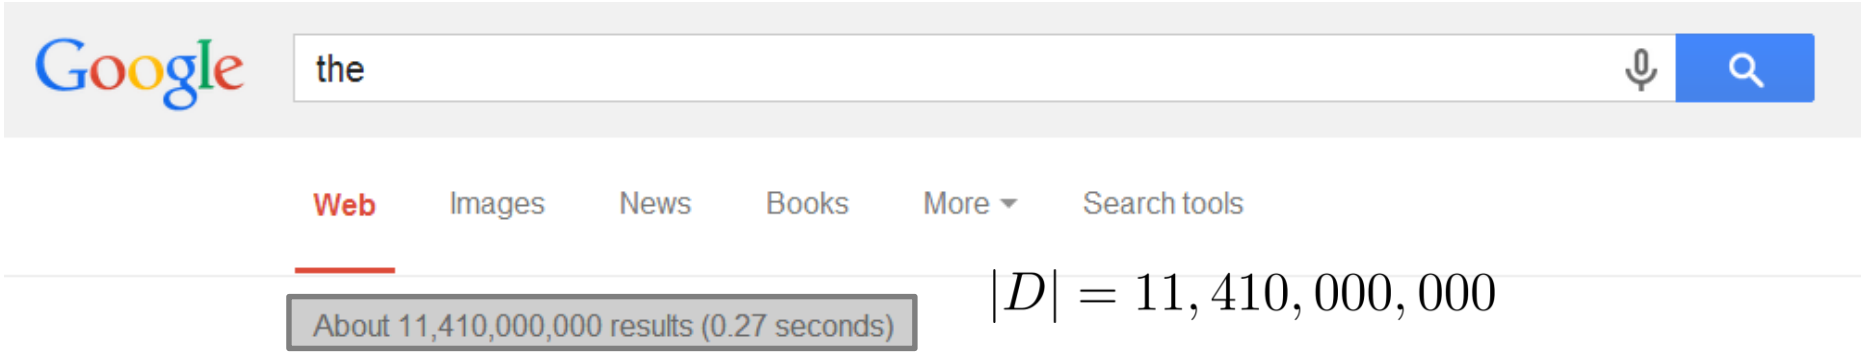
$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$	$\frac{\lvert D\rvert}{\lvert\{d \in D : t \in d\}\rvert+1}$
movie	16	835,000,000	
freedom	7	198,000,000	
wallace	43	49,200,000	



$$|D| = 11,410,000,000$$

Medida de relevancia: TF–IDF



Term Frequency

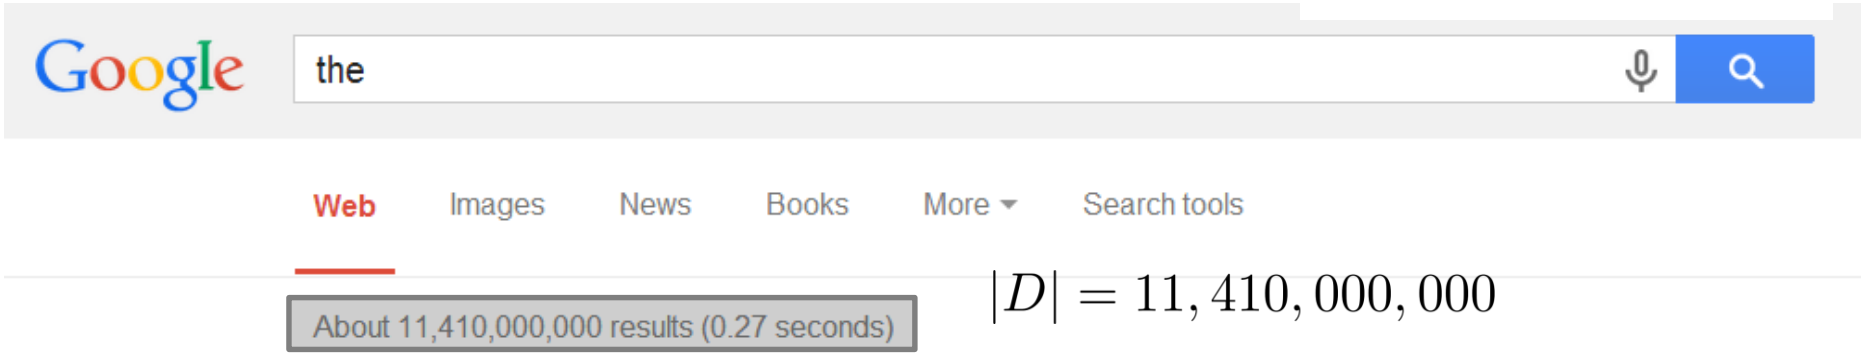
$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$	$\frac{\lvert D\rvert}{\lvert\{d \in D : t \in d\}\rvert+1}$
movie	16	835,000,000	13.66
freedom	7	198,000,000	57.62
wallace	43	49,200,000	231.91



$$|D| = 11,410,000,000$$

Medida de relevancia: TF–IDF



Term Frequency

$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$	$\frac{\lvert D\rvert}{\lvert\{d \in D : t \in d\}\rvert+1}$	$\mathrm{idf}(t,D)$
movie	16	835,000,000	13.66	3.77
freedom	7	198,000,000	57.62	5.84
wallace	43	49,200,000	231.91	7.85

Medida de relevancia: TF–IDF



Term Frequency

$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$	$\frac{\lvert D\rvert}{\lvert\{d \in D : t \in d\}\rvert+1}$	$\mathrm{idf}(t,D)$	$\text{tf-idf}(t,d)$
movie	16	835,000,000	13.66	3.77	60.36
freedom	7	198,000,000	57.62	5.84	40.94
wallace	43	49,200,000	231.91	7.85	337.87

Medida de relevancia: TF–IDF



Term Frequency

$$\mathrm{tf}(t,d) = \mathrm{count}(t,d)$$

Inverse Document Frequency

$$\mathrm{idf}(t,D) = \log_2\left(\frac{|D|}{|\{d \in D : t \in d\}|+1}\right)$$

$$\text{tf-idf}(t,d) = \mathrm{tf}(t,d) \times \mathrm{idf}(t,D)$$

t	$\mathrm{tf}(t,d)$	$\lvert\{d \in D : t \in d\}\rvert$	$\frac{\lvert D\rvert}{\lvert\{d \in D : t \in d\}\rvert+1}$	$\mathrm{idf}(t,D)$	$\text{tf-idf}(t,d)$
movie	16	835,000,000	13.66	3.77	60.36
freedom	7	198,000,000	57.62	5.84	40.94
wallace	43	49,200,000	231.91	7.85	337.87

$$\mathrm{score}(q,d) = \sum_{t \in q} \text{tf-idf}(t,d)$$

$$\mathrm{score}\big((\text{movie}, \text{freedom}, \text{wallace}), \text{http://en.wikipedia.org/Braveheart}\big) \approx 439.17$$

Las dos caras del ranking: Relevancia



"Boosting" basado en campos

- Títulos deberían pesar más que el cuerpo, etc.



El texto de un enlace ("Anchor text")

- Cómo la web "etiqueta" una página externa

```
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN"
 "http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">
<html>
<head>
  <title>What I watched last night ...</title>
</head>
<body>
<p>Last night I was pretty bored so I made some popcorn and watched
<a href="http://en.wikipedia.org/Braveheart">a movie about William Wallace called Braveheart</a>.
Set in Scotland it has lots of blood and gore.
</p>
</body>
</html>
```

El texto de un enlace ("Anchor text")

- Cómo la web "etiqueta" una página externa

```
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN"
 "http://www.w3.org/TR/
<html>
<head>
  <title>What I watched
</head>
<body>
<p>Last night I was pret
<a href="http://en.wikip
Set in Scotland it has
</p>
</body>
</html>
```



Apache Lucene usa puntaje de relevancia

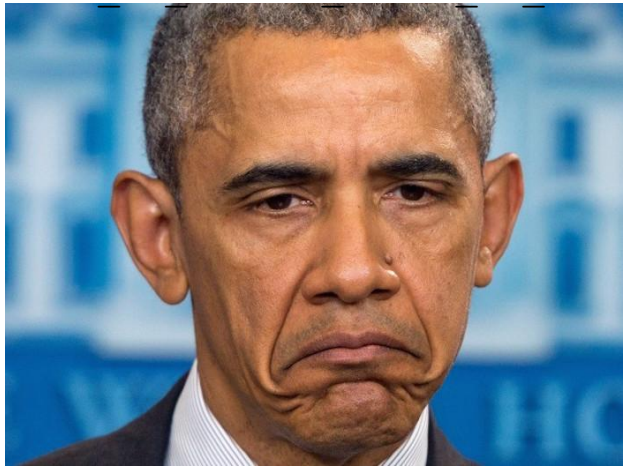
Búsqueda: "`obama`"

Resultados:

1. `http://es.wikipedia.org/wiki/Obama_Republican`
2. `http://es.wikipedia.org/wiki/Obama_(Fukui)`
3. `http://es.wikipedia.org/wiki/Michelle_Obama`
4. `http://es.wikipedia.org/wiki/Barack_Obama`
5. `http://es.wikipedia.org/wiki/Republicanos_por_Obama`
6. `http://es.wikipedia.org/wiki/Cartel_%22Hope%22_de_Obama Cartel`
7. `http://es.wikipedia.org/wiki/Ricardo_Mangue_Obama_Nfubea`
8. `http://es.wikipedia.org/wiki/Transición_presidencial_de_Barack_Obama`
9. `http://es.wikipedia.org/wiki/Primera_investidura_presidencial_de_Barack_Obama`
10. `http://es.wikipedia.org/wiki/Campaña_presidencial_de_Barack_Obama_de_2008`

Entonces ¿cómo podemos definir un proceso de ranking en el cual Barack Obama salga como el primer resultado?

Veremos …



Ranking:
Importancia

Las dos caras del ranking: Importancia



Las dos caras del ranking: Importancia

¿Cómo podemos determinar que Barack Obama es un resultado más importante que Mount Obama?





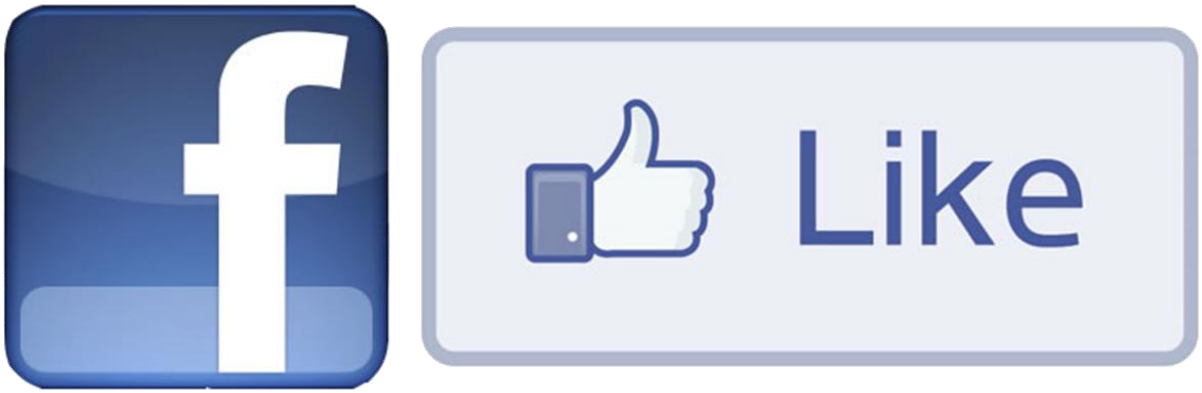
Análisis de enlaces ("Links analysis")

¿A qué documento veremos más enlaces?
¿La página de Wikipedia de Mount Obama? o
¿La página de Wikipedia de Barack Obama?



Análisis de enlaces ("Links analysis")

- Considera los enlaces como "votos" para una página
- Un enlace es como un "like" de la Web abierta …



(… incluso si la página es enlazada de manera negativa.)

Análisis de enlaces ("Links analysis")

Entonces, si contamos el número de enlaces entrantes a una página web, conocemos su importancia, ¿cierto?



"Spamming" de enlaces



Claritin Clomid Combivent Confido Copegus Cordarone Coreg Coumadin Cozaar Crestor Cyklokapron Cymbalta Cystone Cytotec Danazol Deltasone Depakote Desyrel Detrol Diabecon Diakof Diarex Didronel Differin Dilantin Diovan Dostinex Elavil Elimite Emsam Endep Eurax Evecare Evista Exelon Famvir Feldene Femara Femcare Flomax Flonase Flovent Fosamax Gasex Geodon Geriforte Herbolax High Love Himcocid Himcolin Himcospaz Himplasia Hoodia Hytrin Hyzaar Imdur Imitrex Inderal Ismo Isoptin Isordil Kamagra Karela Keftab Koflet Kytril Lamictal Lamisil Lanoxin Lariam Lasix Lasuna Leukeran Levaquin Levlen Levothroid Lincocin Lioresal Lisinopril Liv.52 Lopid Lopressor Loprox Lotensin Lotrisone Loxitane Lozol Lukol Lynoral Maxaquin Menosan Mentat Mentax Mevacor Mexitil Miacalcin Micardis Mobic Monoket Motrin Myambutol Mycelex-G Mysoline Naprosyn Neurontin Nicotinell Nimotop Nirdosh Nizoral Nolvadex Nonoxinol Noroxin Omnicef Ophthacare Oxytrol Pamelor Parlodel Paxil Penisole Phentrimine Pilex Plan B Plavix Plendil Pletal Prandin Pravachol Prednisone Premarin Prevacid Prilosec Prinivil Procardia Prograf Prometrium Propecia Proscar Protonix Proventil Prozac Purim Purinethol Quibron-T Relafen Renalka Reosto Requip Retin-A Revia Rhinocort Rimonabant Risperdal Rocaltrol Rogaine Rumalaya Sarafem Septilin **Serevent** **Serophene** **Seroquel** Shallaki Shoot Sinequan Singulair Snoroff Sorbitrate Speman Starlix StretchNil Stromectol Styplon Sumycin Superman Sustiva Synthroid Tenormin Topamax Trandate Tricor Trimox Triphala Tulasi Urispas V-Gel Vantin Vasodilan Vasotec Ventolin Viramune Vytorin Xeloda Xenacore Zanaflex Zantac Zebeta Zelnorm Zerit Yerba Diet Wellbutrin SR Women Attracting Pheromones Women's Intimacy Enhancer Women's Intimacy Enhancer Cream Virility Gum Vitamin A & D Viagra + Cialis Viagra + Cialis + Levitra Viagra Jelly Viagra Soft + Cialis Soft Viagra Soft Tabs Ultimate Male Enhancer Toprol XL Touch-Up Kit Tentex Royal Tentex Forte Tiberius Erectus Zero Nicotine 2 Complete Professional Whitening Kits 2 Sets Of Moldable Mouth Trays 36 Beauty Acne-n-Pimple Cream ActoPlus Met Superloss Multi SleepWell (Herbal XANAX) Shuddha Guggulu Rythmol SR Rumalaya Forte Pulmicort Inhaler Professional Plasma Tooth Whitening Kit Premium Diet Patch Penis Growth Oil Penis Growth Pack Penis Growth Patch Penis Growth Pills Orgasm Enhancer Norpace CR Mental Booster Men Attracting Pheromones Menopause Gum Male Enhancement Oil Male Enhancement Patch Male Enhancement Pills Male Sexual Tonic InnoPran XL Hoodia Weight Loss Gum Hoodia Weight Loss Patch Human Growth Hormone

¿Cómo podríamos combatir el "spam" así?

La importancia de un enlace

¿Cuál debería pesar más?
¿Un enlace desde http://en.wikipedia.org/wiki/Barack_Obama? o
¿Un enlace desde http://blackmagicspecialist.net.in?



¿Pero por qué?
Y ¿cómo podríamos medir esta intuición?

PageRank



PageRank

- No tan solo un conteo de enlaces entrantes
  - Un enlace de una página más importante pesa más
  - Un enlace de una página con pocos enlaces pesa más

  ∴ Una página con más enlaces entrantes desde páginas más importantes (las cuales tienen menos enlaces salientes) es más importante

PageRank es recursivo



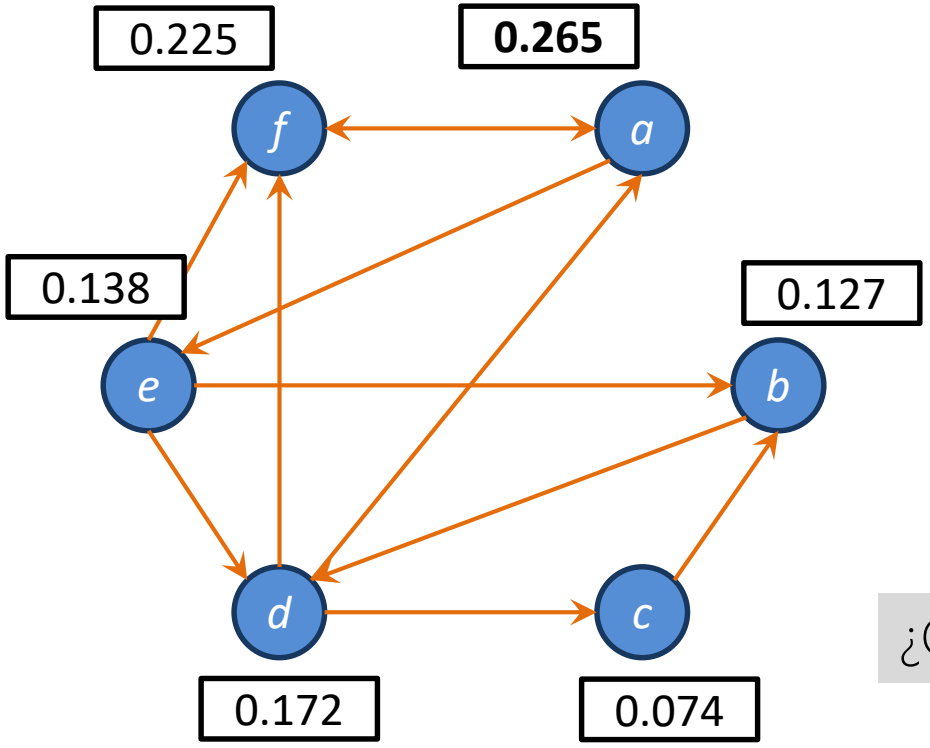
La versión básica de PageRank

- La Web: un grafo dirigido

$$G = (V, E)$$

Vértices (*páginas*)

Arcos (*enlaces*)



¿Cuál es el vértice más importante?

$$V = \{a, b, c, d, e, f\}$$

$$E = \{(a, e), (a, f), (b, d), (c, b), (d, a), (d, c), (d, f), (e, b), (e, d), (e, f), (f, a)\}$$

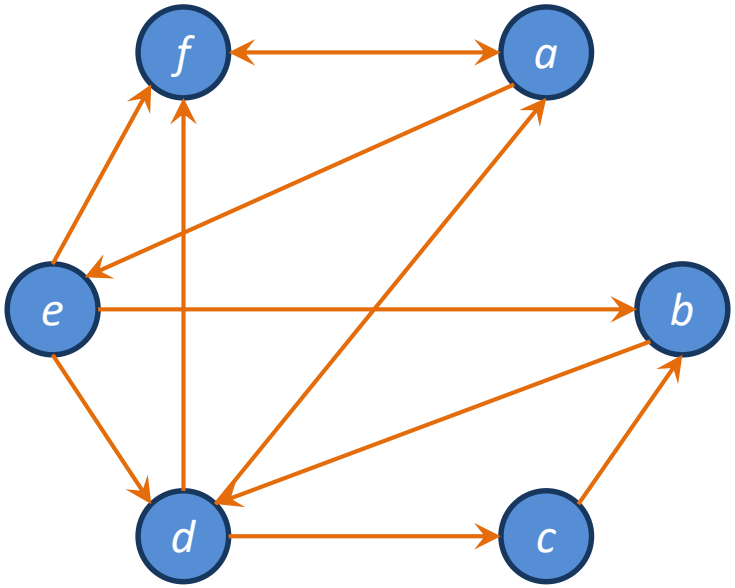
La versión básica de PageRank

- La Web: un grafo dirigido

$$G = (V, E)$$

Vértices (*páginas*)

Arcos (*enlaces*)





$$\text{out}(v) \coloneqq \{v' \in V \mid (v, v') \in E\}$$

$$\text{in}(v) \coloneqq \{v' \in V \mid (v', v) \in E\}$$

$$\text{rank}_0(v) \coloneqq \frac{1}{|V|}$$

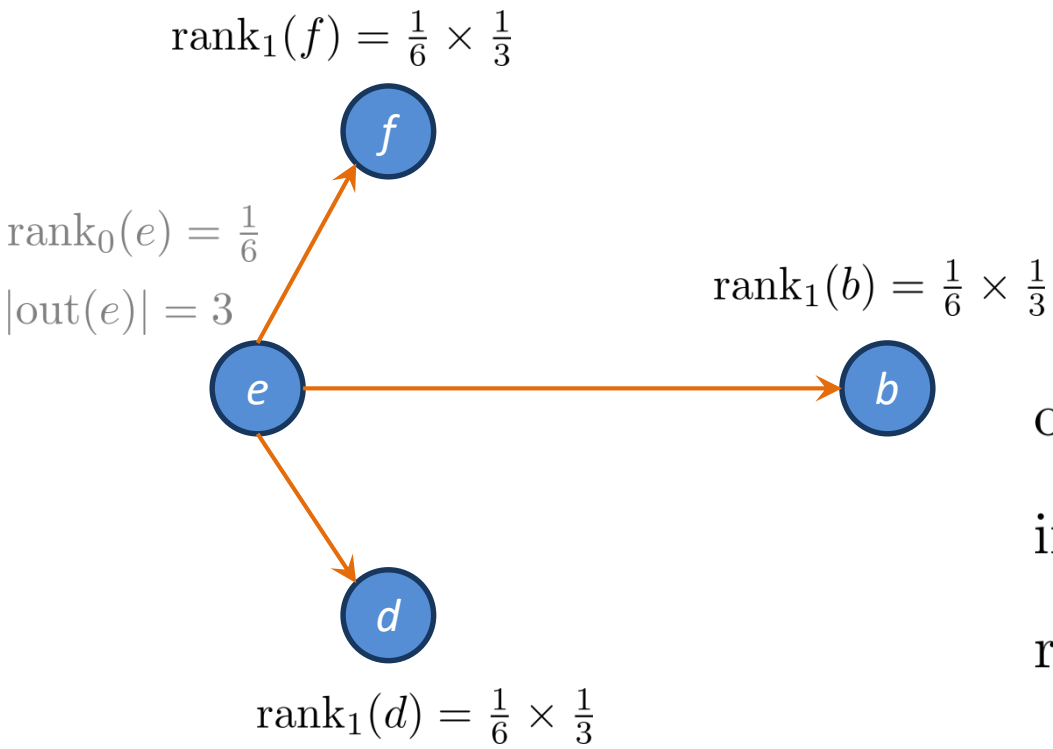
$$\text{rank}_i(v) \coloneqq \sum_{v' \in \text{in}(v)} \frac{\text{rank}_{i-1}(v')}{|\text{out}(v')|}$$

La versión básica de PageRank

$G = (V, E)$

Vértices (*páginas*)

Arcos (*enlaces*)



$$\text{out}(v) \coloneqq \{v' \in V \mid (v, v') \in E\}$$

$$\text{in}(v) \coloneqq \{v' \in V \mid (v', v) \in E\}$$

$$\text{rank}_0(v) \coloneqq \frac{1}{|V|}$$

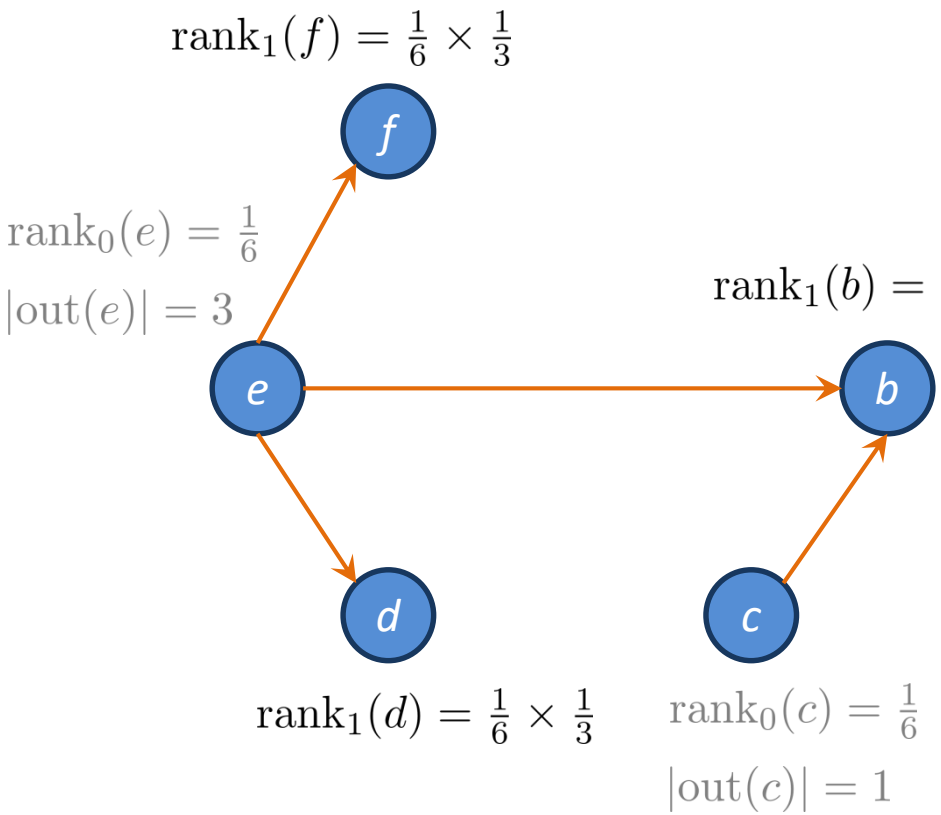
$$\text{rank}_i(v) \coloneqq \sum_{v' \in \text{in}(v)} \frac{\text{rank}_{i-1}(v')}{|\text{out}(v')|}$$

La versión básica de PageRank

$$G = (V, E)$$

Vértices (*páginas*)

Arcos (*enlaces*)



$$\mathrm{out}(v) \coloneqq \{v' \in V \mid (v, v') \in E\}$$

$$\mathrm{in}(v) \coloneqq \{v' \in V \mid (v', v) \in E\}$$

$$\mathrm{rank}_0(v) \coloneqq \frac{1}{|V|}$$

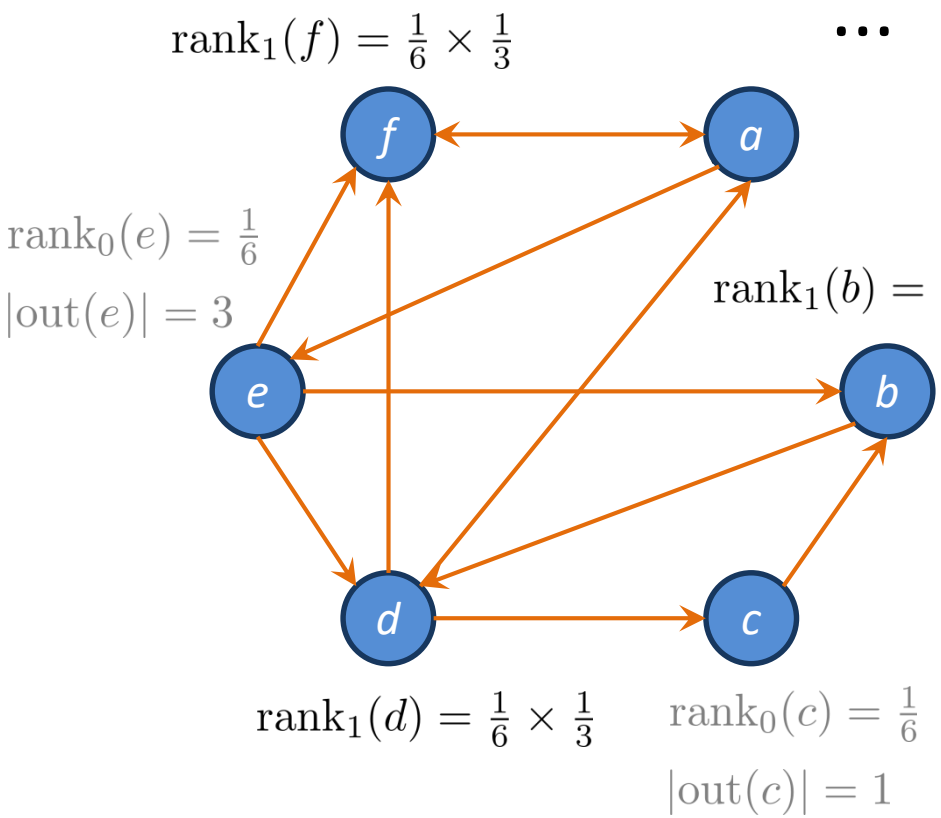
$$\mathrm{rank}_i(v) \coloneqq \sum_{v' \in \mathrm{in}(v)} \frac{\mathrm{rank}_{i-1}(v')}{|\mathrm{out}(v')|}$$

La versión básica de PageRank

$G = (V, E)$

Vértices (*páginas*)

Arcos (*enlaces*)



$$\text{out}(v) \coloneqq \{v' \in V \mid (v, v') \in E\}$$

$$\text{in}(v) \coloneqq \{v' \in V \mid (v', v) \in E\}$$

$$\text{rank}_0(v) \coloneqq \frac{1}{|V|}$$

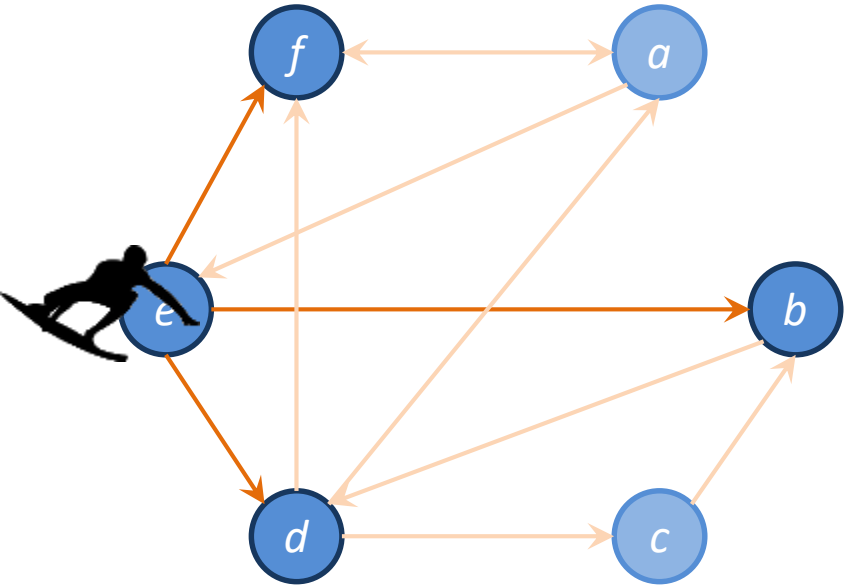
$$\text{rank}_i(v) \coloneqq \sum_{v' \in \text{in}(v)} \frac{\text{rank}_{i-1}(v')}{|\text{out}(v')|}$$

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente

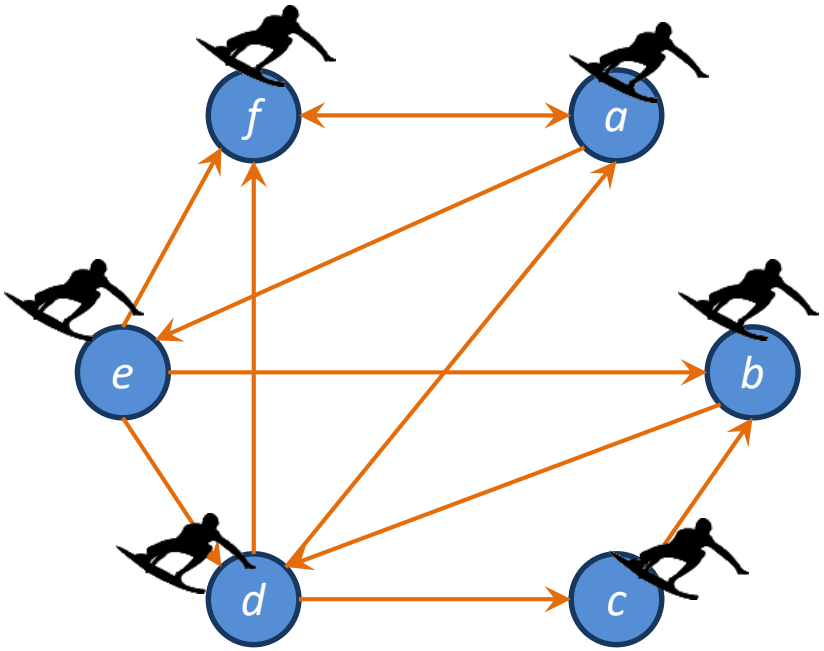
- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?



PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente

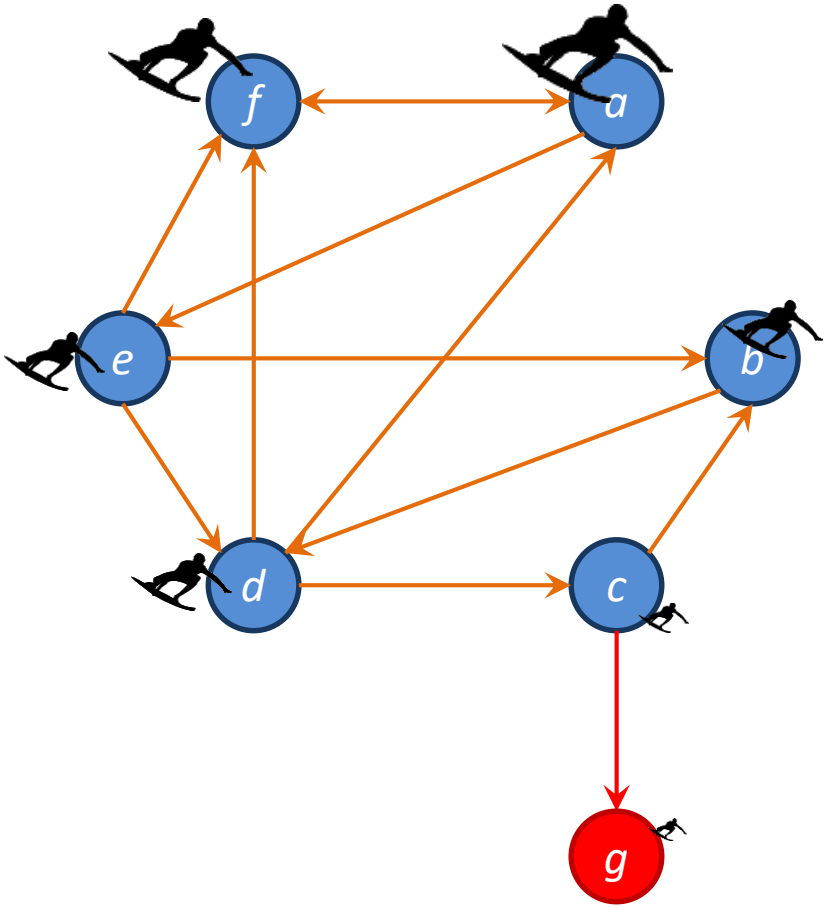


- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente



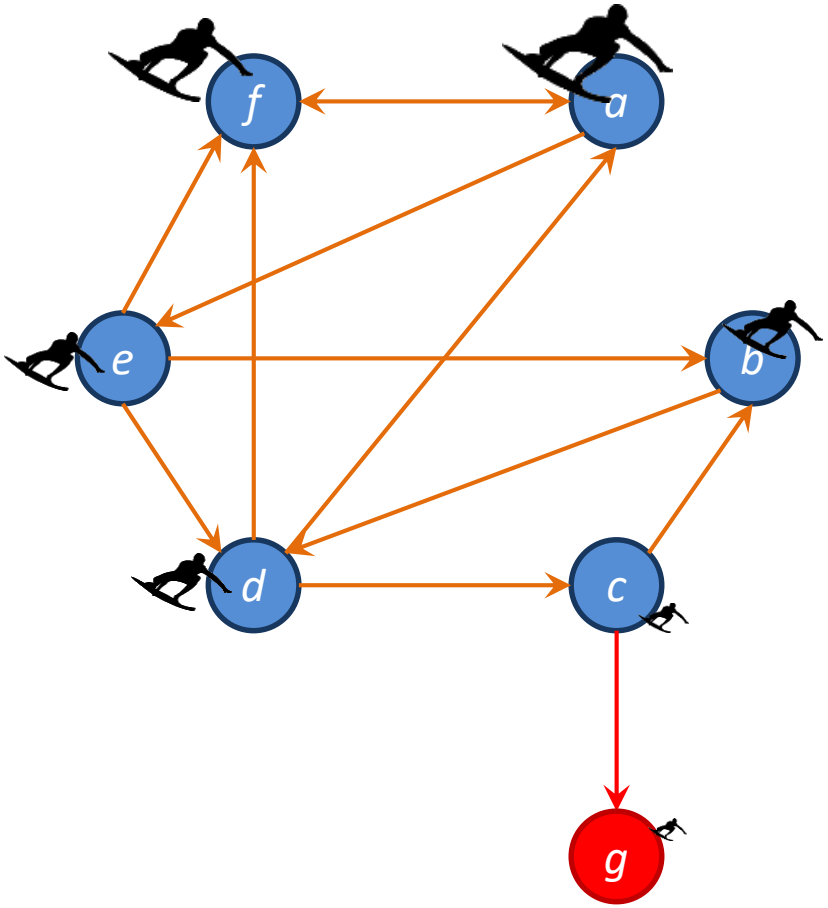
- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo
- PageRank se aplica iterativamente en cada salto: el puntaje indica la probabilidad de estar en esa página después de esa cantidad de saltos

¿Qué pasará con g
a medida que pasa el tiempo?

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente

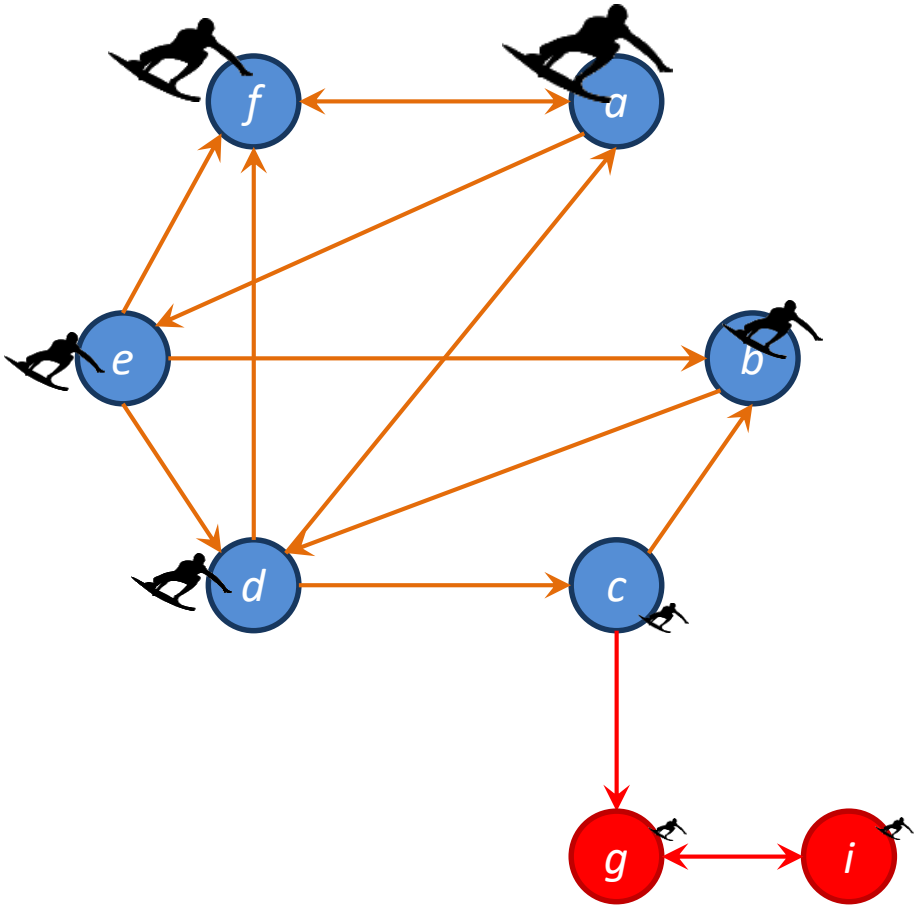


- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo
- PageRank se aplica iterativamente en cada salto: el puntaje indica la probabilidad de estar en esa página después de esa cantidad de saltos
- Si el surfer llega a una página sin enlaces, salta a otra aleatoriamente

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente



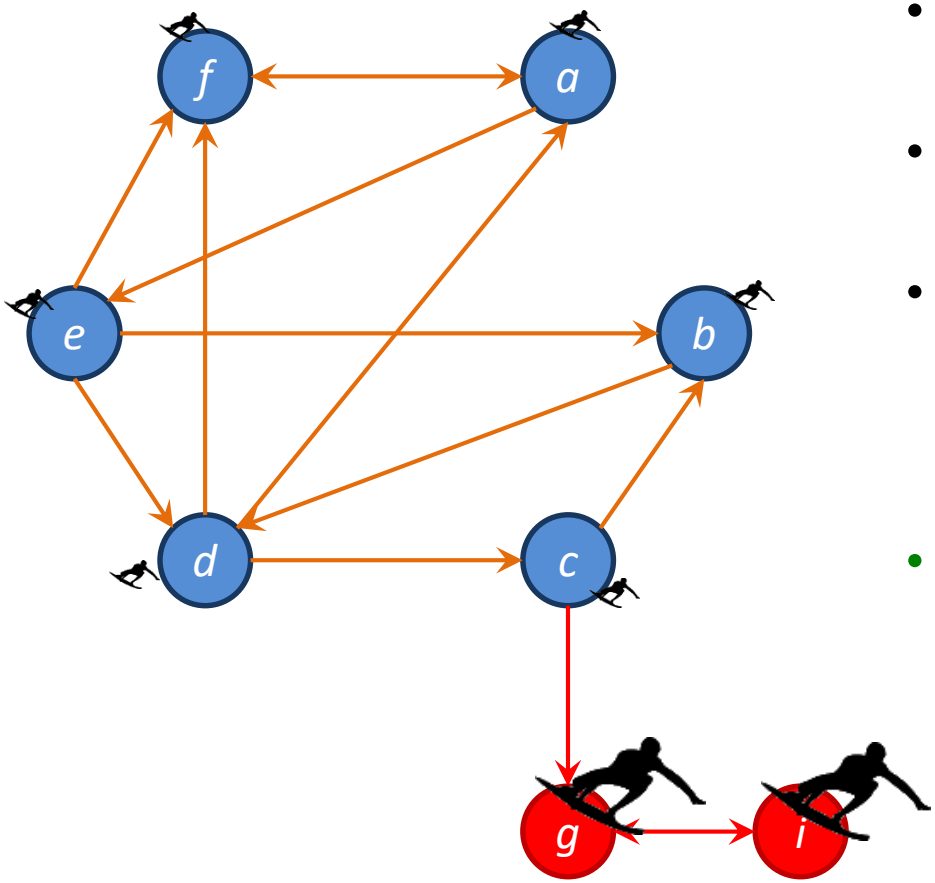
- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo
- PageRank se aplica iterativamente en cada salto: el puntaje indica la probabilidad de estar en esa página después de esa cantidad de saltos
- Si el surfer llega a una página sin enlaces, salta a otra aleatoriamente

¿Qué pasará con g e i
a medida que pasa el tiempo?

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente



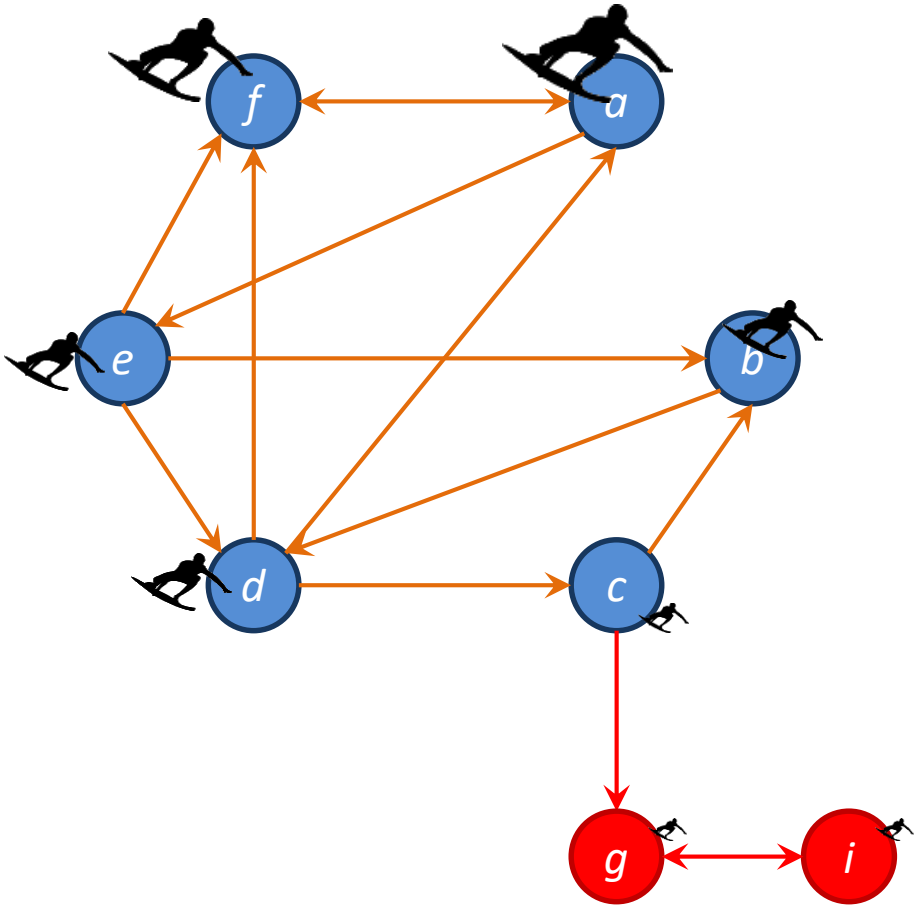
- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo
- PageRank se aplica iterativamente en cada salto: el puntaje indica la probabilidad de estar en esa página después de esa cantidad de saltos
- Si el surfer llega a una página sin enlaces, salta a otra aleatoriamente

¿Qué pasará con g e i
a medida que pasa el tiempo?

PageRank: El modelo del "surfer" aleatorio



= alguien "surfeando" la Web, haciendo clics en enlaces aleatoriamente



- ¿Cuál es la probabilidad de llegar a una página *x* después de *n* saltos?
- *Estado inicial:* El surfer puede empezar en cualquier nodo
- PageRank se aplica iterativamente en cada salto: el puntaje indica la probabilidad de estar en esa página después de esa cantidad de saltos
- Si el surfer llega a una página sin links, salta a otra aleatoriamente
- El surfer saltará a una página aleatoria con probabilidad 1 – *d* … *esto evita trampas y asegura convergencia*

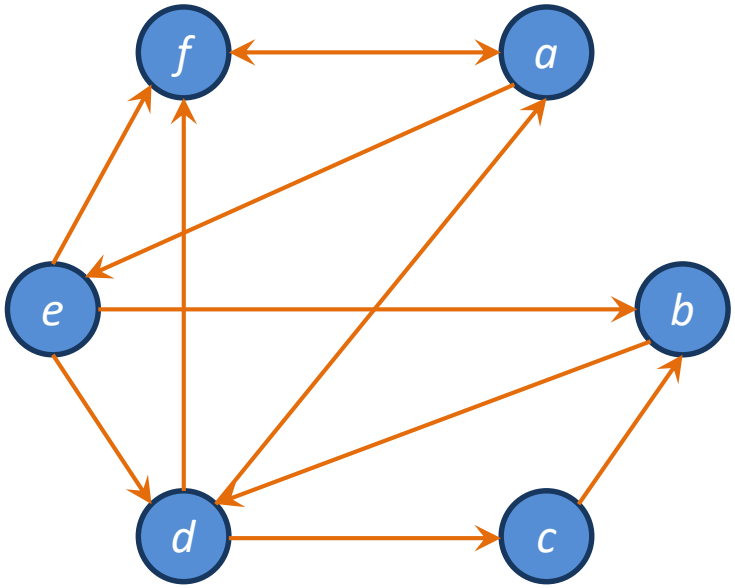
La versión final de PageRank

- La Web: Un grafo dirigido

$$G = (V, E)$$

Vértices (*páginas*)

Arcos (*enlaces*)



$$\mathrm{out}(v) \coloneqq \{v' \in V \mid (v, v') \in E\}$$

$$\mathrm{in}(v) \coloneqq \{v' \in V \mid (v', v) \in E\}$$

$$\mathrm{rank}_0(v) \coloneqq \frac{1}{|V|}$$

$$V' \coloneqq \{v \in V : |\mathrm{out}(v)| = 0\}$$

$$V'' \coloneqq \{v \in V : |\mathrm{out}(v)| \neq 0\}$$

d es la probabilidad de seguir un enlace (típicamente $d = 0{,}85$)

$$\mathrm{rank}_i(v) \coloneqq d \times \sum_{u \in \mathrm{in}(v)} \frac{\mathrm{rank}_{i-1}(u)}{|\mathrm{out}(u)|} + \sum_{v' \in V'} \frac{\mathrm{rank}_{i-1}(v')}{|V|} + (1-d) \times \sum_{v'' \in V''} \frac{\mathrm{rank}_{i-1}(v'')}{|V|}$$

PageRank: Beneficios



- ✓ Más robusto que un conteo simple de enlaces
- ✓ Menos empates
- ✓ Aproximaciones escalables (para grafos dispersos)
- ✓ Su convergencia es garantizada

Las dos caras del ranking: Importancia

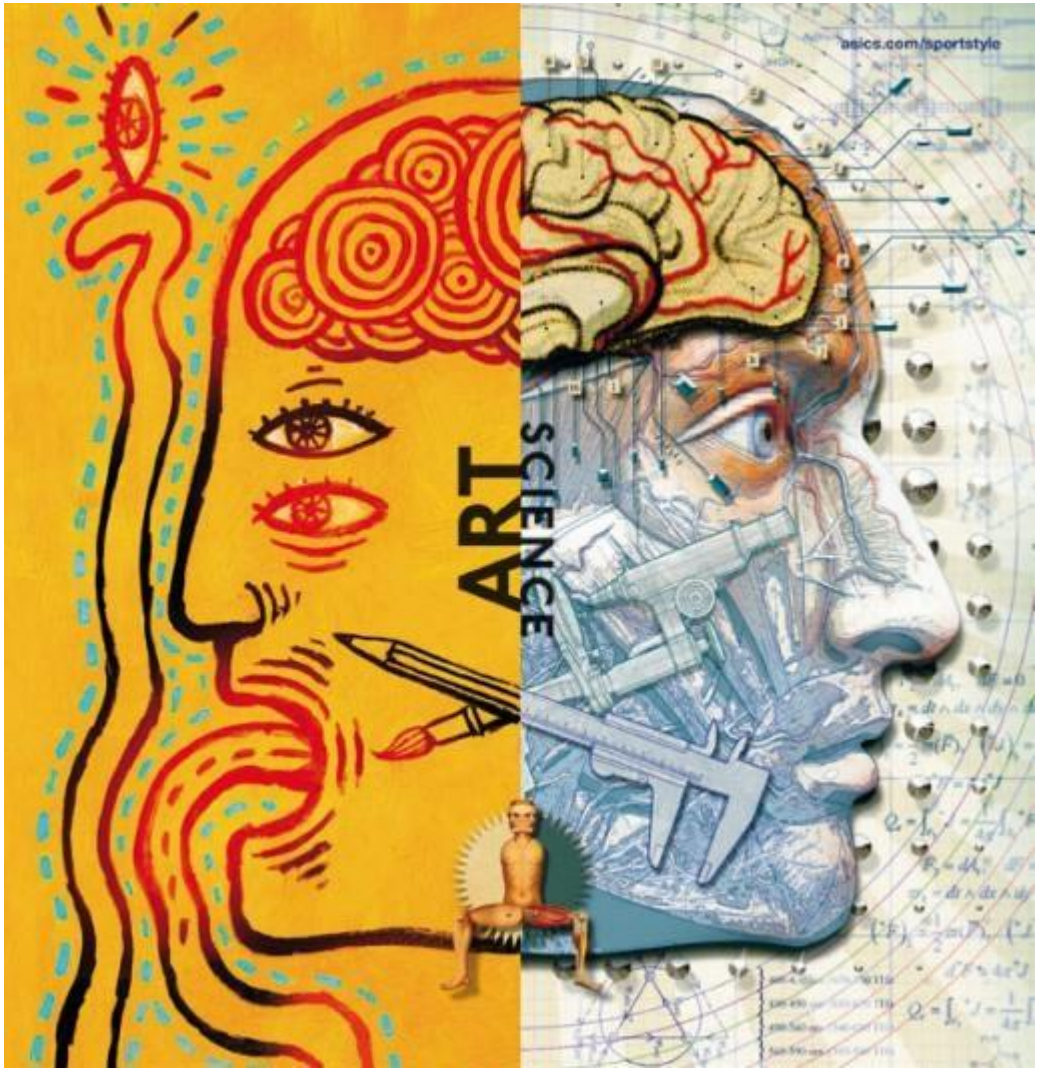
Google PageRank



>



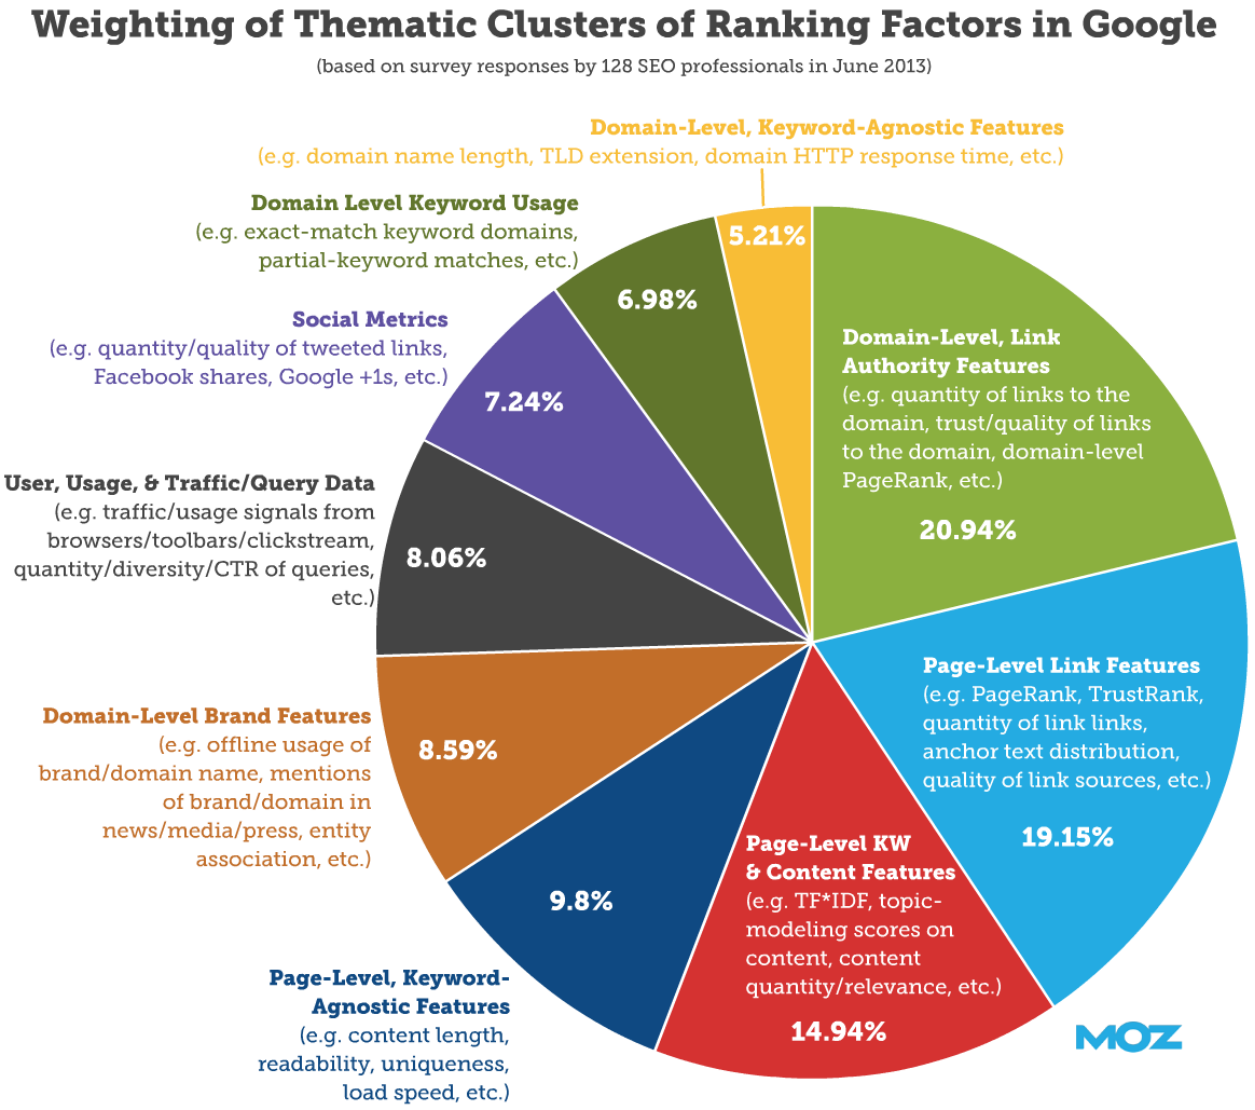
Ranking: ¿Ciencia o arte?



¿Cómo lo hace Google?
Lo que sabemos

¡Según algunos expertos de SEO (optimización de motores de búsqueda), no Google!

Cómo Google rankea sus resultados (quizás)



Cómo Google rankea sus resultados (quizás)

¿Por qué no sabemos más?



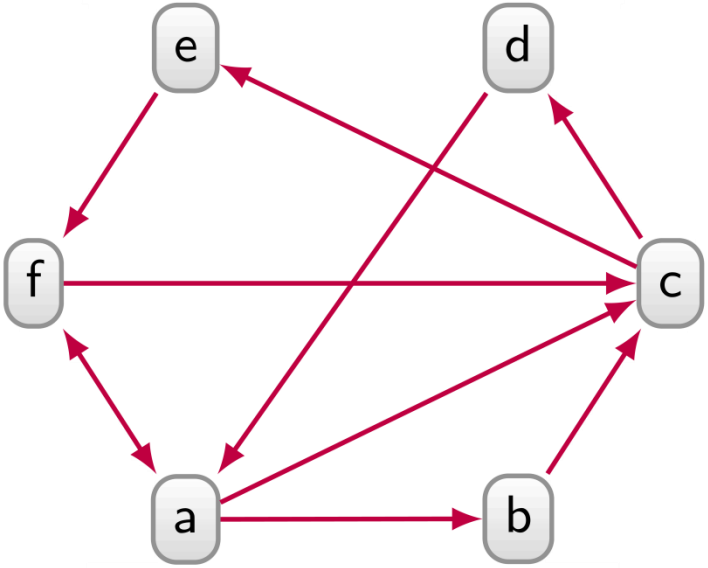
Ley de Goodhart:
"Cuando una medida se convierte en una meta, deja de ser una buena medida"

¡Según algunos expertos de SEO (optimización de motores de búsqueda), no Google!

Distribución de algoritmos de grafos

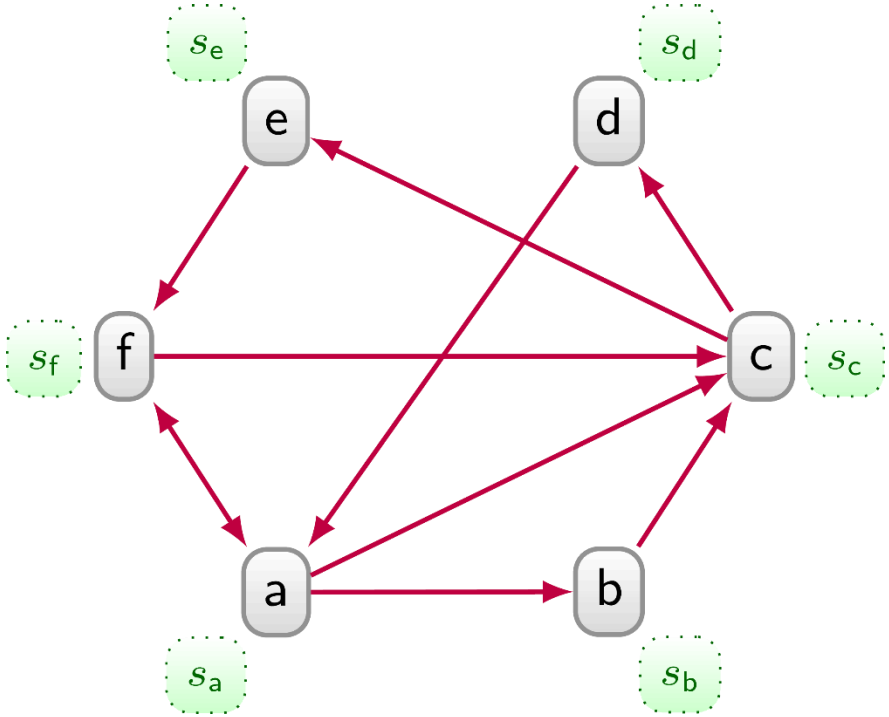
Computación Paralela sobre Grafos

- La entrada es un grafo



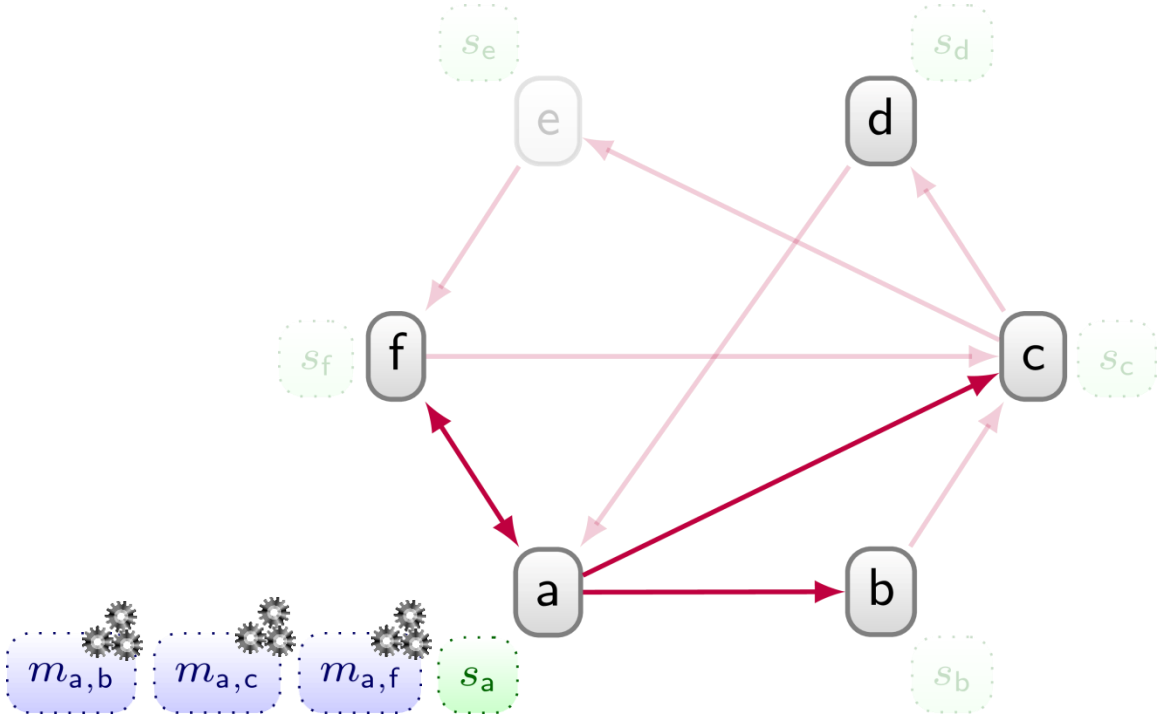
Computación Paralela sobre Grafos

- La entrada es un grafo
- Nodos tienen un estado



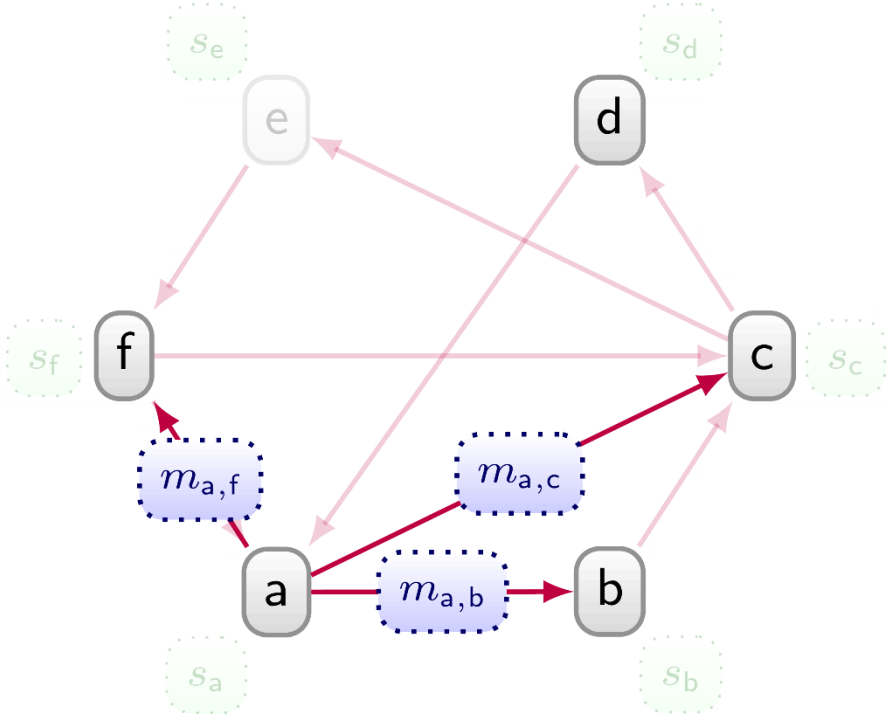
Computación Paralela sobre Grafos

- La entrada es un grafo
- Nodos tienen un estado
- Nodos computan mensajes



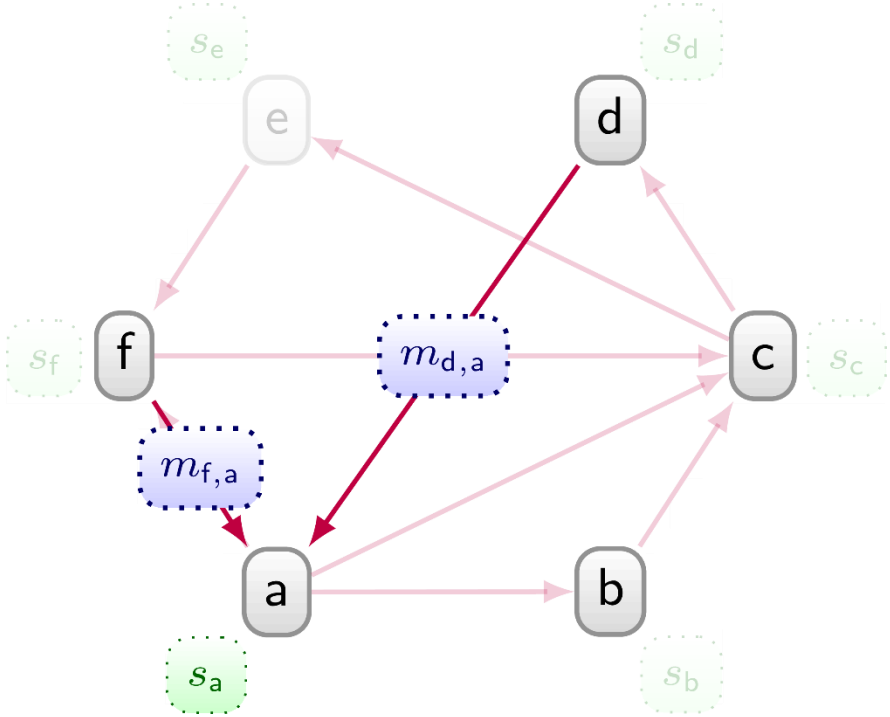
Computación Paralela sobre Grafos

- La entrada es un grafo
- Nodos tienen un estado
- Nodos computan mensajes
- Nodos mandan mensajes a sus vecinos



Computación Paralela sobre Grafos

- La entrada es un grafo
- Nodos tienen un estado
- Nodos computan mensajes
- Nodos mandan mensajes a sus vecinos
- Nodos reciben mensajes y computan un nuevo estado

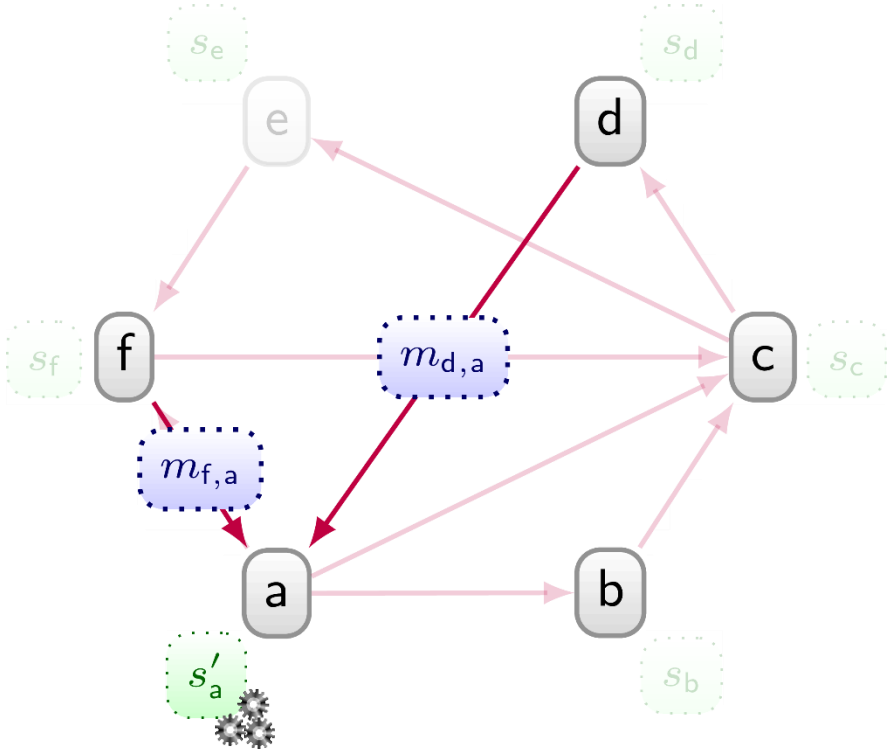


Computación Paralela sobre Grafos

- La entrada es un grafo
- Nodos tienen un estado
- Nodos computan mensajes
- Nodos mandan mensajes a sus vecinos
- Nodos reciben mensajes y computan un nuevo estado

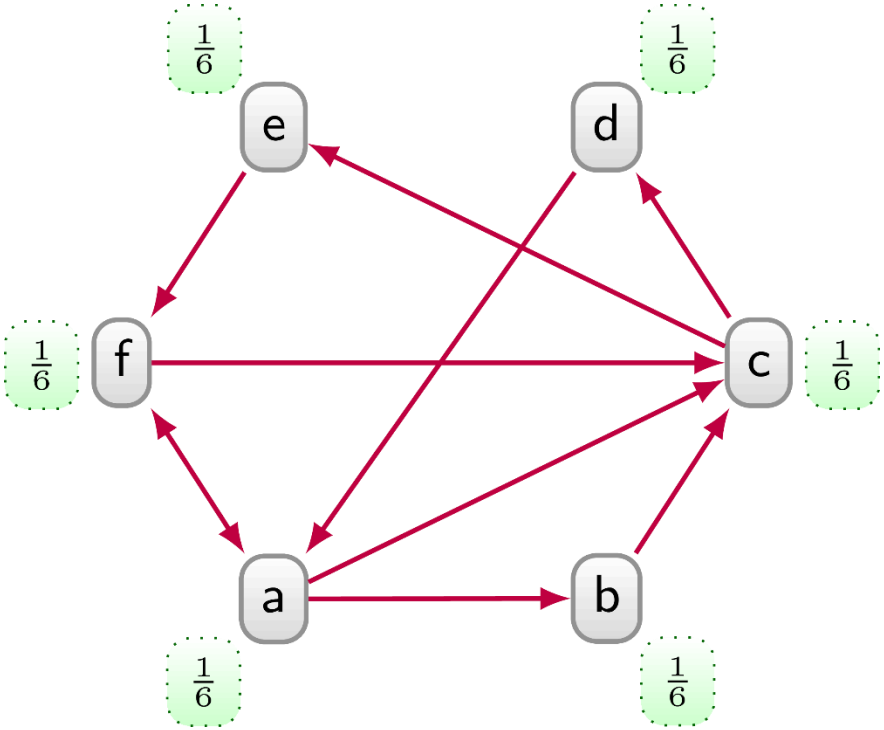
  ... recursivamente

  ... (en paralelo)



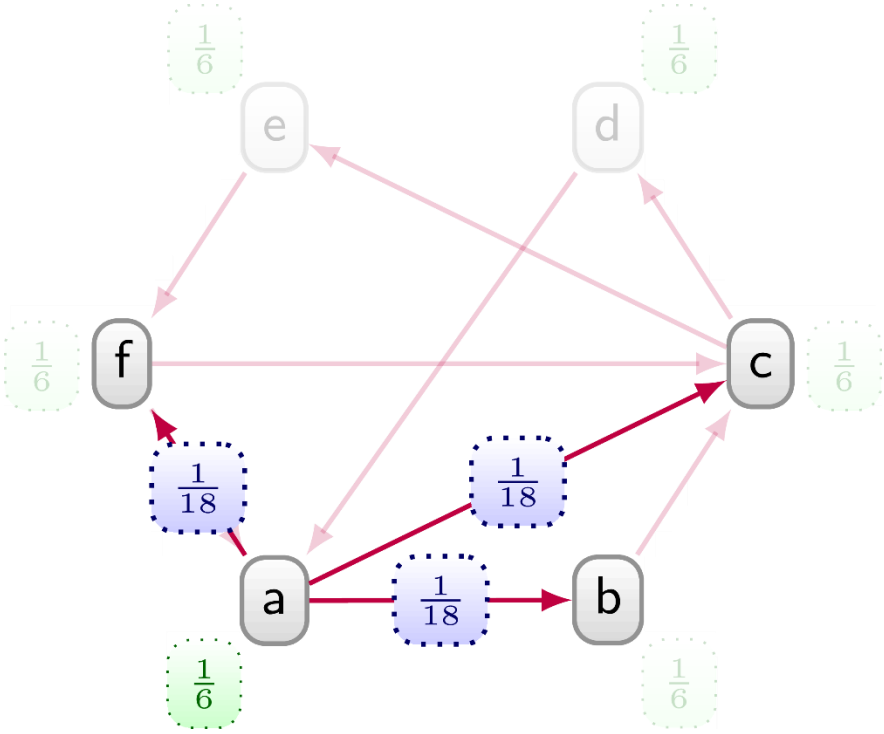
Ejemplo: PageRank (simplificado)

$\text{PageRank}(G)$:



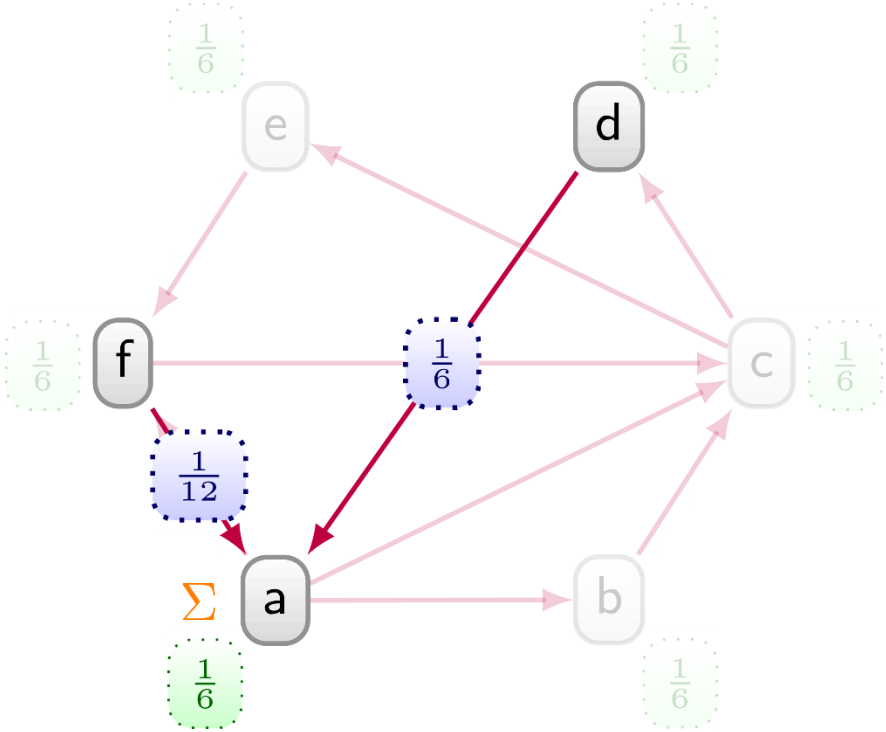
Ejemplo: PageRank (simplificado)

$\text{PageRank}(G)$:



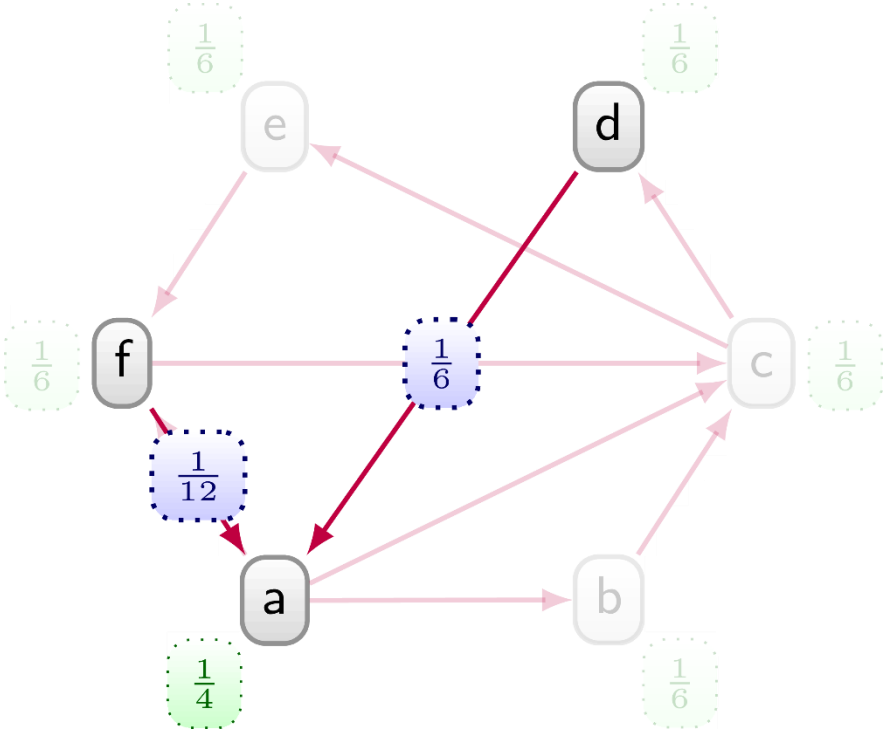
Ejemplo: PageRank (simplificado)

$\text{PageRank}(G)$:



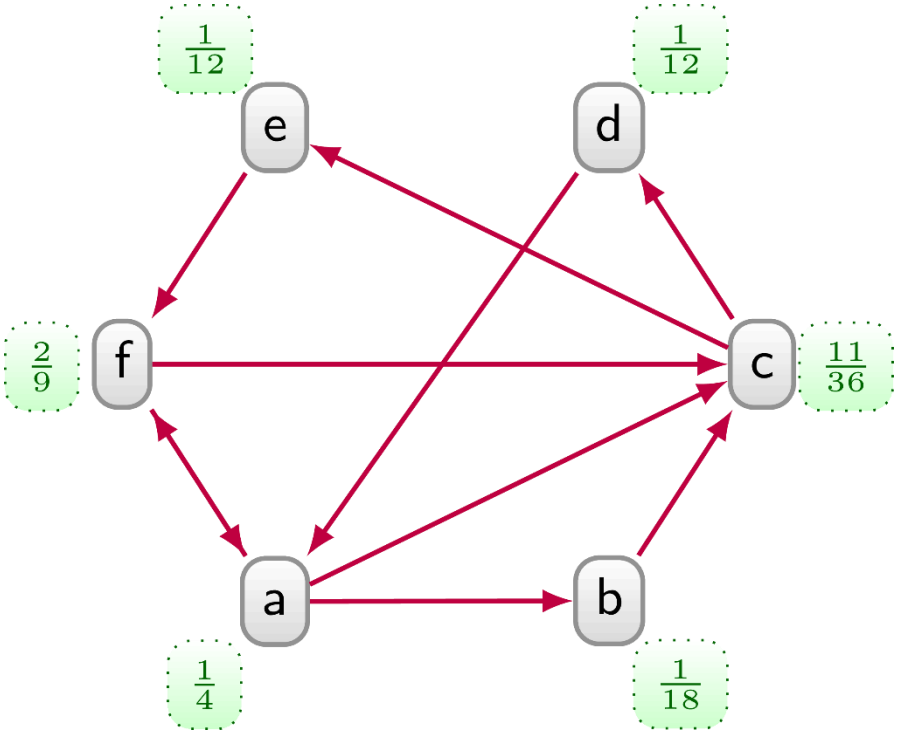
Ejemplo: PageRank (simplificado)

$\text{PageRank}(G)$:



Ejemplo: PageRank (simplificado)

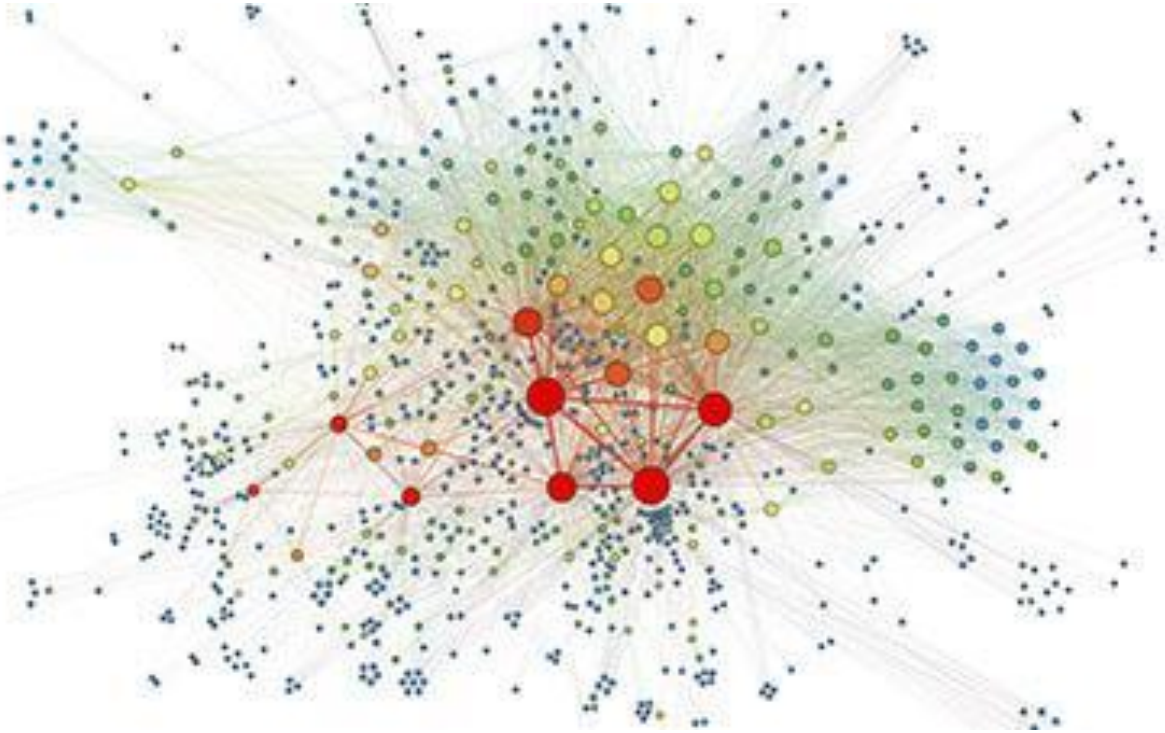
$\text{PageRank}(G)$:



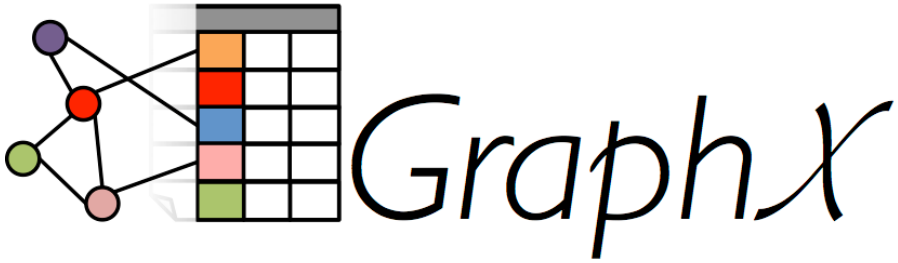
...

Otros algoritmos ...

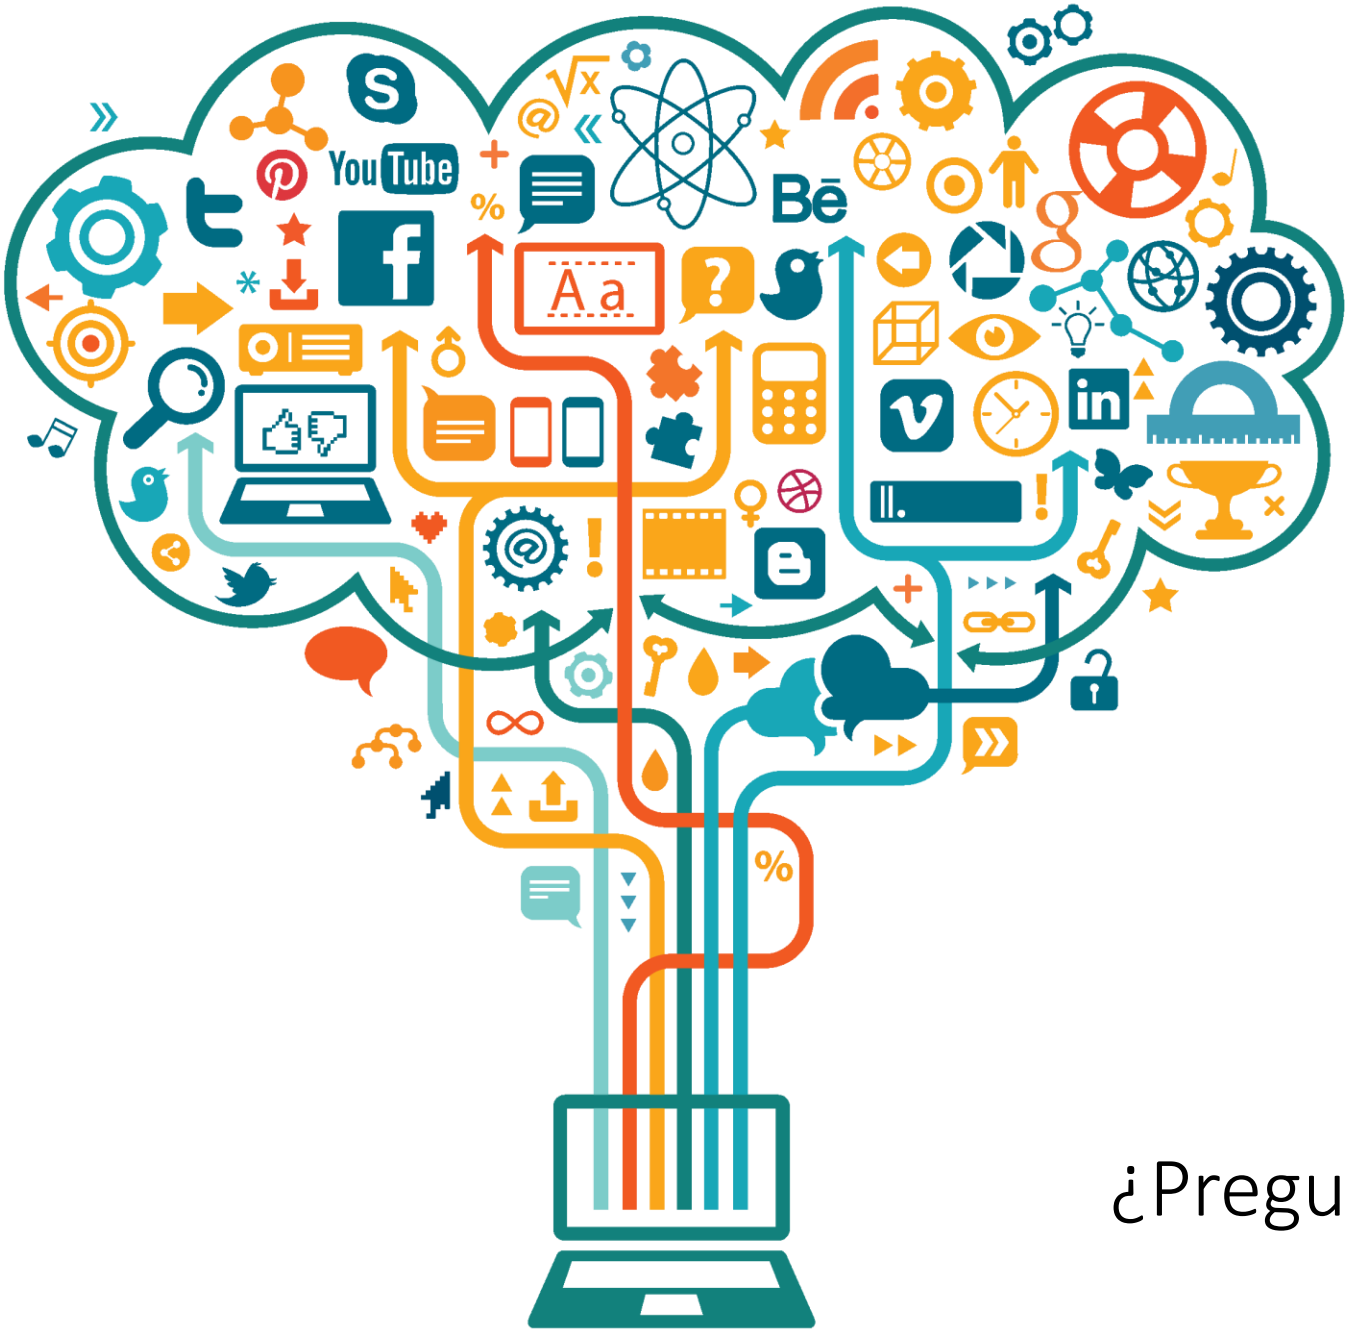
- Caminos más cortos
- Clustering (k-means, label prop.)
- Centralidad (PageRank, ...)
- Cortes de grafo



Implementaciones distribuidas







¿Preguntas?