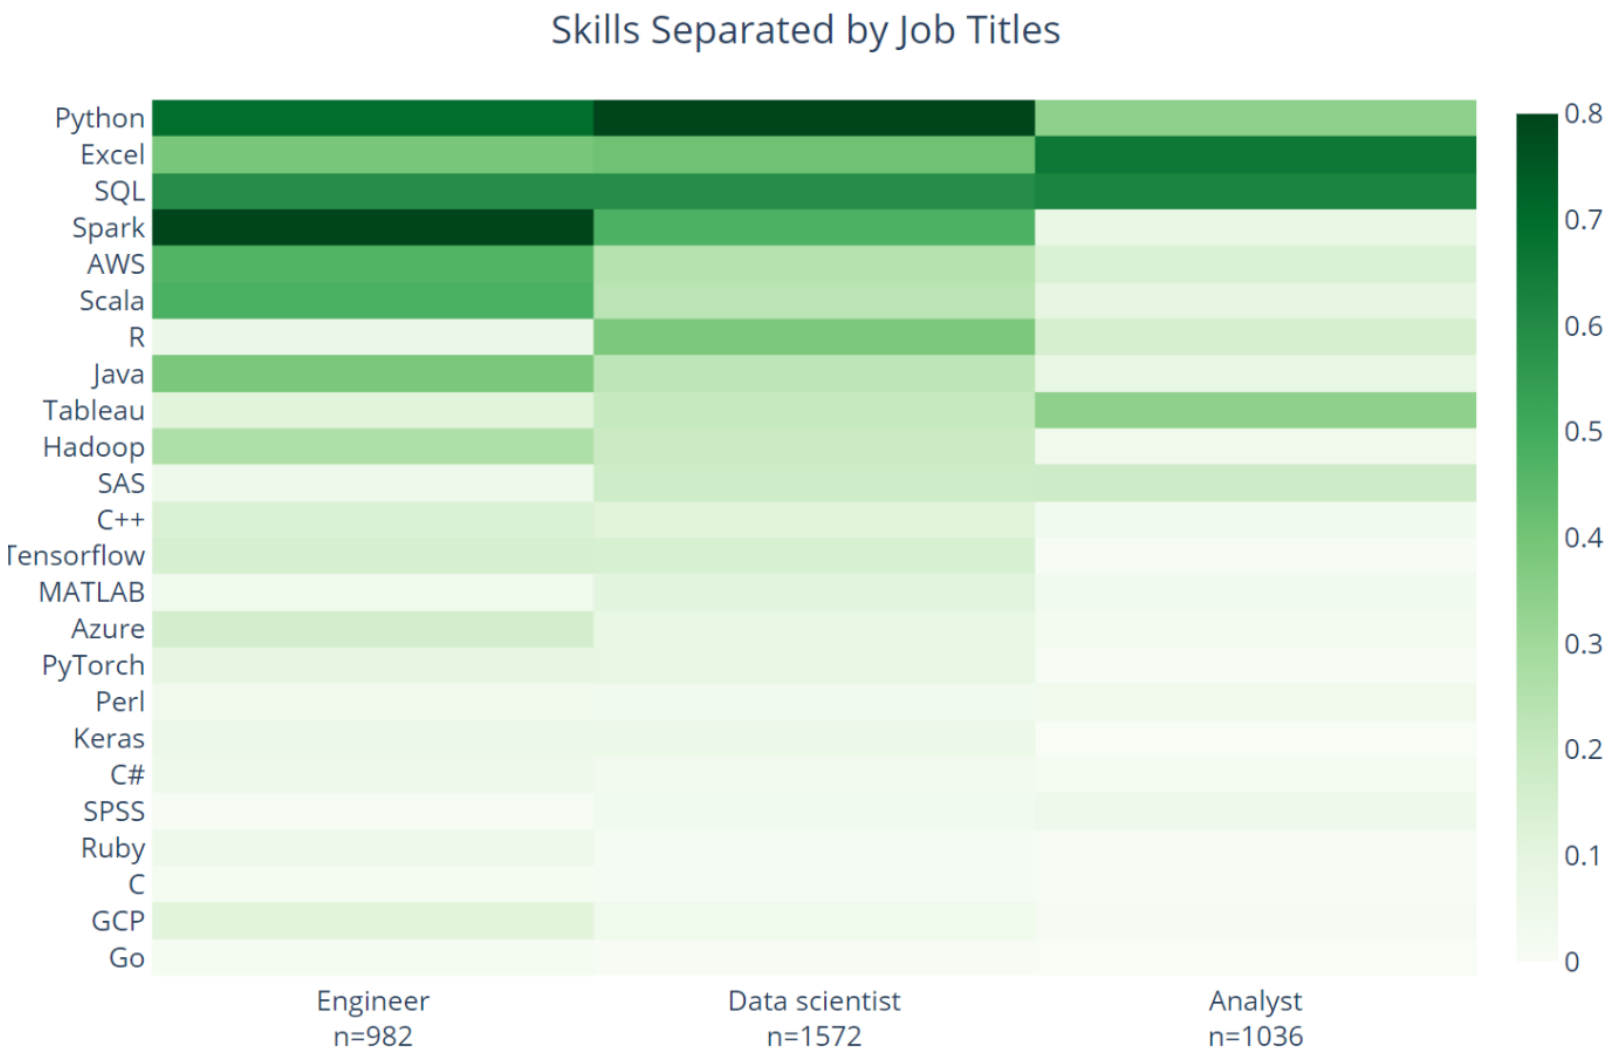
Big Data

Diplomado de Datos 2026

Clase 9: Conclusión

Aidan Hogan
aidhog@gmail.com

“Data Scientist” Ofertas de Trabajo



https://medium.com/@chihhsulin/5-500-data-scientist-jobs-report-2020-adefe1d364d3

Big Data ...

Big Data Consultant Salaries

How much does a Big Data Consultant make?

Updated Jun 14, 2023

Experience: All years of Experience

Industry: All industries

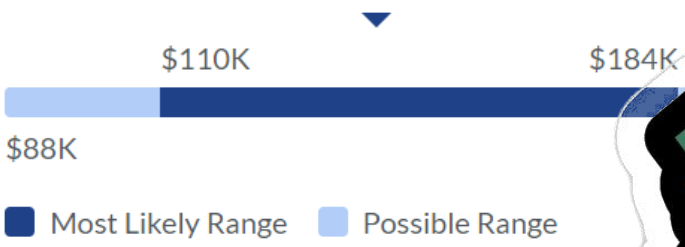
$141,545 / yr

Confident

Total Pay

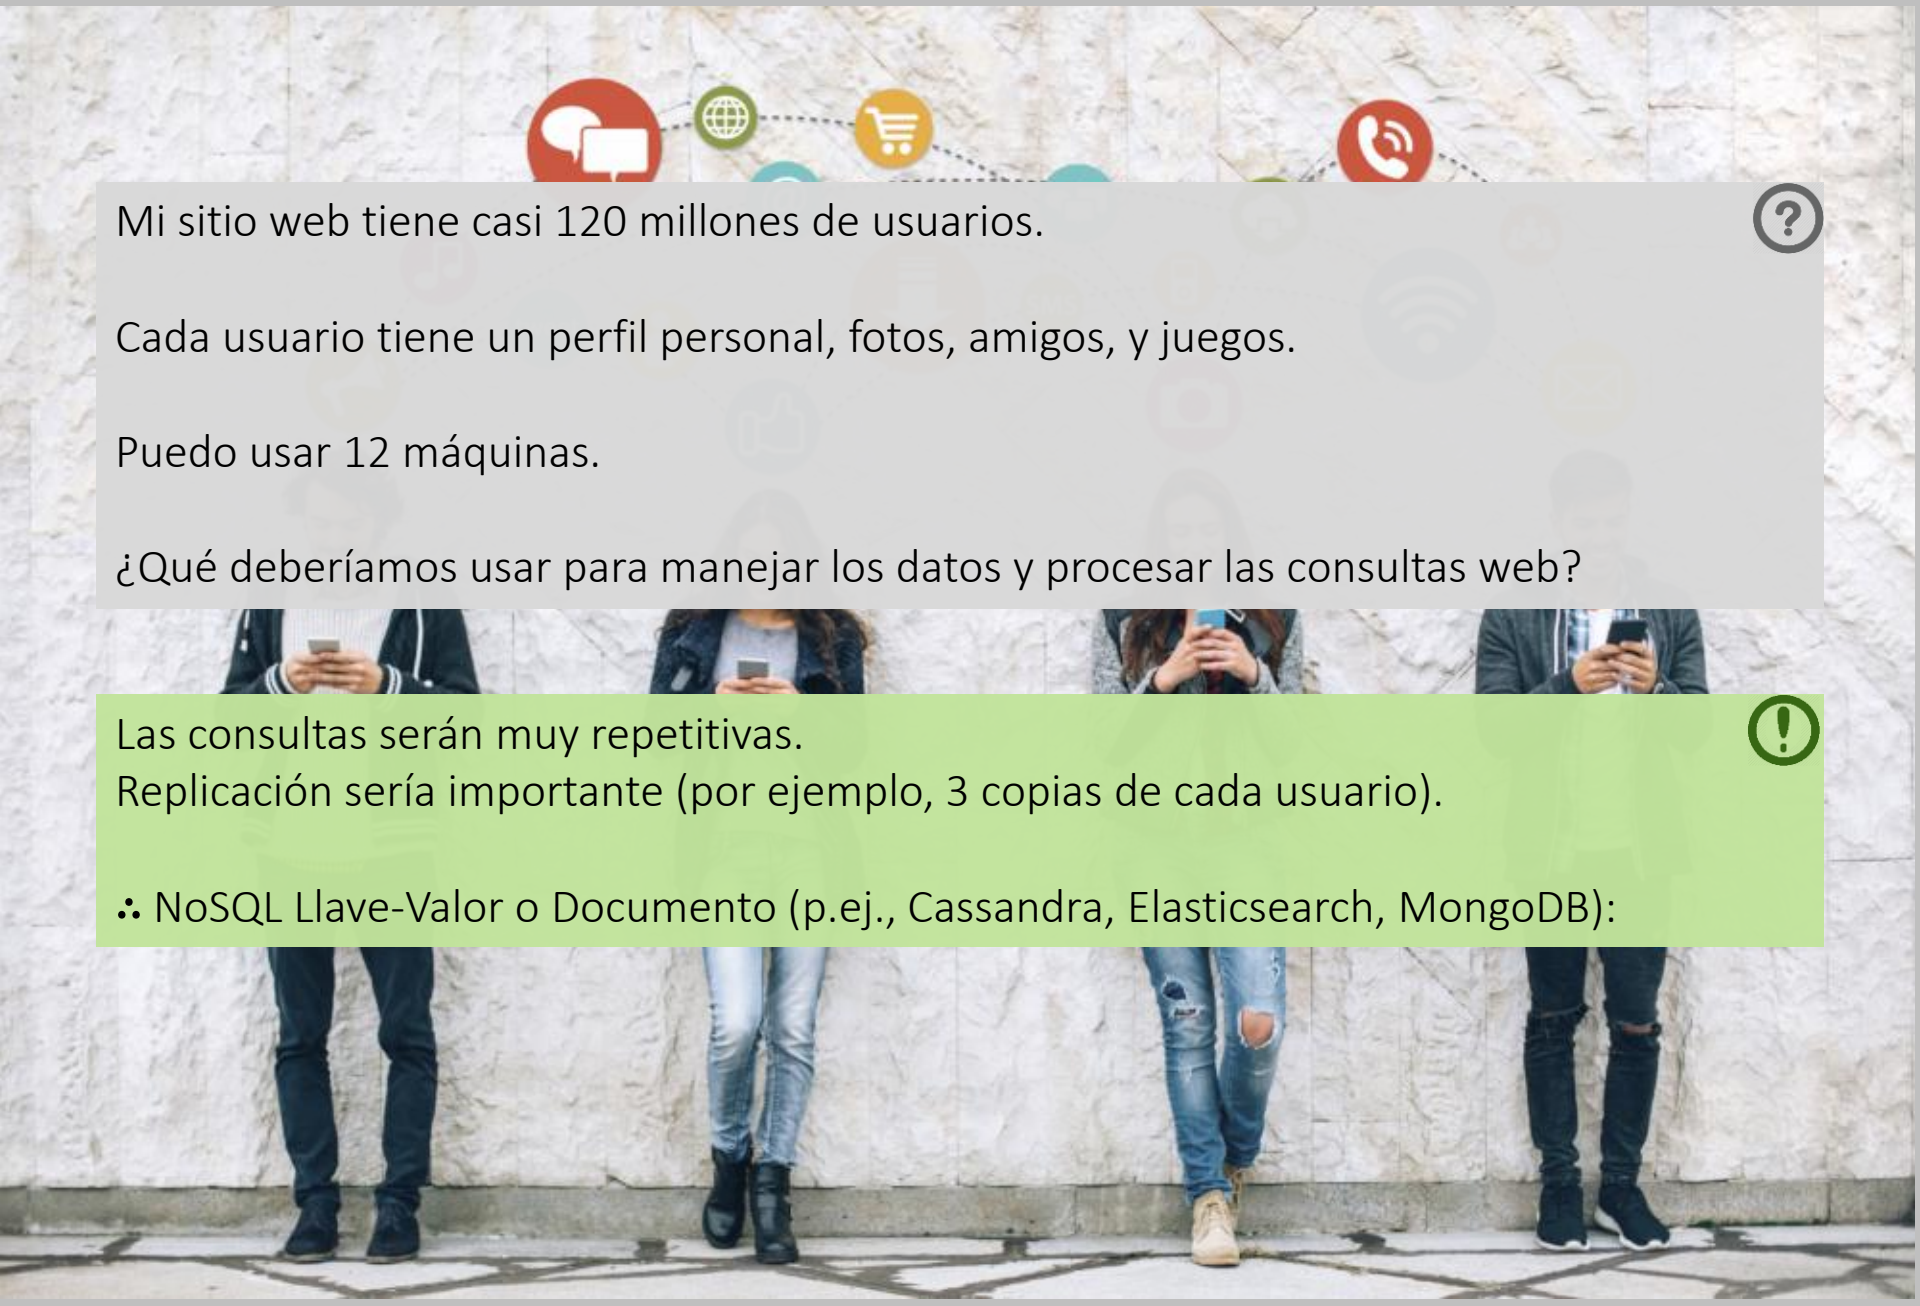
$114,395 / yr
Base Pay

$27,149 / yr
Additional Pay



The estimated total pay for a Big Data Consultant is $141,545 per year in the United State
salary of $114,395 per year. These numbers represent the median, which is the midpoint
proprietary Total Pay Estimate model and based on salaries collected from our users. Th
$27,149 per year. Additional pay could include cash bonus, commission, tips, and profit
Range" represents values that exist within the 25th and 75th percentile of all pay data avail
ole.





Mi sitio web tiene casi 120 millones de usuarios.

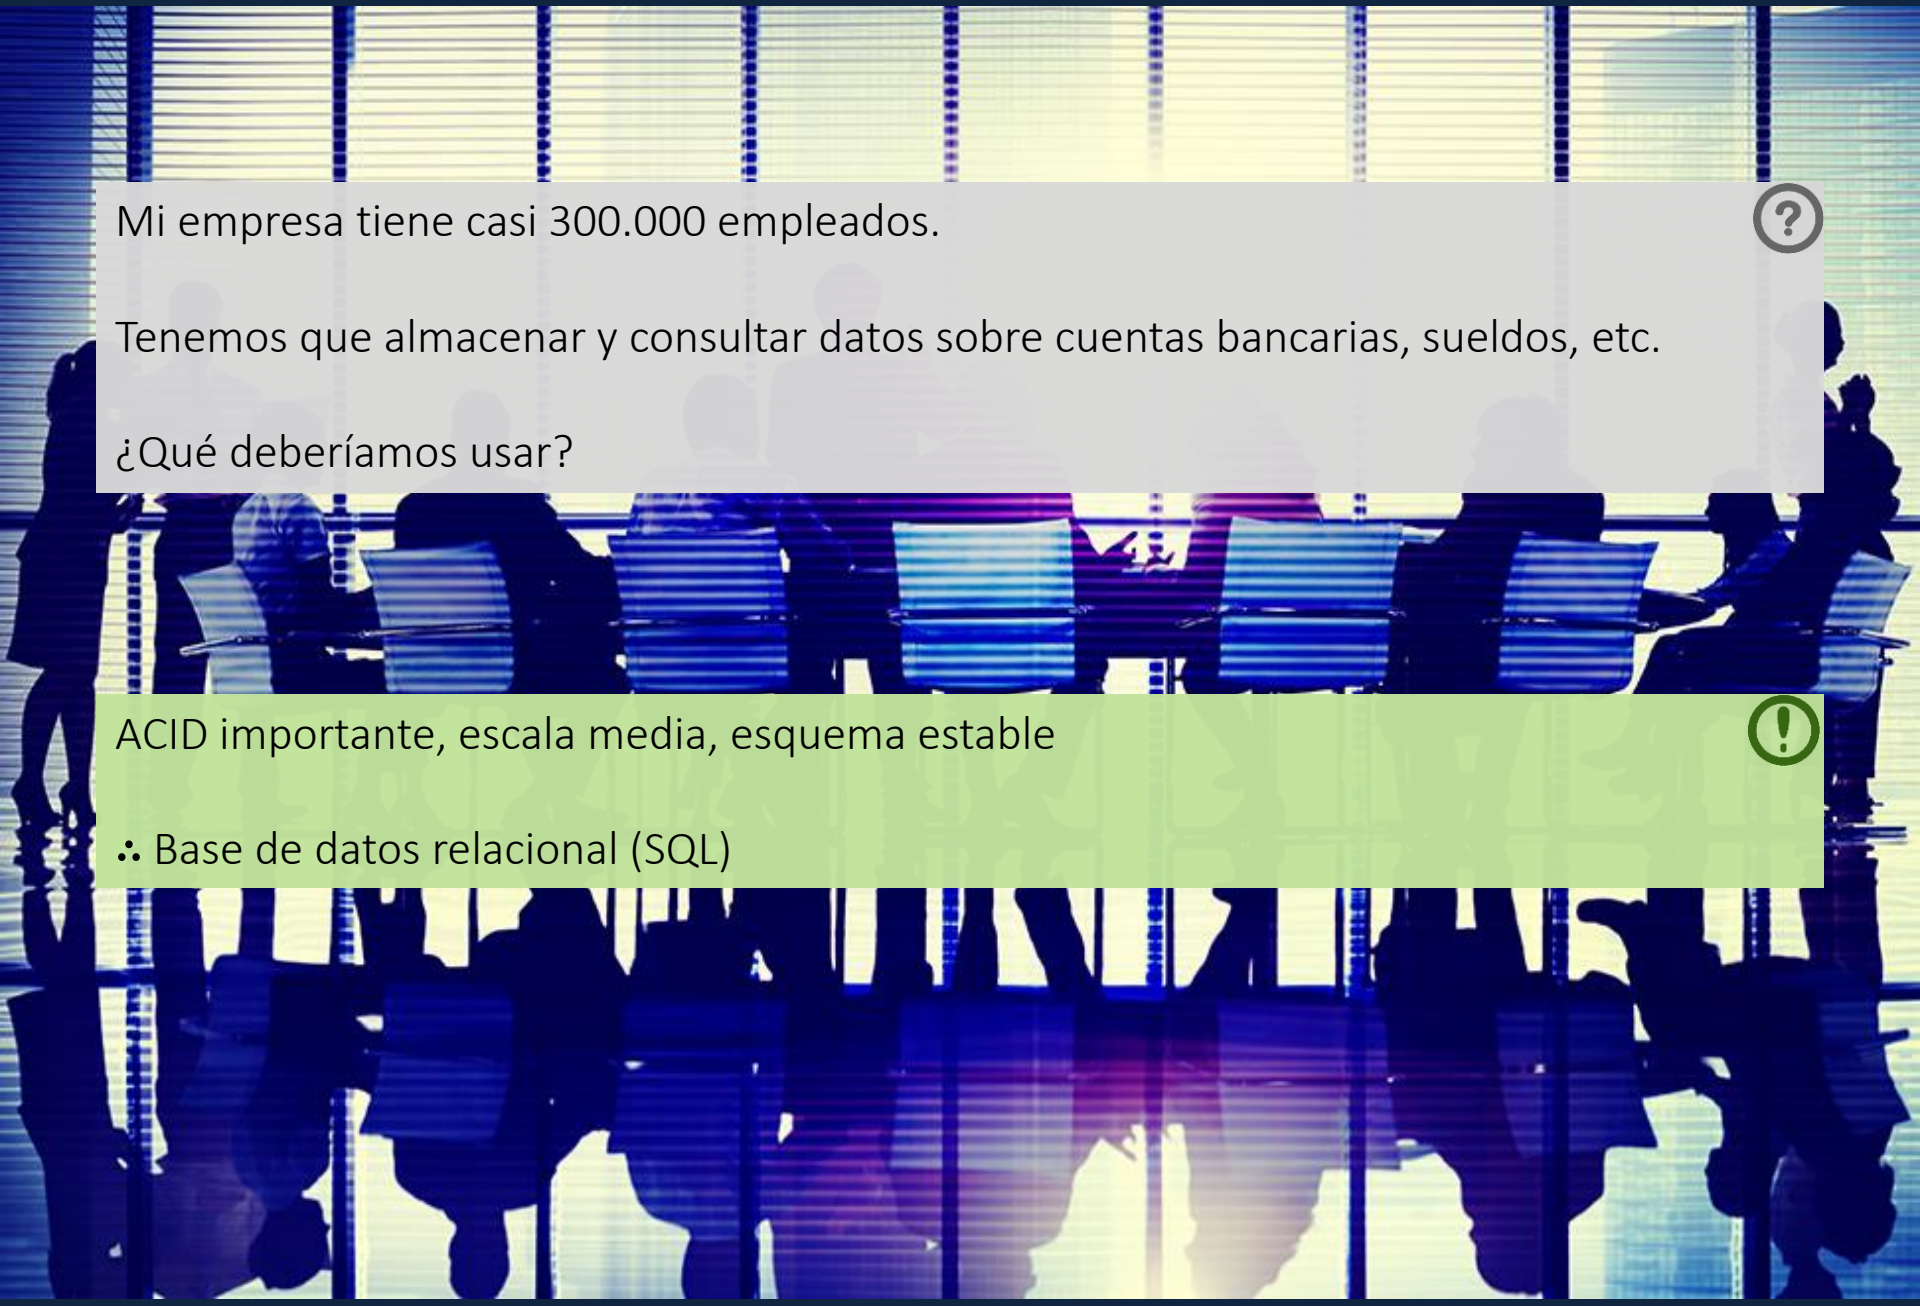
Cada usuario tiene un perfil personal, fotos, amigos, y juegos.

Puedo usar 12 máquinas.

¿Qué deberíamos usar para manejar los datos y procesar las consultas web?

Las consultas serán muy repetitivas.
Replicación sería importante (por ejemplo, 3 copias de cada usuario).

∴ NoSQL Llave-Valor o Documento (p.ej., Cassandra, Elasticsearch, MongoDB):



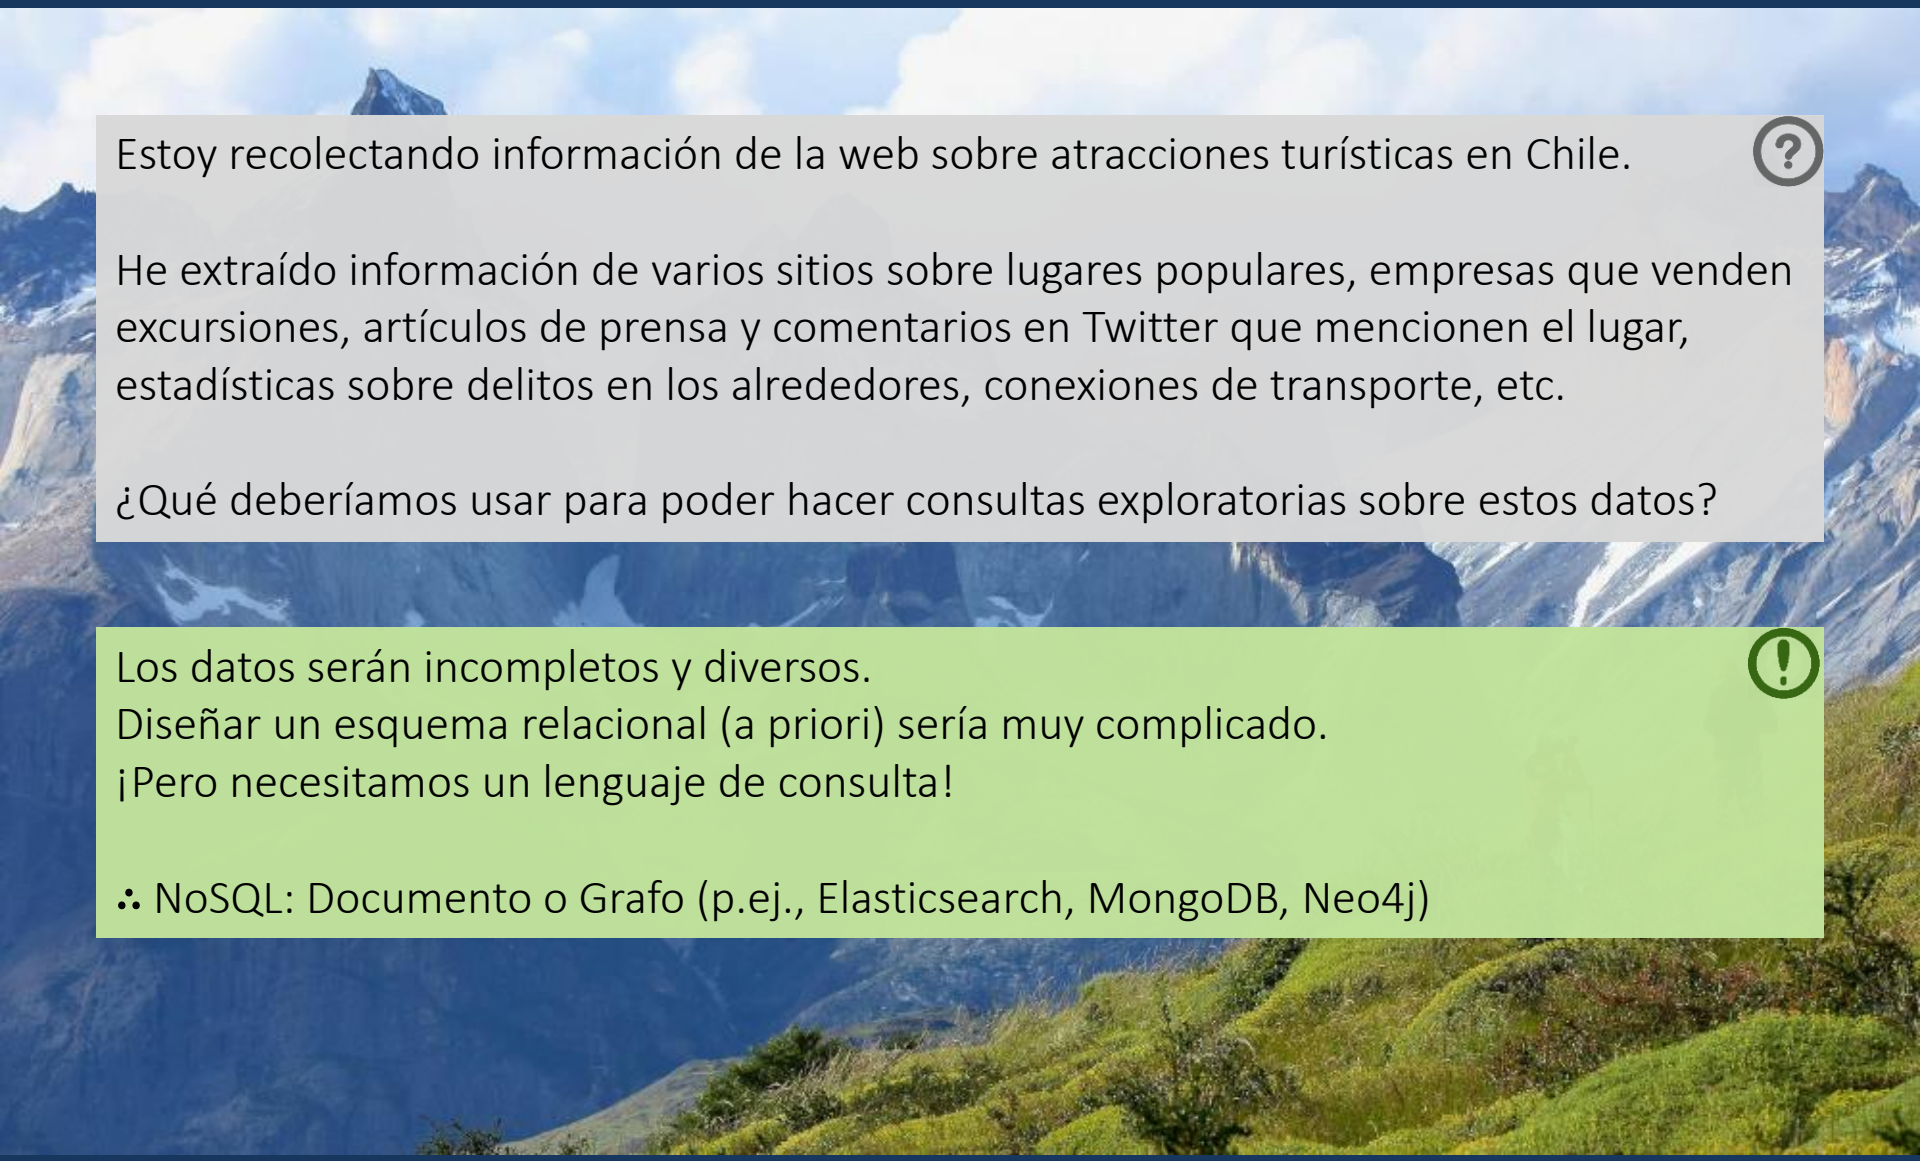
Mi empresa tiene casi 300.000 empleados.

Tenemos que almacenar y consultar datos sobre cuentas bancarias, sueldos, etc.

¿Qué deberíamos usar?

ACID importante, escala media, esquema estable

∴ Base de datos relacional (SQL)



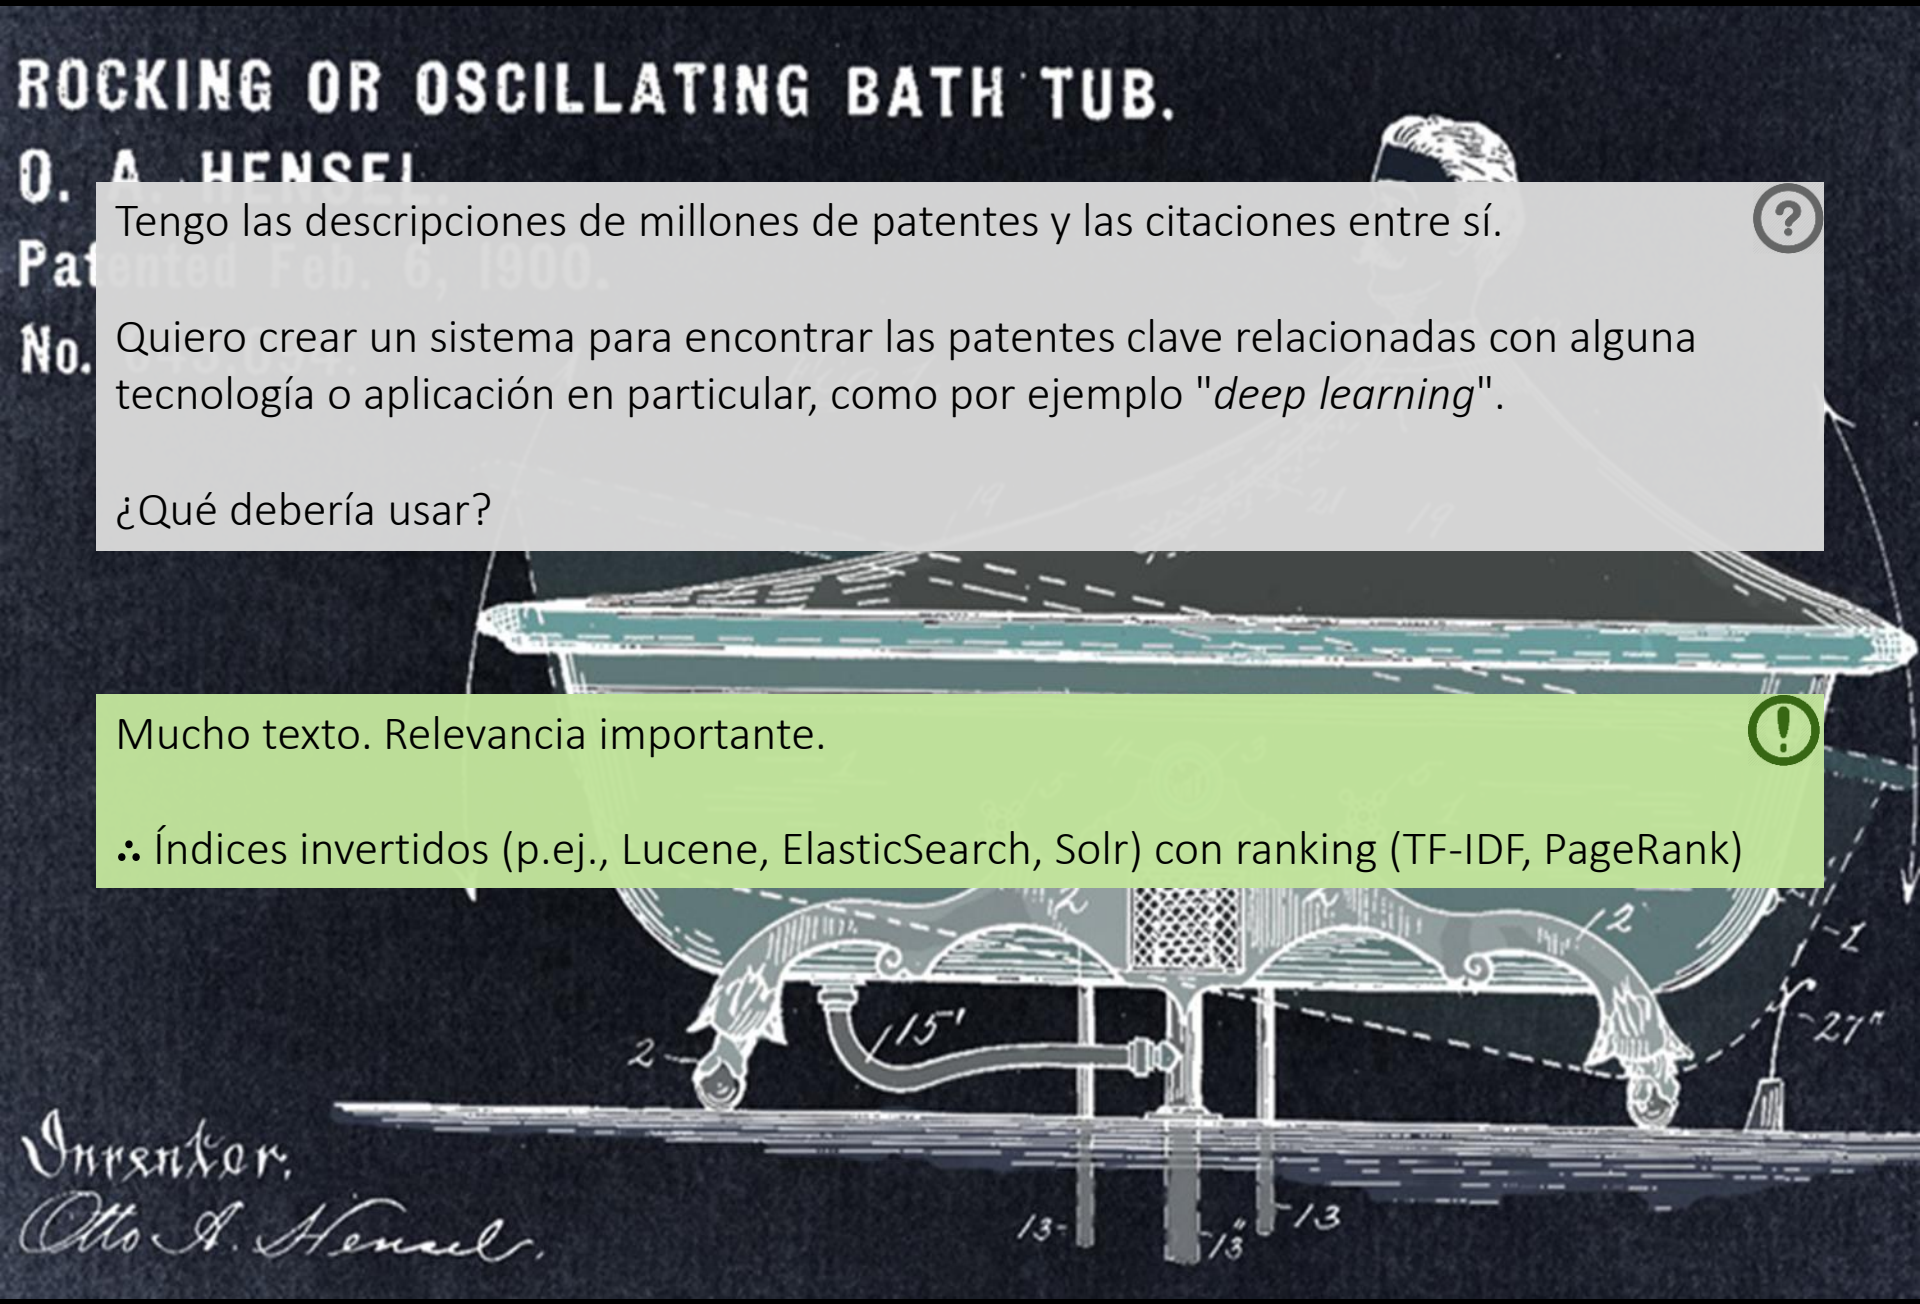
Estoy recolectando información de la web sobre atracciones turísticas en Chile.

He extraído información de varios sitios sobre lugares populares, empresas que venden excursiones, artículos de prensa y comentarios en Twitter que mencionen el lugar, estadísticas sobre delitos en los alrededores, conexiones de transporte, etc.

¿Qué deberíamos usar para poder hacer consultas exploratorias sobre estos datos?

Los datos serán incompletos y diversos.
Diseñar un esquema relacional (a priori) sería muy complicado.
¡Pero necesitamos un lenguaje de consulta!

∴ NoSQL: Documento o Grafo (p.ej., Elasticsearch, MongoDB, Neo4j)



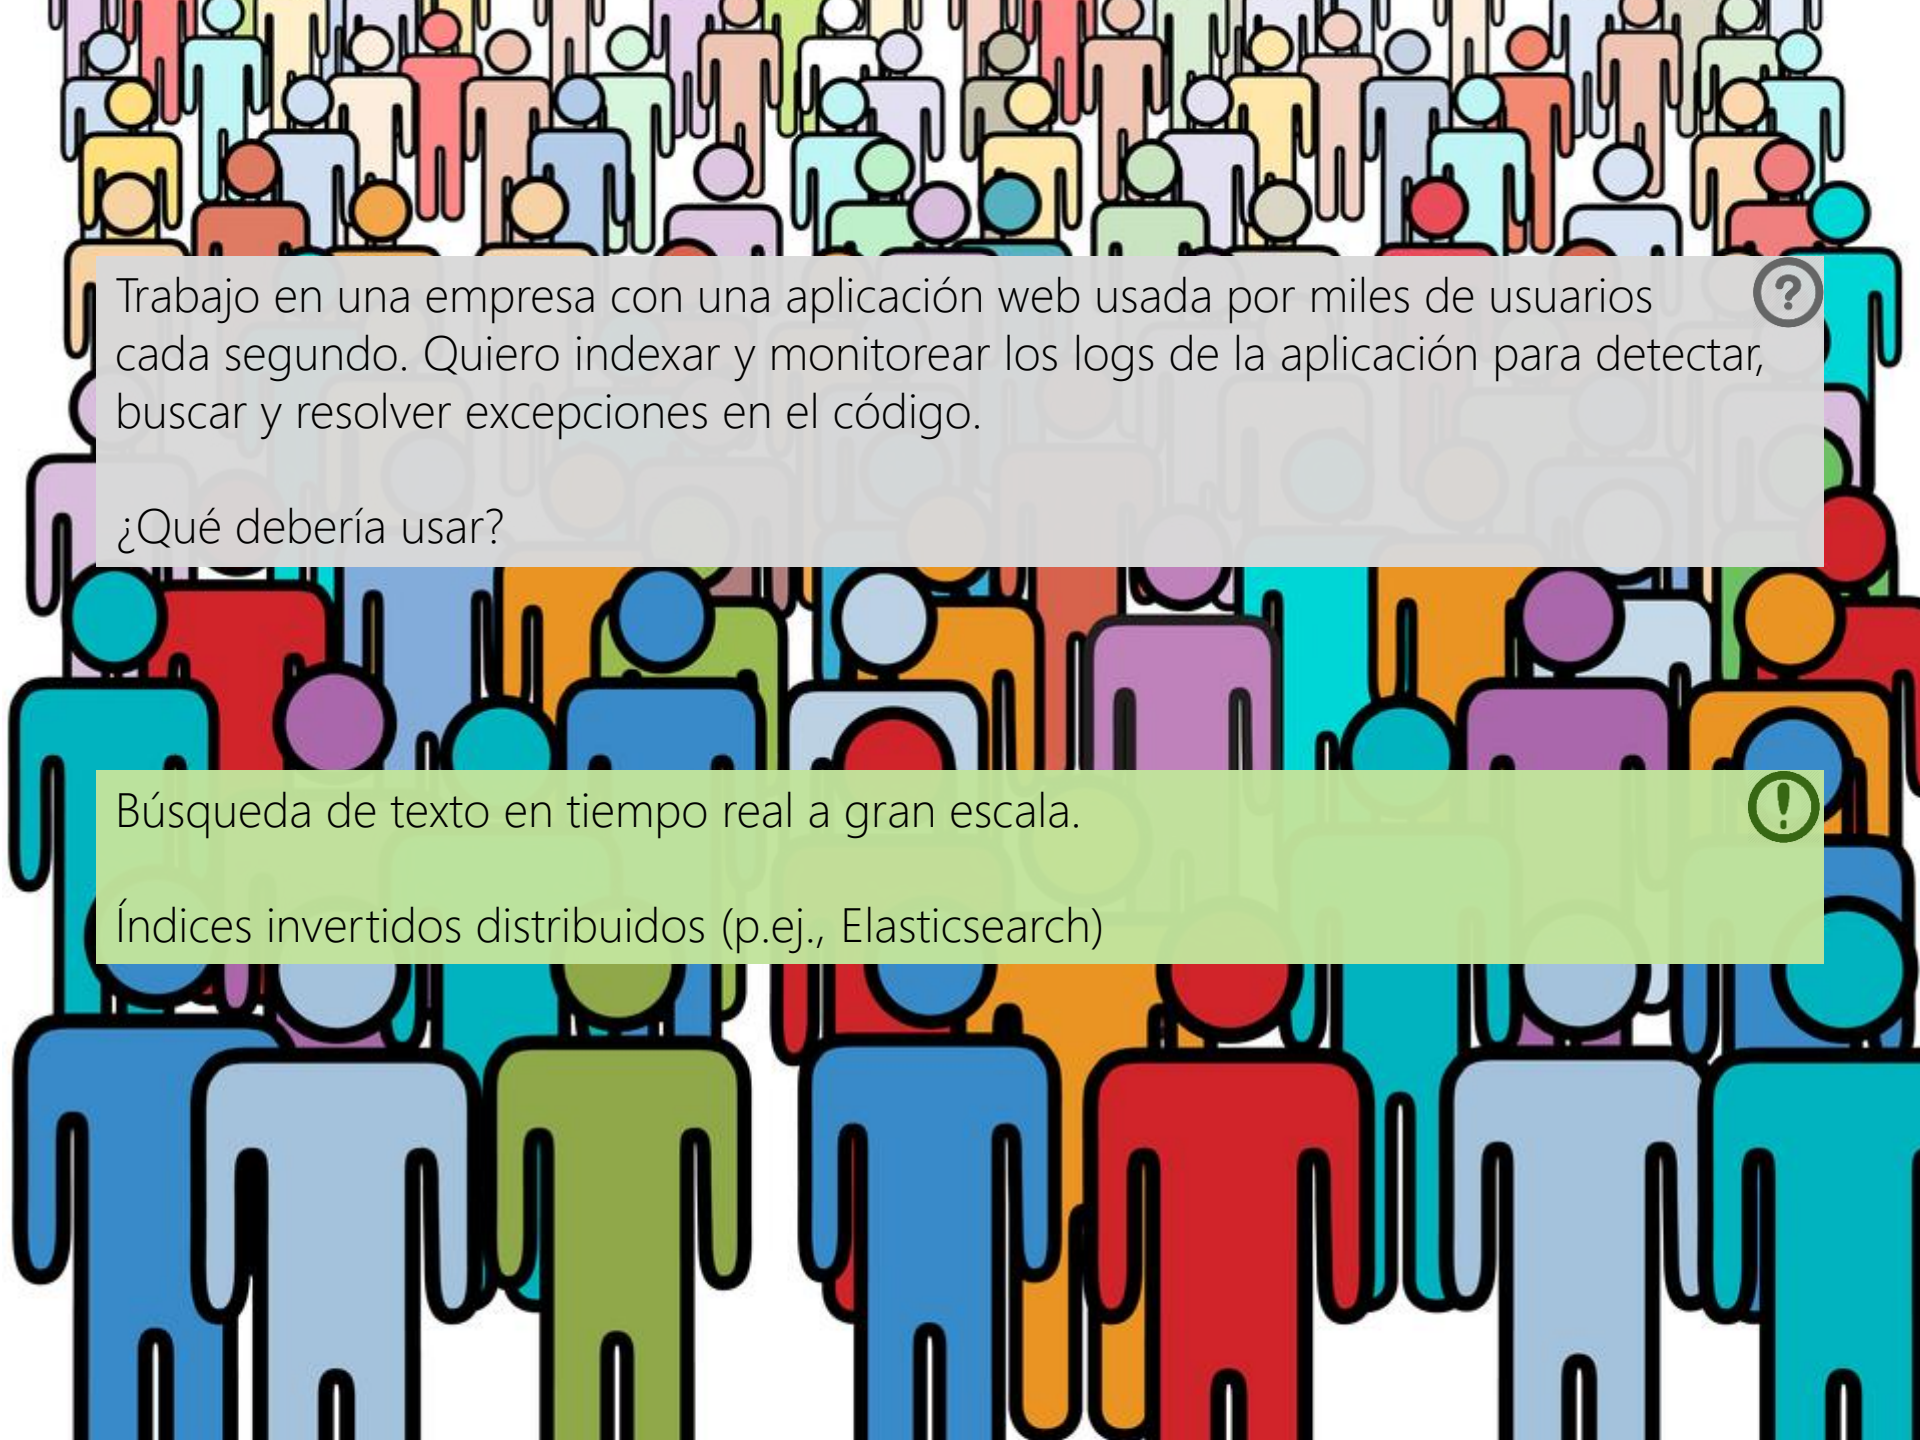
Tengo las descripciones de millones de patentes y las citaciones entre sí.

Quiero crear un sistema para encontrar las patentes clave relacionadas con alguna tecnología o aplicación en particular, como por ejemplo "*deep learning*".

¿Qué debería usar?

Mucho texto. Relevancia importante.

∴ Índices invertidos (p.ej., Lucene, ElasticSearch, Solr) con ranking (TF-IDF, PageRank)

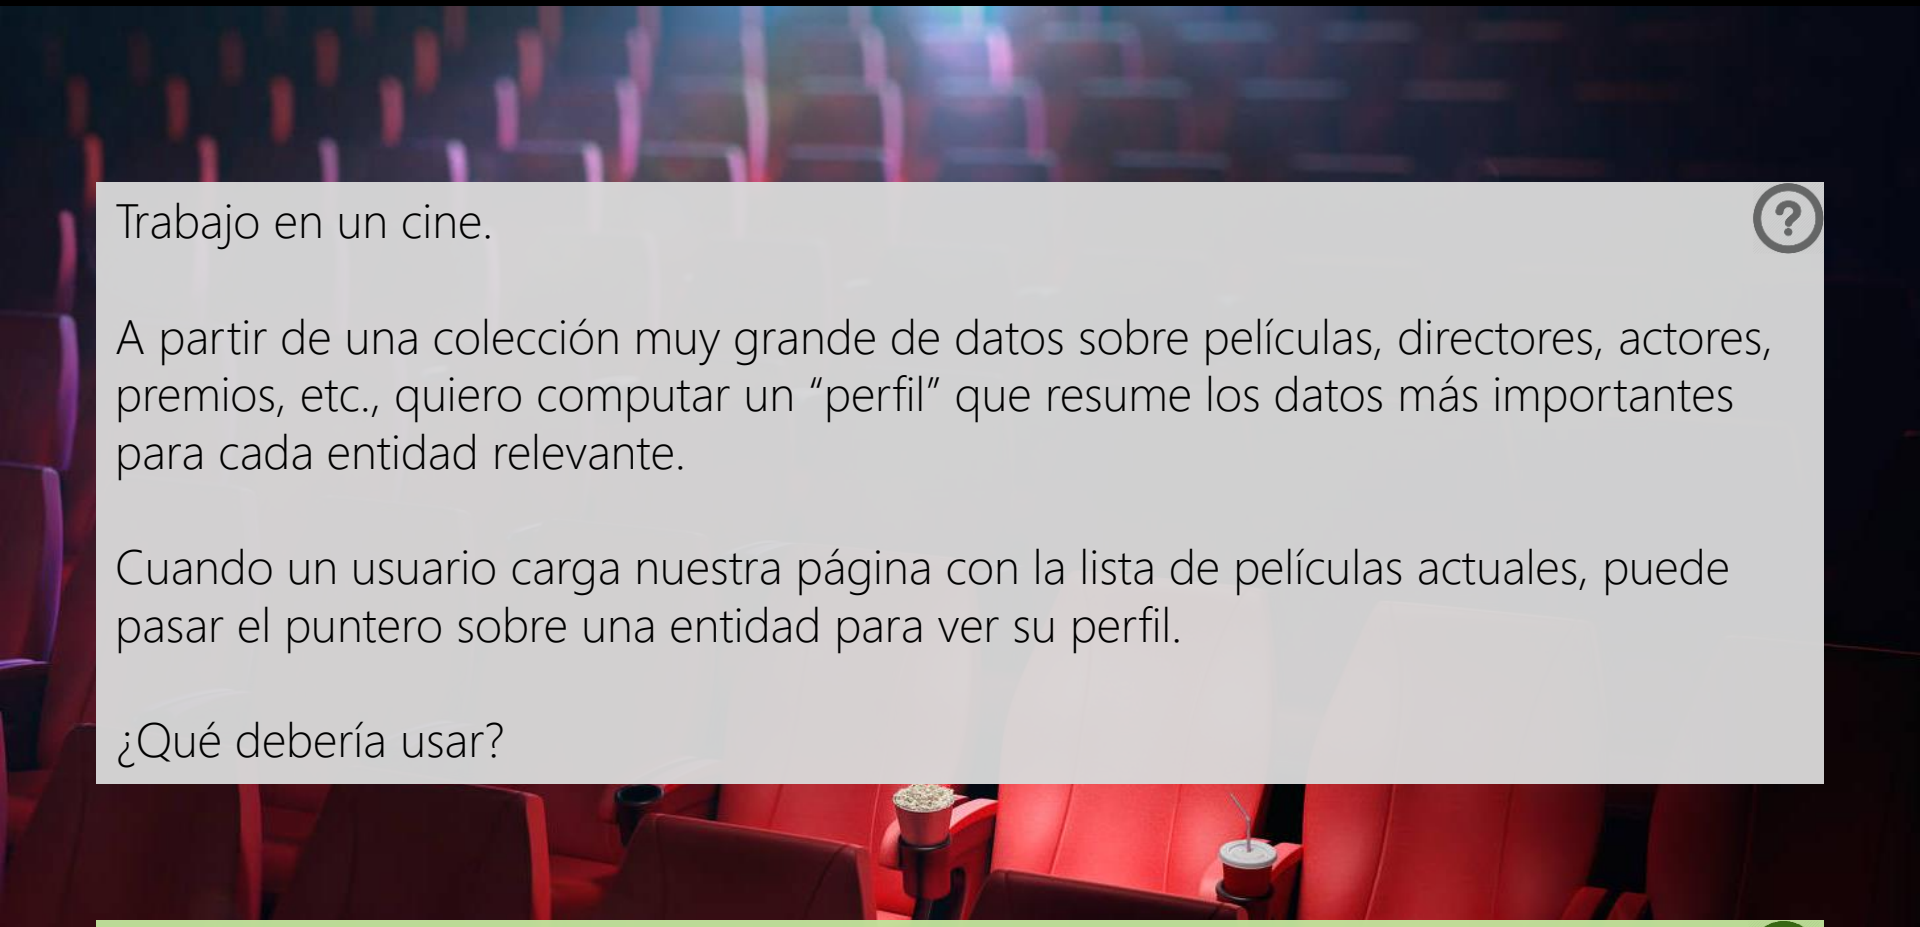


Trabajo en una empresa con una aplicación web usada por miles de usuarios cada segundo. Quiero indexar y monitorear los logs de la aplicación para detectar, buscar y resolver excepciones en el código.

¿Qué debería usar?

Búsqueda de texto en tiempo real a gran escala.

Índices invertidos distribuidos (p.ej., Elasticsearch)



Trabajo en un cine.

A partir de una colección muy grande de datos sobre películas, directores, actores, premios, etc., quiero computar un "perfil" que resume los datos más importantes para cada entidad relevante.

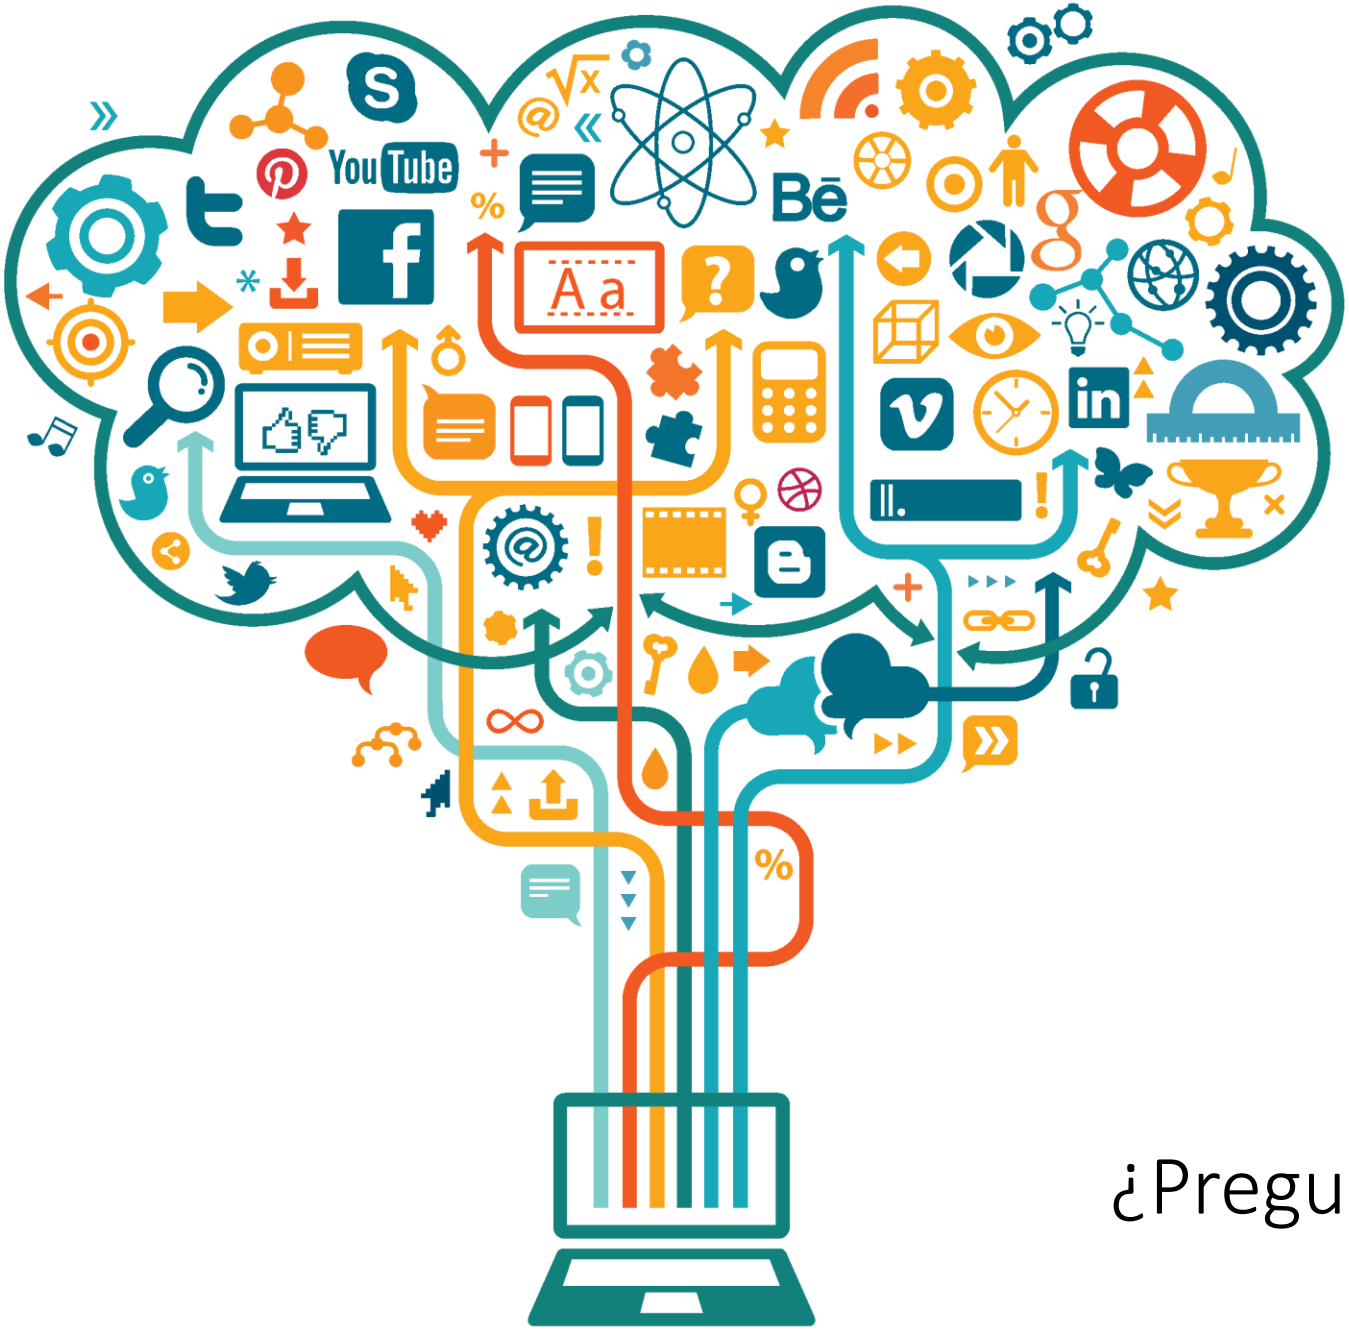
Cuando un usuario carga nuestra página con la lista de películas actuales, puede pasar el puntero sobre una entidad para ver su perfil.

¿Qué debería usar?

Computar los perfiles involucra muchos datos pero podemos hacerlo en bulto e indexar los resultados para la aplicación.

∴ Hadoop/Spark para computar los perfiles
∴ NoSQL Llave-Valor o Documento (p.ej.., Cassandra, ElasticSearch MongoDB) para indexarlos

</curso>



¿Preguntas?